



学校代码: 10272

学 号: 2025213357

上海财经大学

SHANGHAI UNIVERSITY OF FINANCE AND ECONOMICS

硕 士 学 位 论 文

MASTER DISSERTATION

(专 业 硕 士)

论文题目: 基于动态参考点的 CPT-PG 在线
策略优化

培养院系: 统计与数据科学学院

论文类别: 应用统计硕士专业学位论文

论文作者: 董祉含

指导教师: 张智恒

完成日期: 2026 年 6 月

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品成果。对本人的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

论文作者签名：

日期： 年 月 日

学位论文版权使用授权书

(硕士学位论文用)

本人完全了解上海财经大学关于收集、保存、使用学位论文的规定，即：按照有关要求提交学位论文的印刷本和电子版本。上海财经大学有权保留并向国家有关部门或机构送交本论文的复印件和扫描件，允许论文被查阅和借阅。本人授权上海财经大学可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

论文作者签名：

导师签名：

日期： 年 月 日

日期： 年 月 日

摘 要

投资者即使持有相同的期末财富，也可能因为此前经历了上涨回落或下跌反弹，而以不同的参考点评价下一次投资。累积前景理论（CPT）能够描述这种参考依赖的风险判断，但现有的一阶策略优化通常固定参考点；在连续投资中，策略改变财富路径，财富路径又改变参考点，使下一期的 CPT 目标随市场和账户经历共同移动。本文研究这一情形下的在线投资组合学习，提出动态参考点累积前景策略梯度方法（DRCPT-PG）。

方法以股票因子驱动的 Dirichlet 策略生成满足权重约束的随机投资组合，沿每条财富轨迹逐日更新参考点，并用期末相对结果评价策略。针对每一期给定状态后的 CPT 目标，本文结合中心化留一估计与随机层级修正，构造严格无偏的梯度估计量，证明其具有有限期望轨迹成本和有限方差，并给出渐近正态性及固定维度下的最优轨迹预算速率。跨期采用归一化投影更新跟踪移动目标；当目标总变差为次线性、估计与模拟误差的平均影响逐渐消失，平均平方投影残差趋于零，动态局部遗憾呈次线性增长。

实验依次考察参考点的路径依赖、梯度估计和在线跟踪。在连续缓变的半合成市场中，持续更新策略的累积平方投影残差为 0.684，冻结策略为 1.427。按时间顺序进行的沪深 300 真实市场回放表明，在五种策略梯度方法中，DRCPT-PG 取得最高的平均 Sharpe 比率，以及最低的平均最大回撤、换手和交易成本。真实投资者的样本外持股决策进一步显示，非对称动态参考点对减持行为的预测比静态参考点更准确。由此，参考点既记录投资经历对盈亏判断的影响，也成为策略更新时需要随账户路径持续跟踪的状态。

关键词：累积前景理论；动态参考点；策略梯度；投资组合优化；动态局部遗憾

Abstract

Cumulative prospect theory (CPT) models portfolio choice relative to a reference point, yet most first-order CPT policy methods keep that reference fixed even when realized wealth should update it. We study online portfolio optimization with an endogenous reference state, where policy decisions reshape wealth, wealth updates the reference, and the resulting CPT objective moves over time. We introduce Dynamic-Reference Cumulative Prospect Policy Gradient (DRCPT-PG), which combines an exactly unbiased estimator of the regularized frozen-target CPT gradient with finite expected trajectory cost and variance, and a normalized projected update for tracking the moving first-order target. The estimator supports studentized asymptotic inference and attains the fixed-dimensional minimax trajectory-budget rate, while the online analysis controls the projected residual and dynamic local regret under sublinear objective variation. In controlled experiments, continued updating reduces cumulative squared projected residual from 1.427 to 0.684 relative to a frozen closed-loop control. In a chronological 300-stock A-share replay, DRCPT-PG achieves the highest mean Sharpe ratio and the lowest mean maximum drawdown, turnover, and transaction cost among five policy-gradient methods; held-out investor data further show incremental predictive gains from adaptive and asymmetric reference representations. These results connect adaptive reference formation to a statistically controlled first-order learning framework for path-dependent online portfolio optimization.

目 录

摘要	I
Abstract	II
第一章 引言	1
1.1 研究背景	1
1.2 文献综述	2
1.2.1 累积前景理论与策略优化	2
1.2.2 动态参考点、路径依赖与投资者行为	3
1.2.3 非平稳非凸在线优化与局部跟踪	3
1.2.4 梯度去偏与因子化投资组合策略	4
1.2.5 投资建议与异质投资者	5
1.3 研究问题与贡献	5
1.4 论文结构	6
第二章 问题设定与假设	7
2.1 非平稳有限时域投资过程	7
2.2 动态参考点与终端相对结果	7
2.3 Dirichlet 投资组合策略	8
2.4 正则化 CPT 目标	9
2.5 在线近似误差与目标变化	9
2.6 投影残差与动态局部遗憾	10
2.7 分析假设	11
第三章 算法设计	13
3.1 中心化留一法与随机层修正	13
3.2 在线参数更新	14

第四章 主要结论	16
4.1 参考点的路径依赖	16
4.2 冻结目标的 CPT 梯度与统计估计	17
4.3 固定维度下的极小极大信息率	19
4.4 移动 CPT 目标下的一阶跟踪	19
第五章 实验研究	21
5.1 E1: 路径依赖与投资组合选择	21
5.2 E2: 有限样本梯度估计	23
5.3 E3: 连续缓变环境中的在线跟踪	25
5.4 E4: 参考点机制消融与在线跟踪稳健性	27
5.5 E5: 真实市场投资组合评价	29
5.6 E6: 投资者行为预测	31
5.7 E7: 异质投资者模拟交互	33
第六章 讨论与结论	35
参考文献	37
附录	40
附录 1 主要符号与分析预备结果	40
附录 1.1 主要符号	41
附录 1.2 Dirichlet 得分矩	41
附录 1.3 CPT 目标的光滑性	42
附录 1.4 投影残差与受约束驻点	43
附录 2 参考点机制与 CPT 梯度的证明	44
附录 2.1 相同期末财富与路径依赖参考点	44
附录 2.2 参考点收缩与 CPT 敏感性	44
附录 2.3 CPT 梯度的得分表示	45

附录 3 去偏估计器的证明	46
附录 3.1 二阶展开与全样本/半样本耦合	46
附录 3.2 中心化与有限样本偏差	49
附录 3.3 无偏性、方差、成本与中心极限定理	49
附录 4 在线残差与驻点跟踪的证明	51
附录 4.1 归一化投影上升	51
附录 4.2 期望平均平方投影残差	52
附录 4.3 动态局部遗憾	53
附录 4.4 驻点集合的推论	54
附录 5 固定维度极小极大速率的证明	55
致谢	59
个人简历	60

第一章 引言

第一节 研究背景

投资者评价一笔投资时，眼前的账户余额并不是唯一依据。设两位投资者的初始财富都为 1，期末都为 1.2：一人的账户曾升至 1.4 后回落，另一人曾跌至 0.8 后回升。前者可能觉得自己损失了已经到手的收益，后者则可能觉得已经摆脱亏损。两条路径的起点和终点相同，但经历改变了他们用来判断盈亏的参考点。若投资组合策略只观察期末财富，便无法区分这两种处境，也难以解释下一次调仓为何不同。

累积前景理论（cumulative prospect theory, CPT）以参考点为界评价收益和损失，并通过非线性的概率权重描述人们对不同风险事件的感受^[1,2]。在投资组合问题中，这意味着策略的好坏不仅取决于平均收益，还取决于各条财富路径的相对结果及其分布。强化学习使策略能够在连续决策中根据交互结果调整参数；CPT 则为这种学习提供了不同于期望收益最大化的评价准则。已有工作研究了 CPT 下的预测、控制与有限时域策略梯度，为优化这类分布型目标提供了基础^[3,4]。

然而，连续投资中的参考点不会始终停在买入价或预设常数上。证券交易实验发现，经历收益和损失后，人们会调整评价后续结果的基准，而且两个方向的调整幅度可能不同^[5]。适应性参考点与处置效应的关系、以及参考点对完整财富路径的依赖，也已在投资决策模型中得到研究^[6,7]。当这些行为机制进入在线投资组合学习时，策略影响财富，财富改变参考点，参考点又改变下一期策略面对的 CPT 目标。即使外部市场条件暂时不变，投资者自己的交易经历也可能使目标发生移动；市场变化则会在此之外带来另一层扰动。

这一反馈使问题具有两个不同的难点。给定一期的市场和参考状态，CPT 梯度中的概率权重仍依赖未知的结果分布，直接用有限轨迹的经验分布代替，通常会留下估计偏差。跨期来看，策略还须在目标随市场与账户状态变化时持续

更新，不能只证明它在某一个固定目标附近停止。前一问题关乎有限轨迹能否提供可靠的一阶信息，后一问题关乎这些信息能否帮助策略跟上正在移动的目标。本文以动态参考点下的投资组合选择为场景，将二者放在同一在线优化问题中研究。

第二节 文献综述

1.2.1 累积前景理论与策略优化

前景理论及其累积形式把参考依赖的价值判断和非线性概率权重引入风险决策^[1,2]。一笔投资的结果先被判为相对于参考点的收益或损失，再经价值函数和概率权重进入评价。因而，两个平均收益相同的策略，只要极端亏损出现的概率不同，就可能得到不同的 CPT 价值。在多期投资中，评价对象是整条交易路径形成的终端结果分布；简单地把逐日收益换成另一种单期奖励，不能得到同一个目标。

围绕这一分布型目标，Prashanth 等研究了 CPT 强化学习中的价值估计与控制，用经验结果分布计算 CPT 价值，再据此改进决策^[3]。Lepel 和 Barakat 则直接处理有限时域策略的参数优化：他们推导 CPT 策略梯度，将轨迹结果的顺序统计量用于蒙特卡洛估计，并分析所得策略达到近似驻点所需的样本量^[4]。前者说明了如何由样本评价一个具有概率加权的策略，后者进一步说明了如何利用轨迹样本调整策略参数。不过，一旦总体生存概率被有限样本的经验频率代替，非线性权重导数一般不会保持严格无偏；这一点在每期只能取得有限轨迹的在线学习中尤为重要。

投资组合领域还从另一条路线研究 CPT 目标。Luxenberg 等利用目标的优化结构求解非凹的组合配置问题^[8]；Cui 等和 Wu 等以交替方向方法处理概率加权目标及组合约束^[9,10]。这些方法着重于给定收益分布或给定决策问题时如何找到配置。本文沿用有限时域策略梯度的学习路线，关注的是每次调仓只能依据当期轨迹估计梯度、下一次调仓的参考点又会改变的情形。于是，有限样本梯度的统计性质与跨期目标的移动需要一并处理。

1.2.2 动态参考点、路径依赖与投资者行为

参考点如何随经历改变，首先是一个可以观察的行为问题。Arkes 等在证券交易实验中发现，经历上涨后形成的收益基准与经历下跌后的调整并不对称；即使把股票放入组合情境，这种调整也仍值得考察^[5]。如果投资者曾见到账户升至较高水平，随后即便回落至买入价之上，也可能把这次回落视为损失。这说明固定买入成本不能概括投资者的全部盈亏判断。

实现效用研究把这种判断纳入动态交易模型。He 和 Yang 研究单只股票的卖出与再次买入，允许参考点在盈利和亏损后以不同速度适应，说明参考点调整会改变盈利出售概率与亏损出售概率^[6]。Qin 等进一步研究路径依赖的参考点：当前价格与当前持仓相同，先前经历过的高点或低点仍可能改变接下来的卖出选择^[7]。从单只股票走向多期组合后，Gao 等表明动态参考点和跨期相关的收益会共同影响配置决策^[11]。这些模型说明了历史经历为什么会进入当期选择，但其主要任务不是用轨迹样本估计 CPT 策略梯度，也不分析策略持续更新时目标如何随账户状态移动。

实际交易还提醒我们区分个股盈亏与整个组合的状态。组合整体的盈亏会影响投资者对个股的处置^[12]；有关中国投资者的研究则将社交媒体信息与处置行为联系起来^[13]。因此，同一只账面盈利股票是否被减持，不能只由一种参考点划分来解释。本文在比较静态、对称和非对称参考点时，使用同一批持股决策与相同的可观察控制变量，检验哪种盈亏表示更贴近实际减持。行为证据回答参考点是否有解释力；策略分析则回答参考点逐日变化后，投资组合如何学习。

1.2.3 非平稳非凸在线优化与局部跟踪

当市场条件每期改变时，策略面对的是一列目标函数。对非凸目标，即使知道每期的完整函数，也未必能以有限计算找到全局最优组合；要求在线策略始终追随这些最优组合，与梯度更新能够提供的保证并不相称。Aydore 等为非凸在线预测提出动态局部遗憾，通过近期目标的一阶信息及其时间平滑，评价决策是否持续停留在局部不稳定的位置^[14]。这把关注点从“每期是否全局最优”转

到“局部一阶偏差是否随时间积累”。

投资组合参数还受到可行域约束。位于边界的参数即使有非零梯度，也可能已经不能沿可行方向继续改善目标，因此直接累计梯度范数会误判其一阶状态。梯度映射与投影梯度研究为此采用投影后的一阶残差^[15,16]。非平稳强化学习的变化预算进一步表明，目标变化越快，学习者越难仅凭有限样本保持跟踪精度^[17]。本文以当期真实 CPT 目标的投影残差描述可行的一阶偏差，再平滑最近各期的残差向量并累加其平方范数。外部市场改变收益规律，已执行策略改变财富与参考点；这两种来源一起进入目标变化预算，使在线界能够对应到投资过程本身。

1.2.4 梯度去偏与因子化投资组合策略

即使市场和期初参考点都已固定，CPT 梯度仍包含未知的生存概率：需要知道一条轨迹的结果相对于其他可能结果处于什么位置，才能计算概率权重的边际作用。顺序统计量提供了可计算的样本近似^[4]，但将样本频率代入非线性函数，通常不能仅凭样本平均保证无偏。Rhee 和 Glynn 的随机层级方法提供另一种思路：把不同精度估计之间的差分随机求和，在控制层级成本与差分波动时恢复目标量的期望^[18]。本文据此先用留一统计量避免轨迹参与自身的分位估计，再耦合全样本与两个半样本以消去主要波动。随机层修正消除剩余偏差，使每期得到的梯度估计能够与跨期在线更新的误差界衔接。

多资产投资还要求策略的每次输出都满足现金与股票权重非负、总和为一。André 和 Coqueret 以 Dirichlet 分布构造因子驱动的随机组合，资产特征通过浓度参数影响组合分配；这种参数化让同一组因子系数作用于所有股票，而每只股票因特征不同获得不同权重^[19]。它适合用策略梯度学习，但股票因子及其可用日期必须与交易顺序一致。中国 A 股的因子研究与动态金融数据集研究分别提供了市场特征和时间顺序处理的背景^[20,21]。本文保留这一可行的随机动作结构，在半合成市场中分别检验梯度估计与在线跟踪，再用真实 A 股价格路径考察投资后果。

1.2.5 投资建议与异质投资者

投资组合算法最终给出的并非抽象的目标值，而是一份现金与股票的具体配置建议。投资者可能愿意尝试某份建议，但执行后的感受仍取决于原有持仓、风险偏好和其间的价格路径。关于智能体风险偏好的研究指出，不同个体对相同风险结果的评价可能不同^[22]；个性化投资顾问研究也将投资者差异纳入推荐过程^[23]。这些工作提示，推荐是否被接受与接受后的评价应分别观察。本文依据真实历史行为校准模拟投资者类型，使不同类型面对同一组组合建议，并以维持原持仓为对照计算采纳后的模型前景评价。这样可以观察建议在持续交互中的差异，同时保留真实投资者行为数据与模拟评价之间的区别。

第三节 研究问题与贡献

沿着上述研究脉络，本文的核心问题是：当投资者以随财富路径变化的参考点评价风险，而市场条件也在变化时，能否用有限轨迹可靠地估计每期 CPT 策略梯度，并使在线策略跟踪随之移动的一阶目标？这一问题包含相接的三个环节。首先，在给定期初状态和模拟模型后，需要知道有限样本梯度究竟指向哪个目标，以及估计误差如何随轨迹预算变化。其次，参考点和市场共同推动目标移动时，需要衡量持续更新能否减小当期的一阶残差，而不把固定目标下的收敛误认为移动目标下的跟踪。最后，若动态参考点确实承载投资经历的信息，它在组合决策和投资者实际卖出行为中应当留下可以观察的差别。

为回答这一问题，本文建立动态参考点下的 CPT 投资组合模型，并提出相应的在线策略梯度方法 DRCPT-PG。策略用资产因子决定 Dirichlet 分布的浓度，从中随机生成现金与股票的组合。每期开始时，多条模拟路径与真实账户共享同一个已知状态；此后参考点沿各自的每日财富变化更新，期末财富相对期末参考点的结果进入 CPT 评价。这样，策略参数影响的不仅是当期投资权重，也通过财富路径影响未来的评价基准。

统计分析先固定一期目标。正则化 CPT 的得分梯度恒等式说明如何把轨迹在结果分布中的位置与策略得分结合；中心化留一估计和随机层级修正则使有

限轨迹下的梯度输出严格无偏，同时具有有限方差和有限期望轨迹成本。本文进一步给出其渐近正态性，以及固定维度下最优的轨迹预算速率。跨期分析转向不断移动的目标：归一化投影更新的残差界分别计入目标变化、轨迹估计误差和模拟模型误差；近期残差经时间平滑后得到动态局部遗憾界。在附加的局部误差界条件下，残差还控制参数到当期驻点集合的距离。

实验先在受控市场中检验这些环节：相同期末财富能否因路径不同而改变配置选择；有限轨迹给出的梯度有多准；目标连续移动时，更新策略是否比冻结参数更接近当期一阶条件。参考点适应速度、时期长度和更新尺度随后分别变化，以观察跟踪结果如何改变。再把方法放入时间顺序的沪深 300 回放，看收益、风险和交易成本；用真实持股决策比较三种参考点对减持行为的样本外解释力；最后在历史行为校准的模拟投资者中，分别观察推荐是否被采纳及采纳后的模型评价。图 1-1 概括了这些问题之间的关系。




图 1-1 本文研究框架

第四节 论文结构

第二章给出问题设定与假设，第三章介绍梯度估计和在线更新，第四章证明估计性质及跟踪界。第五章通过七项实验连接可控机制、A 股回放与投资者行为，第六章讨论主要发现；相关证明收于附录。

第二章 问题设定与假设

固定参考点的投资模型中，一次调仓后的财富变化只改变账户余额；这里，财富变化还会改变下一次判断盈亏的基准。市场收益、账户财富和参考点沿同一条交易路径相互作用，使策略每期面对的 CPT 目标随之变化。下文从日常调仓和参考点递推入手，定义条件目标与随机策略，最后以投影残差衡量跨期跟踪。

第一节 非平稳有限时域投资过程

将投资过程划分为 K 个时期，记为 $k = 1, \dots, K$ 。每期从 t_k 开始，包含固定的 $h \geq 1$ 个决策日，相邻时期满足 $t_{k+1} = t_k + h$ 。在日历时点 $u \in \{t_k, \dots, t_k + h - 1\}$ ，状态与组合权重分别为

$$s_u = (m_u, X_u, r_u, \omega_{u-1}), \quad \omega_u \in \Delta_N := \left\{ \omega \in \mathbb{R}_+^{N+1} : \sum_{i=0}^N \omega_i = 1 \right\}, \quad (2-1)$$

其中 m_u 是已观测的市场状态，资产 0 为现金， $X_u > 0$ 为以初始账户价值归一化的财富， $r_u \geq 0$ 为同一单位下的参考财富。设收益向量为 R_{u+1} ，现金收益 $R_{0,u+1} = 0$ ，比例交易成本系数为 $c_{tc} \geq 0$ ，则

$$X_{u+1} = X_u (1 + \omega_u^\top R_{u+1} - c_{tc} \|\omega_u - \omega_{u-1}\|_1), \quad X_1 = 1. \quad (2-2)$$

给定当前状态与执行动作后的市场转移规律可以随日历时间变化。因此，非平稳性既可能发生在不同时期之间，也可能出现在一个时期内部。策略梯度所需的参数依赖结构由后文假设 2.2 规定，并不要求时期内部市场平稳。

第二节 动态参考点与终端相对结果

令 $\eta_+, \eta_- \in [0, 1)$ ，参考点按照当日财富相对于此前参考点的位置更新：

$$r_{u+1} = \Phi(r_u, X_{u+1}) = \begin{cases} (1 - \eta_+)r_u + \eta_+ X_{u+1}, & X_{u+1} \geq r_u, \\ (1 - \eta_-)r_u + \eta_- X_{u+1}, & X_{u+1} < r_u. \end{cases} \quad (2-3)$$

两种适应速度可以不同。例如，若财富上升后的参考点上调较快，先涨后跌的路径即使最终回到同一财富水平，也可能被评价为损失。设 $\mathcal{F}_k$ 表示第 k 期开始时可用的信息，并记

$$r_k := r_{t_k}, \quad z_k := (m_{t_k}, X_{t_k}, \omega_{t_k-1}). \quad (2-4)$$

这里 r_k 专指时期起点的参考点， r_u 则表示时期内部随日更新的参考点。第 k 期的蒙特卡洛学习轨迹均以冻结的 $(\mathcal{F}_k, z_k, r_k)$ 为共同起点，但每条轨迹沿自身的财富路径递推参考点。轨迹 τ 的终端相对结果为

$$Y_k(\tau) = X_{t_k+h}(\tau) - r_{t_k+h}(\tau). \quad (2-5)$$

由此，同一时期的多条候选轨迹可以落入不同的盈利或亏损区域。

第三节 Dirichlet 投资组合策略

资产 $i = 0, \dots, N$ 在时点 u 的因子特征为 $q_{i,u} \in \mathbb{R}^d$ ，由当前市场信息和状态 s_u 中的前期持仓构造。给定参数 $\theta \in \Theta \subset \mathbb{R}^d$ ，策略先随机产生潜在组合：

$$a_{i,u}(\theta) = \exp(\theta^\top q_{i,u}), \quad \tilde{\omega}_u \sim \pi_\theta(\cdot \mid s_u) = \text{Dirichlet}(a_{0,u}(\theta), \dots, a_{N,u}(\theta)). \quad (2-6)$$

参数 θ 决定各因子的配置作用，因子值因股票而异，因此同一参数可以形成不同的资产浓度。设 $\mathbf{M}_u(\cdot \mid s_u) : \Delta_N \rightarrow \Delta_N$ 为依赖已观测历史的可行性映射， $\chi \in (0, 1]$ 为固定交易比例。实际执行的组合为

$$\omega_u = (1 - \chi)\omega_{u-1} + \chi \mathbf{M}_u(\tilde{\omega}_u \mid s_u). \quad (2-7)$$

真实账户路径和学习轨迹均按式 (2-6) 随机抽取组合，再经式 (2-7) 执行。增广轨迹保留潜在组合 $\tilde{\omega}_u$ ，其得分函数为

$$G_{k,\theta}(\tau) = \sum_{u=t_k}^{t_k+h-1} \sum_{i=0}^N a_{i,u} q_{i,u} \left\{ \log \tilde{\omega}_{i,u} - \psi(a_{i,u}) + \psi\left(\sum_{j=0}^N a_{j,u}\right) \right\}, \quad (2-8)$$

其中 ψ 是 digamma 函数。得分记录了整条轨迹对策略参数的似然敏感性，后文将其与轨迹在 CPT 分布中的相对位置结合，得到策略梯度。

第四节 正则化 CPT 目标

对 $x \geq 0$ 定义

$$u_{\alpha, \varepsilon_v}(x) = (x^2 + \varepsilon_v^2)^{\alpha/2} - \varepsilon_v^\alpha, \quad v_+(y) = u_{\alpha_+, \varepsilon_v}(y^+), \quad v_-(y) = \lambda u_{\alpha_-, \varepsilon_v}(y^-), \quad (2-9)$$

其中 $y^+ := \max\{y, 0\}$ 、 $y^- := \max\{-y, 0\}$ ，且 $0 < \alpha_+, \alpha_- \leq 1$ 、 $\lambda > 1$ 、 $\varepsilon_v > 0$ 。正则化的价值函数在零点附近保持平滑，同时保留收益与损失的不对称评价。设 $w_\pm$ 为严格递增的概率权重函数。取固定的 $\varepsilon \in (0, 1/2)$ ，其端点归一化形式为

$$w_\pm^\varepsilon(p) = \frac{w_\pm(\varepsilon + (1 - 2\varepsilon)p) - w_\pm(\varepsilon)}{w_\pm(1 - \varepsilon) - w_\pm(\varepsilon)}, \quad 0 \leq p \leq 1. \quad (2-10)$$

于是 $w_\pm^\varepsilon(0) = 0$ 且 $w_\pm^\varepsilon(1) = 1$ 。

固定一期的环境或模型 P 及起点 (z, r) 后， P_θ 表示策略 π_θ 诱导的增广轨迹分布。记

$$S_{P, z, r, \theta}^\pm(y) = P_\theta\{v_\pm(Y) > y\}.$$

在假设 2.1 规定的分析域内， $v_\pm(Y) \in [0, B_v]$ 。条件 CPT 目标定义为

$$J(P, z, r; \theta) = \int_0^{B_v} w_+^\varepsilon(S_{P, z, r, \theta}^+(y)) dy - \int_0^{B_v} w_-^\varepsilon(S_{P, z, r, \theta}^-(y)) dy. \quad (2-11)$$

设 P_k 为第 k 期真实的条件模型， $\tilde{P}_k$ 为该期冻结的模拟模型。求导前固定起点信息和模型；参数如何进入轨迹分布由假设 2.2 给出。真实目标与模拟目标分别为

$$J_k(\theta, r_k) := J(P_k, z_k, r_k; \theta), \quad \tilde{J}_k(\theta, r_k) := J(\tilde{P}_k, z_k, r_k; \theta), \quad (2-12)$$

对应梯度为

$$g_k(\theta) := \nabla_\theta J_k(\theta, r_k), \quad \tilde{g}_k(\theta) := \nabla_\theta \tilde{J}_k(\theta, r_k). \quad (2-13)$$

第五节 在线近似误差与目标变化

在实际迭代点定义模拟梯度与真实梯度的差异

$$\beta_k := \|\tilde{g}_k(\theta_k) - g_k(\theta_k)\|_2, \quad (2-14)$$

以及真实目标序列的累计变化

$$\mathcal{V}_K := \sum_{k=1}^{K-1} \sup_{\theta \in \Theta} |J_{k+1}(\theta, r_{k+1}) - J_k(\theta, r_k)|. \quad (2-15)$$

β_k 衡量冻结模拟模型的梯度近似误差, $\mathcal{V}_K$ 则衡量真实目标随时间移动的程度。两者来源不同, 在在线界中也分别出现。下述有界条件保证它们在任意有限期内有定义。

第六节 投影残差与动态局部遗憾

给定归一化下界 $\vartheta > 0$ 与步长 $\gamma > 0$, 定义方向映射

$$\mathbf{d}(g) = \frac{g}{\max\{\|g\|_2, \vartheta\}}, \quad (2-16)$$

以及真实梯度对应的投影残差

$$Q_k(\theta) = \frac{\Pi_{\Theta}\{\theta + \gamma \mathbf{d}(g_k(\theta))\} - \theta}{\gamma}. \quad (2-17)$$

其中 Π_{Θ} 表示到 Θ 的欧氏投影。受约束的一阶驻点集合为

$$\mathbf{S}_k = \{\theta \in \Theta : Q_k(\theta) = 0\} = \{\theta \in \Theta : \langle g_k(\theta), \theta' - \theta \rangle \leq 0 \ \forall \theta' \in \Theta\}. \quad (2-18)$$

由于 J_k 在紧凸集 Θ 上连续可微, 每期目标都取得最大值, 且最大值满足式 (2-18) 的一阶条件; Q_k 的连续性进一步保证 $\mathbf{S}_k$ 非空且紧。沿实际迭代路径, 记

$$\zeta_k := \|Q_k(\theta_k)\|_2^2, \quad \mathcal{E}_K := \frac{1}{K} \sum_{k=1}^K \mathbb{E} \zeta_k. \quad (2-19)$$

给定窗口长度 $W \geq 1$ 与折扣系数 $\rho \in (0, 1]$, 定义

$$A_{\rho, W} := \sum_{j=0}^{W-1} \rho^j, \quad \bar{Q}_k := A_{\rho, W}^{-1} \sum_{j=0}^{W-1} \rho^j Q_{k-j}(\theta_{k-j}), \quad (2-20)$$

并约定 $t \leq 0$ 时 $Q_t(\theta_t) = 0$ 。动态局部遗憾为

$$\mathcal{R}_{\rho, W}(K) := \sum_{k=1}^K \|\bar{Q}_k\|_2^2. \quad (2-21)$$

ζ_k 记录当期一阶残差; 动态局部遗憾则先对最近各期的残差向量作时间平滑, 再对平滑向量的平方范数逐期累加。这里不是对各期平方残差先求平均。

第七节 分析假设

以下条件分别约束轨迹的分析域、轨迹似然中的参数来源和 CPT 权重的光滑性。它们使固定目标的梯度估计与跨期的一阶跟踪使用同一组基本量。

假设 2.1 (策略参数与轨迹的共同有界域): 参数集合 $\Theta \subset \mathbb{R}^d$ 非空、紧且凸, 并包含于策略有定义的一个开集中。时期长度 h 和资产数 N 有限。对所有分析中的真实模型 P_k 与冻结模拟模型 $\tilde{P}_k$, 统一有

$$\sup_{i,u} \|q_{i,u}\|_2 < \infty, \quad \sup_u X_u < \infty, \quad \sup_u r_u < \infty, \quad 0 \leq v_{\pm}(Y_k) \leq B_v < \infty. \quad (2-22)$$

参数域、时期长度、资产数量和因子范数由模型设计控制; 财富、参考点与价值函数的上界则指定理论作用的分析域。该条件保证不同期的得分矩、目标值及光滑常数可以统一控制。

假设 2.2 (由策略传递的似然参数依赖): 给定已观测历史与执行动作, 市场转移核和依赖历史的可行性映射 $M_u(\cdot | s_u)$ 不显式依赖 θ 。潜在 *Dirichlet* 提议 $\tilde{\omega}_u$ 保留在增广轨迹中; 当 θ 变化时, 每期的冻结模拟模型保持不变。因此, 条件增广轨迹分布对 θ 的显式依赖仅来自策略密度。

在这一结构下, 市场及交易可行性机制可以通过执行动作和历史受到策略影响, 却不产生额外的显式似然导数, 因而整条轨迹的参数敏感性由式 (2-8) 给出。若转移核本身直接含有策略参数, 则梯度恒等式还须包含相应的似然导数或路径导数。

假设 2.3 (正则化 CPT 权重的光滑性): 式 (2-9)–(2-10) 中的偏好参数固定。归一化权重函数 $w_{\pm}^{\varepsilon}$ 严格递增, 属于 $C^3([0, 1])$, 并满足

$$C_j := \max_{\sigma \in \{+, -\}} \sup_{p \in [0, 1]} |(w_{\sigma}^{\varepsilon})^{(j)}(p)| < \infty, \quad j = 1, 2, 3. \quad (2-23)$$

一阶导数用于 CPT 得分梯度恒等式, 二阶导数控制目标的光滑性, 三阶导数则控制全样本与两个半样本耦合后的余项。附录 附录 1 由此建立统一的有限

得分矩，以及对真实目标和冻结模拟目标均适用的 $B_g, L < \infty$ ，使

$$\sup_{k, \theta \in \Theta} \|g_k(\theta)\|_2 \leq B_g, \quad \|g_k(\theta) - g_k(\theta')\|_2 \leq L\|\theta - \theta'\|_2. \quad (2-24)$$

特别地，任意有限实验中的 β_k 和 $\mathcal{V}_K$ 都是有限的。

第三章 算法设计

每一期的学习从已实现的市场、财富、参考点和持仓出发。在这个共同起点下，模拟模型产生多条候选投资路径，用于估计当期 CPT 目标的梯度；真实账户则沿一条独立的随机策略路径前进，逐日更新财富和参考点。两条路径使用相同的策略分布和交易规则，而参数只在时期结束后更新。

第一节 中心化留一法与随机层修正

固定一期的起点信息、模型和参数，暂时省略时期下标。一条完整轨迹可概括为

$$\mathbf{X}_i = (V_i^+, V_i^-, G_i), \quad V_i^\pm = v_\pm(Y_i). \quad (3-1)$$

其中 V_i^+ 和 V_i^- 分别是该轨迹的收益侧与损失侧价值， G_i 是整条轨迹的得分。对 $\sigma \in \{+, -\}$ ，令 $\varsigma_+ = 1$ 、 $\varsigma_- = -1$ ，并定义留一生存概率

$$I_{i,\sigma}(y) = \mathbf{1}\{V_i^\sigma > y\}, \quad \hat{S}_{-i,n}^\sigma(y) = \frac{1}{n-1} \sum_{j \neq i} I_{j,\sigma}(y). \quad (3-2)$$

第 i 条轨迹的生存事件与用于评价其分位位置的其余 $n-1$ 条轨迹分开，避免自身参与自身的概率估计。中心化留一统计量为

$$U_n^{\text{cen}} = \frac{1}{n} \sum_{i=1}^n G_i \sum_{\sigma \in \{+,-\}} \varsigma_\sigma \int_0^{B_v} (w_\sigma^\varepsilon)' \left(\hat{S}_{-i,n}^\sigma(y) \right) \left\{ I_{i,\sigma}(y) - \hat{S}_{-i,n}^\sigma(y) \right\} dy. \quad (3-3)$$

供层间差分使用的未中心化统计量为

$$U_n^{\text{raw}} = \frac{1}{n} \sum_{i=1}^n G_i \sum_{\sigma \in \{+,-\}} \varsigma_\sigma \int_0^{B_v} (w_\sigma^\varepsilon)' \left(\hat{S}_{-i,n}^\sigma(y) \right) I_{i,\sigma}(y) dy. \quad (3-4)$$

两者期望相同，但随机波动的结构不同。中心化统计量用作低方差基项，未中心化统计量用于构造严格抵消一阶样本影响的全样本与半样本差分。

取 $n \geq 2$ 、激活概率 $p_{\text{act}} \in (0, 1]$ 和指数 $b \in (1, 2)$ ，令

$$\nu_\ell = (1 - 2^{-b})2^{-b(\ell-1)}, \quad \ell = 1, 2, \dots \quad (3-5)$$

在层级 ℓ 上， $n_\ell = n2^\ell$ 条轨迹同时构成一个全样本和两个互不相交的半样本。相

应差分为

$$D_{n,\ell}^{\text{raw}} = U_{n_\ell}^{\text{raw}} - \frac{1}{2} \left(U_{n_{\ell-1}}^{\text{raw},(1)} + U_{n_{\ell-1}}^{\text{raw},(2)} \right). \quad (3-6)$$

设 $A \sim \text{Bernoulli}(p_{\text{act}})$ ；在 $A = 1$ 时，从分布 ν 抽取 ℓ^* 。激活变量和层级均与基项样本及修正样本独立。一次完整的去偏输出为

$$Z_n^{\text{db}} = U_n^{\text{cen}} + \frac{A}{p_{\text{act}} \nu_{\ell^*}} D_{n,\ell^*}^{\text{raw}}, \quad (3-7)$$

其中 $A = 0$ 时第二项定义为零。

算法 3-1: 一次中心化留一随机层去偏 CPT 梯度输出

Require: $(z, r, \tilde{P}, \theta)$, $n \geq 2$, $p_{\text{act}} \in (0, 1]$, $b \in (1, 2)$

- 1: 在冻结的 (z, r, θ) 下独立抽取 $\mathcal{X}_0 \leftarrow \{\mathbf{X}_i\}_{i=1}^n$ ；计算 $U_0 \leftarrow U_n^{\text{cen}}(\mathcal{X}_0)$
 - 2: 抽取 $A \sim \text{Bernoulli}(p_{\text{act}})$
 - 3: **if** $A = 0$ **then**
 - 4: **return** U_0
 - 5: **end if**
 - 6: 抽取 $\ell \sim \nu$ ；从同一冻结模型独立抽取 $\mathcal{X}_\ell \leftarrow \{\mathbf{X}_i\}_{i=1}^{n2^\ell}$ ，且与 $\mathcal{X}_0$ 独立
 - 7: $D \leftarrow U_{n2^\ell}^{\text{raw}}(\mathcal{X}_\ell) - \frac{1}{2} \{U_{n2^{\ell-1}}^{\text{raw}}(\mathcal{X}_\ell^{(1)}) + U_{n2^{\ell-1}}^{\text{raw}}(\mathcal{X}_\ell^{(2)})\}$
 - 8: **return** $Z_n^{\text{db}} = U_0 + D/(p_{\text{act}} \nu_\ell)$
-

以一期五个交易日为例，先从当期账户状态模拟 n 条五日投资路径，形成中心化留一基项；若随机修正被激活，再独立生成抽中层级所需的路径。全样本与两个半样本复用这批新路径，使层间差分反映样本精度变化，而不是不同市场噪声造成的波动。

第二节 在线参数更新

第 k 期从冻结模拟模型独立取得 M_k 次式 (3-7) 的输出，并求平均：

$$\hat{g}_k^{\text{db}} = \frac{1}{M_k} \sum_{m=1}^{M_k} Z_{k,m}^{\text{db}}. \quad (3-8)$$

时期结束后，按归一化方向更新参数：

$$\theta_{k+1} = \Pi_{\Theta} \{ \theta_k + \gamma \mathbf{d}(\hat{g}_k^{\text{db}}) \}. \quad (3-9)$$

算法 3-2: 动态参考点 CPT 策略梯度 (DRCPT-PG)

Require: $\theta_1 \in \Theta$, (X_1, r_1, ω_0) , $h, \chi, \gamma, \vartheta$, (n, p_{act}, b) , $\{M_k\}_{k=1}^K$

- 1: **for** $k = 1, \dots, K$ **do**
 - 2: 根据 $\mathcal{F}_k$ 固定 $(z_k, r_k, \tilde{P}_k)$
 - 3: 由算法 3-1 独立生成 $Z_{k,1}^{\text{db}}, \dots, Z_{k,M_k}^{\text{db}}$
 - 4: $\hat{g}_k^{\text{db}} \leftarrow M_k^{-1} \sum_{m=1}^{M_k} Z_{k,m}^{\text{db}}$
 - 5: **for** $u = t_k, \dots, t_k + h - 1$ **do**
 - 6: $\tilde{\omega}_u \sim \pi_{\theta_k}(\cdot \mid s_u)$
 - 7: $\omega_u \leftarrow (1 - \chi)\omega_{u-1} + \chi \mathbf{M}_u(\tilde{\omega}_u \mid s_u)$
 - 8: $X_{u+1} \leftarrow X_u \{1 + \omega_u^\top R_{u+1} - c_{\text{tc}} \|\omega_u - \omega_{u-1}\|_1\}; r_{u+1} \leftarrow \Phi(r_u, X_{u+1})$
 - 9: **end for**
 - 10: $\theta_{k+1} \leftarrow \Pi_\Theta \{\theta_k + \gamma \mathbf{d}(\hat{g}_k^{\text{db}})\}$
 - 11: **end for**
 - 12: **return** $\{\theta_k, X_{t_k}, r_k, \omega_{t_k-1}\}_{k=1}^{K+1}$
-

仍以五日调仓为例，期初已知的财富、参考点与持仓成为所有模拟轨迹的共同起点。模拟轨迹各自随机配置股票和现金，逐日经历收益、成本及参考点变化，最终汇总成当期梯度估计。实际账户也按同一随机 Dirichlet 策略执行，每天记录新财富和新参考点。五日结束后，算法才依据模拟轨迹提供的梯度方向更新因子参数，并将真实账户的期末状态带入下一期。期内的市场变化由各条轨迹完整承受，参数则始终保持为期初确定的值。

第四章 主要结论

动态参考点改变了策略所优化的目标：即使两条财富路径停在同一终点，先前经历留下的参考点仍可能使 CPT 评价不同。每一期需要从有限轨迹中估计当前目标的梯度；时期继续推进时，策略还必须跟上目标的移动。由路径依赖出发，本章先建立冻结目标下的梯度估计结果，再给出连续更新时的投影残差与动态局部遗憾界。

第一节 参考点的路径依赖

命题 4.1 (相同期末财富与不同的 CPT 价值): 设 $x_{lo} < r_0 < x_f < x_{hi}$, 考虑两条财富路径

$$I : r_0 \rightarrow x_{hi} \rightarrow x_f, \quad II : r_0 \rightarrow x_{lo} \rightarrow x_f.$$

若

$$x_f < (1 - \eta_+)r_0 + \eta_+x_{hi}, \quad x_f > (1 - \eta_-)r_0 + \eta_-x_{lo},$$

则

$$r_I - r_{II} = \eta_+(1 - \eta_-)x_{hi} - \eta_-(1 - \eta_+)x_{lo} + (\eta_- - \eta_+)x_f. \quad (4-1)$$

当右侧不为零时，两条路径虽然具有相同的期末财富 x_f ，其正则化 CPT 价值却不同。

这一命题揭示了终值评价与路径评价的区别：投资者在最终持有同样财富时，先前的上涨或下跌仍会通过参考点留下影响。附录 附录 2 给出直接递推的证明。

命题 4.2 (参考点敏感性): 在假设 2.1–2.3 下，固定 (P, z, θ) 。仅在本命题的比较中，假设策略特征和市场转移核与参考点隔离：若使用共同的策略随机数和市场随机数，将期初参考点从 r 改为 r' 不会改变财富与持仓路径。令

$$\eta_{\min} = \min(\eta_+, \eta_-), \quad L_v = \alpha_+ \varepsilon_v^{\alpha_+ - 1} + \lambda \alpha_- \varepsilon_v^{\alpha_- - 1}. \quad (4-2)$$

沿同一财富路径耦合的两个期初参考点满足

$$|r_{t_k+h}(r) - r_{t_k+h}(r')| \leq (1 - \eta_{\min})^h |r - r'|, \quad (4-3)$$

并且对固定的 (P, z, θ) ,

$$|J(P, z, r; \theta) - J(P, z, r'; \theta)| \leq C_1 L_v (1 - \eta_{\min})^h |r - r'|. \quad (4-4)$$

进一步记

$$\Delta_k^{\text{nr}} := \sup_{\theta \in \Theta} |J(P_{k+1}, z_{k+1}, r_k; \theta) - J(P_k, z_k, r_k; \theta)|,$$

则

$$\sup_{\theta \in \Theta} |J_{k+1}(\theta, r_{k+1}) - J_k(\theta, r_k)| \leq \Delta_k^{\text{nr}} + C_1 L_v (1 - \eta_{\min})^h |r_{k+1} - r_k|. \quad (4-5)$$

式 (4-5) 把跨期目标变化分为参考点以外的状态、市场变化，以及由期初参考点移动带来的部分。后者并非独立施加的外部扰动，而是账户此前投资路径的结果。

第二节 冻结目标的 CPT 梯度与统计估计

定理 4.1 (正则化 CPT 得分梯度恒等式): 在假设 2.1–2.3 下，固定一个目标，并简记 $J = J_k$ 、 $Y = Y_k$ 、 $S_\theta^\pm(y) := S_{P_k, z_k, r_k, \theta}^\pm(y)$ 、 $G_\theta := G_{k, \theta}$ 。定义

$$\begin{aligned} \Psi_\theta(\tau) = & \int_0^{B_v} (w_+^\varepsilon)'(S_\theta^+(y)) \{ \mathbf{1}[v_+(Y(\tau)) > y] - S_\theta^+(y) \} dy \\ & - \int_0^{B_v} (w_-^\varepsilon)'(S_\theta^-(y)) \{ \mathbf{1}[v_-(Y(\tau)) > y] - S_\theta^-(y) \} dy. \end{aligned} \quad (4-6)$$

于是

$$\nabla J(\theta) = \mathbb{E}\{\Psi_\theta(\tau) G_\theta(\tau)\}. \quad (4-7)$$

同一恒等式也适用于冻结模拟模型的目标 $\tilde{J}$ 。

Ψ_θ 根据轨迹结果超过各价值阈值的情况，以及这些阈值在总体中的生存概率，确定该轨迹在 CPT 评价中的权重； G_θ 则说明轨迹出现概率如何随参数改变。两者相乘再取期望，得到目标函数对因子参数的梯度。此后讨论有限样本估计时，固定模型、起点与所查询的参数，记相应冻结目标的梯度为

$$g := \nabla_\theta J(\theta).$$

在线算法使用的冻结模型为 $\tilde{P}_k$ ，因此它在给定第 k 期期初信息后的估计目标是 $\tilde{g}_k(\theta_k)$ 。

若直接把经验生存概率代入非线性的权重导数，有限样本梯度通常带有偏差。附录 附录 3 证明，留一法基项的期望误差为 $O(n^{-1})$ ；全样本与两个半样本共享轨迹后，一阶影响项相互抵消，层间差分的二阶矩降为 $O(n^{-2}4^{-\ell})$ 。算法 3-1 的随机层修正据此把有限精度基项连接到无限精度目标。

定理 4.2 (严格无偏、有限方差与有限期望成本): 令 Z_n^{db} 由式 (3-7) 定义, 其中 $n \geq 2$ 、 $p_{\text{act}} \in (0, 1]$ 、 $1 < b < 2$ 。令 C_U 和 C_{rem} 为引理 6.4 中的有限常数, 记

$$\Xi_b := \sum_{\ell \geq 1} \frac{4^{-\ell}}{\nu_\ell} = \frac{1}{4(1-2^{-b})(1-2^{b-2})}, \quad \Upsilon_b := \sum_{\ell \geq 1} \nu_\ell 2^\ell = \frac{2(1-2^{-b})}{1-2^{1-b}}. \quad (4-8)$$

则

$$\mathbb{E}Z_n^{\text{db}} = g, \quad (4-9)$$

$$\text{tr Cov}(Z_n^{\text{db}}) \leq C_{\text{var}}(n, p_{\text{act}}, b) := \frac{C_U}{n} + \frac{9C_{\text{rem}}\Xi_b}{p_{\text{act}}n^2} < \infty, \quad (4-10)$$

且每次输出使用的完整轨迹数的期望为

$$C_{\text{cost}}(n, p_{\text{act}}, b) = n(1 + p_{\text{act}}\Upsilon_b) < \infty. \quad (4-11)$$

对 M 个独立输出,

$$\hat{g}_{M,n}^{\text{db}} := \frac{1}{M} \sum_{m=1}^M Z_{n,m}^{\text{db}}, \quad \mathbb{E}\|\hat{g}_{M,n}^{\text{db}} - g\|_2^2 \leq \frac{C_{\text{var}}(n, p_{\text{act}}, b)}{M}. \quad (4-12)$$

此处的无偏对象是固定模型和期初状态后的 CPT 梯度。层级分布不截断, 保证随机修正的期望覆盖全部层级; 指数条件 $1 < b < 2$ 同时使期望轨迹成本和输出方差有限。

定理 4.3 (固定目标的渐近正态性): 在定理 4.2 的条件下, 固定 (n, p_{act}, b) , 记 $\Sigma_n = \text{Cov}(Z_n^{\text{db}})$ 。则

$$\sqrt{M}(\hat{g}_{M,n}^{\text{db}} - g) \rightsquigarrow \mathcal{N}(0, \Sigma_n). \quad (4-13)$$

若 Σ_n 非奇异, $\hat{\Sigma}_{M,n}$ 为 M 次输出的经验协方差, 则

$$\sqrt{M}\hat{\Sigma}_{M,n}^{-1/2}(\hat{g}_{M,n}^{\text{db}} - g) \rightsquigarrow \mathcal{N}(0, \text{Id}_d). \quad (4-14)$$

独立重复输出因而能够用于估计固定一期梯度的不确定性。跨期目标即使继续移动，也可以在每一期分别使用这一统计结论。

第三节 固定维度下的极小极大信息率

定义 4.1 (完整轨迹查询实验): 固定维度 d 、 $\theta_0 = 0 \in \text{int}(\Theta)$ 、 h 和 N 的共同有限上界，以及假设 2.1–2.3 中的常数。设模型类 $\mathfrak{C}$ 满足这些界，包含附录 附录 5 构造的伯努利收益子模型，并有 $(w_+^\varepsilon)'(0) > 0$ 。对 $P \in \mathfrak{C}$ ，第 t 次自适应查询 $\theta_t \in \Theta$ 返回一条新的完整增广轨迹

$$\tau_t \mid \mathcal{G}_{t-1} \sim P_{\theta_t}, \quad \mathcal{G}_t := \sigma\{(\theta_j, \tau_j) : j \leq t\}.$$

可行程序选择停止时刻 T_{call} 和关于 $\mathcal{G}_{T_{\text{call}}}$ 可测的估计量 $\hat{g}$ ，满足

$$\sup_{P \in \mathfrak{C}} \mathbb{E}_P T_{\text{call}} \leq B, \quad (4-15)$$

估计目标为 $g_P := \nabla J_P(\theta_0)$ 。

相应的极小极大风险为

$$\mathfrak{R}_B := \inf_{\hat{g}: \sup_{P \in \mathfrak{C}} \mathbb{E}_P T_{\text{call}} \leq B} \sup_{P \in \mathfrak{C}} \mathbb{E}_P \|\hat{g} - g_P\|_2^2. \quad (4-16)$$

定理 4.4 (固定维度下的最优轨迹预算率): 对定义 4.1 的查询实验，存在与 B 无关的常数 $c_{\text{lb}}, C_{\text{ub}}, B_0 \in (0, \infty)$ ，使任意 $B \geq B_0$ 均满足

$$\frac{c_{\text{lb}}}{B} \leq \mathfrak{R}_B \leq \frac{C_{\text{ub}}}{B}. \quad (4-17)$$

在相同期望完整轨迹预算下，独立平均未截断的 Z_n^{db} 输出可以达到该上界的常数倍。因此，当 d 和正则化参数固定时，梯度估计的极小极大速率为 $\Theta(B^{-1})$ 。

第四节 移动 CPT 目标下的一阶跟踪

定理 4.5 (期望平均平方投影残差上界): 设假设 2.1–2.3 成立，且 $\gamma L \leq \vartheta$ 。固定估计器设计 (n, p_{act}, b) ，令 $C_g := \max\{B_g, \vartheta\}$ ， $\hat{g}_k^{\text{db}}$ 由式 (3-8) 给出，目标为 $\tilde{g}_k(\theta_k)$ 。则

$$\mathbb{E} \|\hat{g}_k^{\text{db}} - g_k(\theta_k)\|_2^2 \leq \frac{C_{\text{var}}(n, p_{\text{act}}, b)}{M_k} + \mathbb{E} \beta_k^2, \quad (4-18)$$

并有

$$\mathcal{E}_K \leq \frac{8\{2B_v + \mathbb{E}\mathcal{V}_K\}}{\vartheta\gamma K} + \frac{10C_g}{\vartheta^3 K} \sum_{k=1}^K \left(\frac{C_{\text{var}}(n, p_{\text{act}}, b)}{M_k} + \mathbb{E}\beta_k^2 \right). \quad (4-19)$$

上界中的 $\mathcal{V}_K$ 对应真实目标的移动, M_k^{-1} 对应蒙特卡洛估计误差, β_k^2 对应冻结模拟模型与真实模型之间的梯度差异。控制的是每一期当下的一阶条件, 而不是要求所有时期共享同一个最优参数。

推论 4.1 (动态局部遗憾): 任取固定窗口长度 $W \geq 1$ 、折扣系数 $\rho \in (0, 1]$ 及总期数 $K \geq 1$, 逐路径有

$$\mathcal{R}_{\rho, W}(K) \leq \sum_{k=1}^K \zeta_k, \quad (4-20)$$

从而

$$\frac{1}{K} \mathbb{E} \mathcal{R}_{\rho, W}(K) \leq \mathcal{E}_K. \quad (4-21)$$

因此, 投影残差界也控制了对近期一阶残差作时间平滑后得到的动态局部遗憾。

投影残差直接衡量受约束的一阶驻点条件。若还满足统一的局部误差界: 存在 $\kappa < \infty$ 使

$$\text{dist}(\theta, \mathcal{S}_k) \leq \kappa \|Q_k(\theta)\|_2, \quad \theta \in \Theta, \quad (4-22)$$

则残差大小进一步给出参数到当期驻点集合的距离。

推论 4.2 (移动驻点集合的跟踪): 若式 (4-22) 成立, 则

$$\frac{1}{K} \sum_{k=1}^K \mathbb{E} \text{dist}^2(\theta_k, \mathcal{S}_k) \leq \kappa^2 \mathcal{E}_K. \quad (4-23)$$

推论 4.3 (平均平方投影残差与动态局部遗憾趋于零): 固定 $W < \infty$ 和 $\rho \in (0, 1]$ 。若

$$\mathbb{E}\mathcal{V}_K = o(K), \quad \frac{1}{K} \sum_{k=1}^K \left(\frac{1}{M_k} + \mathbb{E}\beta_k^2 \right) \rightarrow 0, \quad (4-24)$$

则

$$\mathcal{E}_K \rightarrow 0, \quad K^{-1} \mathbb{E} \mathcal{R}_{\rho, W}(K) \rightarrow 0. \quad (4-25)$$

若式 (4-22) 也成立, 则式 (4-23) 的左侧同样趋于零。

第五章 实验研究

财富路径影响参考点，参考点改变 CPT 评价，而策略更新又会改变下一条财富路径。为了逐步看清这些关系，前四组实验从路径比较出发，依次考察有限样本梯度、连续在线跟踪和参考点机制的作用；后三组实验转向真实 A 股价格、投资者持股决策及持续推荐。可控环境便于区分各环节的影响，真实数据则呈现组合表现与行为解释上的结果。七组实验的关系见图 5-1。



图 5-1 七组实验之间的证据关系。

第一节 E1：路径依赖与投资组合选择

为观察参考点如何把投资经历带入下一次选择，考虑两条初始财富和最终财富相同的路径：

$$(1, 1.10, 1.015) \quad \text{与} \quad (1, 0.90, 1.015).$$

参考点按式 (2-3) 逐期更新，取 $(\eta_+, \eta_-) = (0.20, 0.05)$ 。到决策时，两位投资者的财富都为 $X_T = 1.015$ ，调仓前均持有 50% 现金和 50% 风险资产。下一期风

险资产以概率 p 上涨 4%，否则下跌 4%。可选的目标风险权重为 20% 和 80%；经过式 (2-7) 的动作惯性，实际执行权重分别为 44% 和 56%。下一期只有两种收益状态，故两种配置的 CPT 价值均可精确计算。

图 5-2A 先画出两条财富路径及参考点的变化，B 对照动态、对称动态和静态参考点下的期末盈亏位置；C、D 则分别沿两条路径改变上涨概率，比较两种可执行配置的 CPT 价值。




图 5-2 财富路径、参考点与投资组合选择

表 5-1 E1 在 $p = 0.7$ 时的精确机制结果。

财富路径	X_T	r_T	$X_T - r_T$	优选风险资产权重	CPT 区间
先涨后跌	1.015	1.01975	-0.00475	44%	损失
先跌后涨	1.015	0.99900	+0.01600	56%	收益

两条路径最终都到达 1.015，但先涨后跌的账户留下较高参考点， $X_T - r_T = -0.00475$ ；先跌后涨的账户则处于参考点之上， $X_T - r_T = 0.016$ 。因此，面对

相同的 $\{+4\%, -4\%\}$ 下一期收益，前者主要从损失一侧评价风险，后者则从收益一侧评价。上涨概率取 $p = 0.7$ 时，前者选择 44% 风险资产，后者选择 56% (图 5-2)。财富、持仓和可选配置均已配平，排序的反转来自历史路径留下的参考点差异，与命题 4.1 所揭示的机制一致。

第二节 E2：有限样本梯度估计

单凭真实价格路径，难以知道梯度估计误差究竟来自方法本身，还是来自不断变化的市场。从 E2 开始，实验采用 30 只股票加现金的半合成市场：各股因子来自固定的 A 股经验因子块库，收益规律则按预设路径变化。股票之间仍有真实因子差异，而市场何时突变、何时缓变可以明确控制。时期 k 内，风险资产 i 在第 u 日的收益为

$$R_{i,k,u} = 0.08 \tanh \left(\frac{\mu_k^{\text{ret}} + 2.5 (\phi_k^{\text{ret}})^\top f_{i,u} + \xi_{k,u}^{\text{com}} + \xi_{i,k,u}^{\text{id}}}{0.08} \right),$$

其中 $f_{i,u}$ 是资产 i 的因子向量， ϕ_k^{ret} 与其维度相同；共同冲击和个股冲击的标准差分别为 $0.006\sigma_k^{\text{ret}}$ 与 $0.009\sigma_k^{\text{ret}}$ ， $(\mu_k^{\text{ret}}, \phi_k^{\text{ret}}, \sigma_k^{\text{ret}})$ 控制当期的收益规律。市场先在第 1–40 期保持动量规律，第 41–60 期转向反转，第 61–120 期逐渐过渡到低波动、价值和质量占优的状态；此后外生收益规律不再改变。这样，四个取样时期分别落在稳定、突变后、缓变中和缓变后的市场状态。

E2 把账户条件统一为

$$(X, r, \omega, \theta) = (1, 1, e_{\text{cash}}, 0), \quad e_{\text{cash}} := (1, 0, \dots, 0),$$

并在第 20、50、90 和 150 期分别冻结一个目标，对应稳定、突变后、缓变中和缓变后的市场状态。E3 沿用同一因子分布和时期收益规律，但让账户状态在各期之间连续演化。

我们比较本文采用的中心化留一估计器（带独立原始随机修正）与改编自 CPT-PG v5 的原始独立分割 plug-in 估计器。两者估计的都是式 (2-9) 中的平方平滑 CPT 目标。预期完整轨迹预算取

$$B \in \{32, 64, 128, 256, 512, 1024, 2048\},$$

两种方法在每一预算下匹配轨迹成本，数值梯度参照值由独立且成本高得多的模拟产生。

图 5-3A 比较固定目标上的坐标偏差，B 考察独立估计量取平均后的协方差迹，C 在 $M = 64$ 时检查标准化统计量的正态分位数，D 比较不同因子维度下全梯度 MSE 随预算的变化。B、D 中的虚线均表示斜率为 -1 的参照线。




图 5-3 半合成环境中的有限样本梯度估计

表 5-2 四个固定目标在预期轨迹预算 $B = 512$ 时的全梯度均方误差。MSE 数值单位为 10^{-6} ；末列为 $\text{MSE}_{\text{prop}} - \text{MSE}_{\text{v5}}$ 的配对 95% bootstrap 区间，单位相同。

市场状态	本文估计器	CPT-PG v5	比值	差值的 95% CI
稳定期	3.123	2.938	1.063	$[-0.055, 0.434]$
突变后	10.134	10.809	0.938	$[-1.495, 0.139]$
缓变中	10.647	11.468	0.928	$[-1.739, 0.102]$
缓变后	10.589	12.257	0.864	$[-2.599, -0.721]$

有限预算下，两种估计器首先在偏差上拉开距离。本文估计量的各坐标均

值靠近独立数值参照值，CPT-PG v5 的 plug-in 估计量在低预算时则出现偏移（图 5-3A）。原因在于 plug-in 方法把经验生存概率直接送入非线性权重导数；留一中心化和独立随机修正则使这一有限样本偏移在期望上得到消除。

无偏并不意味着只用少量轨迹就能得到精确方向，因而还须看预算增加后的波动。独立完整估计量取平均时，两种方法协方差迹的拟合斜率分别为 -0.989 和 -0.999 ；本文方法在 $d = 2, 4, 8, 10$ 时，全梯度 MSE 的预算斜率介于 -1.17 与 -1.12 之间（图 5-3B、D），与定理 4.4 的逆预算率相吻合。固定 $M = 64$ 时，本文方法的标准化统计量均值为 -0.049 、标准差为 0.993 ，95% 区间覆盖率为 96.25%；CPT-PG v5 的均值为 0.556 ，覆盖率为 91.75%（图 5-3C）。前一组数字说明估计波动如何随预算下降，后一组数字则反映有限样本偏移对区间推断的影响。

MSE 比较还取决于所处的市场状态。预算 $B = 512$ 时，四个目标中有三个的 MSE 点估计较低；缓变结束后的降幅为 13.6%，配对区间全部在零以下，稳定期的点估计却略高且区间跨过零（表 5-2）。四个目标共同支持的是有限样本偏移得到修正、误差随预算增大以约 $1/B$ 的速度下降；在某一固定预算下，哪种方法的 MSE 更低还取决于目标状态。

第三节 E3：连续缓变环境中的在线跟踪

固定目标上的梯度估计只是策略更新的第一步。市场从动量转向反转、再逐渐改变因子偏好时，在线策略还需要沿着自己的账户路径继续运行。记第 k 期结束、跨期缓变处理之前的原始账户状态为 $(X_k^{\text{raw}}, r_k^{\text{raw}}, \omega_k^{\text{raw}})$ 。下一期从以下状态出发：

$$\begin{aligned}\log X_{t_{k+1}} &= (1 - \varpi_k) \log X_{t_k} + \varpi_k \log X_k^{\text{raw}}, \\ r_{k+1} &= (1 - \varpi_k) r_k + \varpi_k r_k^{\text{raw}}, \\ \omega_{t_{k+1}-1} &= (1 - \varpi_k) \omega_{t_k-1} + \varpi_k \omega_k^{\text{raw}}, \quad \varpi_k = k^{-3/4}.\end{aligned}$$

期内参考点仍按式 (2-3) 非对称更新, $(\eta_+, \eta_-) = (0.20, 0.05)$ 。在假设 2.1 的共同有界域和有界半合成收益下, 期初状态变化量为 $O(\varpi_k)$, 且

$$\sum_{k \leq K} \varpi_k = O(K^{1/4}) = o(K).$$

因子块分布保持不变, 外生收益系数沿 E2 的阶段路径变化至第 120 期, 此后固定。跨期混合使账户承接上一期的经历, 同时使后期状态每次移动的幅度逐渐缩小; 期内的每日财富和参考点仍由实际交易路径决定。若冻结目标在所考察紧域内对期初账户变量和收益系数一致 Lipschitz 连续, 附录 附录 4 中的推导把这种状态变化转为 $\mathcal{V}_K = O(K^{1/4})$ 的目标变化预算。

实验使用 20 条独立测试轨迹。在线学习者与冻结对照在前 40 期共享完整路径; 此后前者继续运行算法 3-2, 后者固定 θ , 但仍按相同缓变规则推进各自的财富、参考点和持仓。测试前设定 $(\gamma, \vartheta) = (0.08, 0.05)$, 每期估计量独立重复 $M_k = \max\{4, \lceil \sqrt{k} \rceil\}$ 次。因此 $M_k \geq \sqrt{k}$, 且 $K^{-1} \sum_{k=1}^K M_k^{-1} \leq (2\sqrt{K} - 1)/K = O(K^{-1/2})$ 。动态局部遗憾按式 (2-21) 计算, 取 $W = 5$ 、 $\rho = 0.9$ 。为避免将评估梯度的抽样波动直接计入平方残差, 图中使用两条独立梯度流的交叉乘积, 分别评价当期投影残差和经式 (2-20) 平滑后的残差; 相应误差界见式 (6-29) 和 (6-30)。

图 5-4A、B 依次给出平方投影残差的累计值和时期平均值, C、D 以同样方式给出动态局部遗憾。竖直点线标出市场突变、缓变开始及外生收益规律固定的时点; 曲线是 20 条测试轨迹的均值, 阴影为 1.96 倍标准误。

前 40 期, 两组账户走过同一条路径; 参数冻结后, 持续更新组与对照组的残差逐渐分开 (图 5-4)。第 41 期至第 300 期, 持续更新组的动态局部遗憾累计为 0.687, 约为冻结对照 1.369 的一半; 直接累计平方投影残差也得到相近的差距 (0.684 对 1.427)。两项差值按种子配对的 95% bootstrap 区间分别为 $[-0.738, -0.622]$ 和 $[-0.834, -0.650]$ 。到第 300 期, 两组平均动态局部遗憾分别为 2.411×10^{-3} 和 4.685×10^{-3} 。冻结策略仍继续持仓、经历市场并更新参考点, 因此差距反映的是持续修正参数能否更好地跟上各自当期的 CPT 目标。

第 121 期以后, 外生收益规律已经固定, 目标的继续移动主要来自缓变的




图 5-4 缓变环境中的连续在线跟踪

账户状态。在第 121–300 期，累积动态局部遗憾的经验双对数斜率，持续更新为 0.704，冻结对照为 0.968；平方投影残差的斜率分别为 0.745 和 0.959。持续更新曲线在这一有限区间内呈现低于线性的积累趋势，与推论 4.1 和 4.3 描述的渐近方向一致。在式 (4-22) 的局部几何条件下，残差控制还能按推论 4.2 转化为到当期驻点集合的平均平方距离控制。市场不再改变收益规律之后，账户仍记着此前的交易经历；持续修正参数因而仍比停留在第 40 期的策略更贴近当期目标。

第四节 E4：参考点机制消融与在线跟踪稳健性

持续更新在 E3 的默认配置下优于冻结策略，但这一差距可能随参考点适应速度、每期长度和参数更新尺度改变。参考点若保持不变，持续学习还是否有用？收益后与损失后采用不同的适应速度，又会把差距推向哪一边？为使不同配置的比较不受目标尺度影响，对配置 c 和配对种子 s ，计算突变后在线策略与冻结策略的动态局部遗憾比值

$$\text{Ratio}_{\text{DLR}}(c, s) = \frac{\text{DLR}_{\text{online}}^{\text{post}}(c, s)}{\text{DLR}_{\text{frozen}}^{\text{post}}(c, s)}.$$

先在每个种子内求比值，再计算其平均值和配对 bootstrap 区间。比值小于一，表示该配置下持续更新比冻结参数积累更少的动态局部遗憾。

首先在完整的 9×9 参考点网格中改变收益和损失后的适应速度：

$$\eta_+, \eta_- \in \{0, 0.05, 0.10, \dots, 0.40\}.$$

随后将时期长度设为

$$h \in \{1, 5, 10, 15, 20, 25, 30, 35, 40, 45, 50\};$$

市场阶段仍按第 200、300、600、1500 个交易日界定；当边界落在一个时期内部时，归入最近的完整时期，跨期状态增益则按已经经过的交易日计算。最后考察更新步长与归一化下界，从

$$\gamma \in \{0.01, 0.02, 0.03, 0.04, 0.05, 0.06, 0.08, 0.10, 0.12\},$$

$$\vartheta \in \{0.005, 0.01, 0.015, 0.02, 0.03, 0.04, 0.05, 0.06\}, \quad 0.31 \gamma \leq \vartheta$$

中筛出 48 组配置；这里的 0.31 为网格筛选系数。每组配置运行四条独立配对轨迹和两条独立评估流。

图 5-5A 是 9×9 参考点网格：原点对应无适应，对角线对应收益和损失后的对称适应，非对角区域体现两个方向的不同适应速度。B 比较不同时期长度的配对区间，C 比较筛选后的更新参数；C 中的空白格不属于筛选区域。黑色等值线或横线表示比值为 1，星号与竖线标出 E3 的默认值 $(\eta_+, \eta_-) = (0.20, 0.05)$ 、 $h = 5$ 和 $(\gamma, \vartheta) = (0.08, 0.05)$ 。




图 5-5 参考点机制消融及在线跟踪优势的稳健性

即使参考点完全不适应， $(\eta_+, \eta_-) = (0, 0)$ 时的比值仍为 0.716；八组正的对

称适应配置也全部低于一，平均为 0.715，其中六组的配对 95% 区间完全低于一（图 5-5A）。可见，持续更新本身已经能够改善移动市场中的一阶跟踪，非对称适应改变的是改善的幅度。

收益后的适应较快时，这一幅度更大。36 组 $\eta_+ > \eta_-$ 配置的平均比值为 0.511，全部点估计低于一，33 组区间完全低于一。相反， $\eta_+ < \eta_-$ 区域的平均比值为 0.826；在 $(\eta_+, \eta_-) = (0.05, 0.40)$ 时，比值升至 1.403，区间为 $[1.224, 1.552]$ 。同一市场路径中，参考点向收益适应更快会放大在线更新的优势，方向倒置且损失后适应很快时，这种优势甚至可能消失。

时期长度改变后，全部 11 个长度的平均比值仍低于一，其中 10 个配对区间完全低于一，只有 $h = 50$ 的区间跨过一（图 5-5B）。在筛出的 48 组 (γ, ϑ) 中，47 组点估计低于一、45 组区间完全低于一；唯一高于一点估计对应区间为 $[0.876, 1.342]$ （图 5-5C）。因而，E3 中看到的跟踪差距并不只出现在一个时期长度或一组更新参数上；对差距大小影响更明显的是参考点在收益与损失后的适应方向。

第五节 E5：真实市场投资组合评价

半合成市场能够指定何时突变，也能控制因子与收益的关系；真实市场不会按预设的规律切换。转入 A 股回放后，比较的重点因此从一阶残差变为实际价格路径上的收益、风险与调仓代价。资产池在测试期之前固定为沪深 300 的 300 只成分股，历史输入从 2023 年 1 月 3 日开始，样本外执行期为 2025 年 1 月 2 日至 2026 年 5 月 29 日。动量、反转、波动、估值、流动性、规模与前期持仓仅使用执行日前可获得的信息；质量因子要等财务数据公告后才进入策略。训练与实际账户执行均从同一个随机 Dirichlet 策略采样，每次调仓从财富中扣除 $0.001\|\omega_t - \omega_{t-1}\|_1$ 的交易成本。

比较对象为 DRCPT-PG、Symmetric CPT-PG、Static CPT-PG、Expected-Wealth PG 与 Exponential-Utility PG。五种方法共用五日时域、 $\gamma = 0.08$ 、预期轨迹预算 512 和预先设定的十个策略种子；DRCPT-PG 的参考点参数为 $(\eta_+, \eta_-) =$

(0.20, 0.05)。评价同时观察财富、年化收益与波动、Sharpe 比率、最大回撤、换手和累计交易成本。

图 5-6A 展示十个种子的财富中位数及其离散带，B 沿市场阶段观察回撤和恢复过程；C 将期末财富与最大回撤对应，气泡面积反映换手；D 比较平均换手和累计交易成本。这些视角分别衡量持有结果、下行风险与调仓代价。




图 5-6 A 股时间顺序回放中的财富、回撤与交易成本

表 5-3 E5 真实市场结果，表中数值为十个策略种子的均值。

方法	年化收益 (%)	年化波动 (%)	Sharpe	最大回撤 (%)	总换手	交易成本 (%)
DRCPT-PG	13.03	15.62	0.856	11.67	10.87	2.42
Symmetric CPT-PG	13.21	16.35	0.796	12.48	12.41	2.78
Static CPT-PG	14.69	17.74	0.789	14.36	14.09	3.21
Expected-Wealth PG	10.51	16.68	0.606	14.23	11.63	2.56
Exponential-Utility PG	14.79	17.42	0.773	13.95	12.92	2.92

真实回放没有显示 DRCPT-PG 在平均收益上领先：它与直接的机制对照 Symmetric CPT-PG 的年化收益分别为 13.03% 和 13.21%。差别主要在取得这份收益的过程。DRCPT-PG 的平均 Sharpe 比率为 0.856，在五种方法中最高；

最大回撤为 11.67%，总换手与交易成本也最低（表 5-3）。相较对称参考点，它以较低的波动、回撤和调仓代价获得了接近的收益。图 5-6 中的回撤路径和换手比较与这一结果一致：参考点机制在真实市场上更多改变了风险暴露与交易强度，而不是显著拉开期末财富。

第六节 E6：投资者行为预测

一个投资组合策略是否按动态参考点学习，与真实投资者是否也以变化的参考点判断持股，是两个不同的问题。为考察后者，取 306,444 次真实持股调仓机会，其中时间顺序测试集包含 71,854 次，以投资者下次调仓是否降低该股目标权重为因变量。四个 logistic 模型面对同一批决策，使用同样的标签、控制变量和时间划分；它们依次不使用参考点，或采用静态买入成本、对称动态、非对称动态参考点。最后一种取 $(\eta_+, \eta_-) = (0.40, 0.10)$ 。模型共同控制持有时间、前期权重、价格、投资者既往减持倾向，以及滞后的市场、组合和社交媒体汇总信息。配对不确定性由 200 次按投资者聚类的 bootstrap 估计。

对同一批真实决策，盈利与亏损状态分别按各模型的参考点划分。除样本外预测误差外，还观察股票价格高于自身参考点时的实际减持率、低于参考点时的减持率及两者之差。这使“能否预测减持”与“怎样识别盈利易卖、亏损易持”成为两个分别可以比较的问题。

图 5-7A 报告三种参考点相对无参考点模型在 log loss 和 Brier score 上的样本外改善；B 给出各自盈亏划分下观察到的减持率，C 比较两种状态的减持率之差，D 再按投资者测试期以前的交易历史检查预测改善。A 至 C 的区间均来自按投资者聚类的配对 bootstrap。

在 71,854 次样本外决策上，模型能否知道股票相对于投资者参考点处于盈利还是亏损，比参考点如何适应更能影响预测。无参考点模型的 log loss 为 0.60420，加入静态买入成本参考点后降至 0.58109；对称动态和非对称动态参考点分别进一步降至 0.57975 与 0.57937（图 5-7A）。非对称模型相对无参考点模型的配对差值为 -0.02488 ，95% bootstrap 区间为 $[-0.02866, -0.02142]$ ，其他




图 5-7 参考点与投资者减持行为的样本外比较

预测指标也沿同一方向变化。

在已经考虑盈亏状态之后，参考点的更新方式仍有增量作用，但幅度小得多。非对称动态参考点相对静态参考点的 log loss 低 0.00174，相对对称动态参考点低 0.000391；后一个差值的配对区间为 $[-0.000695, -0.000014]$ 。因此，样本外证据首先支持参考依赖的盈亏划分，其次才支持收益和损失后采用不同适应速度带来的额外预测信息。

预测误差之外，实际减持率也呈现一致的行为图景：不论采用哪种参考点，处于盈利状态的股票都比亏损股票更容易被减持。盈利与亏损减持率之差在静态、对称动态和非对称动态划分下依次为 0.2214、0.2250 和 0.2274；非对称划分相对对称划分多 0.00255，配对区间为 $[0.00107, 0.00404]$ （图 5-7B、C）。按投资者先前的交易历史分成六组后，非对称模型在每组的 log loss 改善也最大（图 5-7D）。参考点适应的贡献虽小，但在预测减持与识别处置效应两个角度上方向一致。

第七节 E7：异质投资者模拟交互

真实持股决策表明，不同参考点对一次减持行为的解释力不同。若投资者反复收到组合建议，接受建议之后的评价又会怎样变化？这里沿用真实市场回放生成的建议，依据 3,481 名真实用户训练期的盈亏减持、交易活跃度、持仓分散程度、情绪及社交网络汇总信息，形成四类模拟投资者。中等交易频率且持仓集中的投资者占 49.4%，具有处置效应的投资者占 28.7%，活跃且分散投资者占 19.4%，低频且分散投资者占 2.5%。每类选取 16 名用户校准模拟规则，共有 64 名模拟投资者；分类只依据训练期行为，不以 E6 行为预测模型的全局系数决定类型。

五种策略梯度方法均提供现金加 300 只股票的组合建议。每个五日时期开始时，模拟投资者依据当前建议、由历史行为校准的偏好、建议与自身特征的匹配程度，以及此前的模型评价，决定是否采纳；这一决定发生在当期收益公布之前。采纳后执行建议五日，拒绝后维持原组合，两种路径都扣除交易成本并独立更新参考点。采纳后的条件满意度取该五日归一化前景价值与“不调仓”反事实之间的模型评价差；交互价值是采纳指示乘以这一差值，拒绝时为零。方法间使用配对的市场路径与采纳随机数，并按真实类型占比加权汇总。

图 5-8A 给出四类模拟投资者的标准化行为特征，B 和 C 分别比较不同类型对各方法的采纳率与采纳后的五日模型评价。D 把各方法的采纳率和模型评价放在同一平面，气泡面积表示平均推荐匹配程度。这里的“满意度”始终是相对维持原持仓的模型前景价值差，不代表投资者报告的主观感受。

五种方法的加权模拟采纳率都接近四分之三，落在 0.735 至 0.745 之间；单看采纳意愿，难以判断建议执行后是否比维持原持仓更合适（图 5-8）。Expected-Wealth PG 的采纳率略高，为 0.745，采纳后的模型评价却低于 DRCPT-PG。后者的采纳率为 0.741，五日条件满意度为 -3.087×10^{-4} ，采纳加权交互价值为 -2.265×10^{-4} ，后二者在五种方法中最接近零。换言之，模拟投资者接受建议的频率相近，但 DRCPT-PG 执行后相对原持仓的负向前景评价较小；图 5-8D




图 5-8 异质投资者的持续模拟交互

将这两个维度放在一起比较。

在活跃分散、处置效应、低频分散以及中等频率集中持仓的四类模拟投资者中，DRCPT-PG 的采纳加权交互价值均为最高，其平均换手 9.29 和累计成本 0.0208 也是五种方法中最低的。五种方法相对“不调仓”的模型满意度均为负值；在这一共同评价尺度上，DRCPT-PG 的负向差距最小。真实持股决策中的减持差异与模拟交互中的采纳后评价，分别从行为识别和连续推荐两个角度呈现了动态参考点的作用。

第六章 讨论与结论

两条财富路径到达同一终点后，参考点仍可能不同；投资者下一期面对的也就不是同一个 CPT 目标。在财富、持仓和可选投资机会相同的条件下，本文的路径比较确实得到不同的风险资产配置。由此，参考点既记录已发生的投资经历，也参与决定下一期策略所优化的目标。针对每一期给定状态后的目标，本文构造严格无偏且方差有限的梯度估计量；当市场与账户状态推动目标继续移动时，策略再依据估计梯度更新，并用投影残差和动态局部遗憾衡量它能否跟上当期的一阶条件。

固定参考点的 CPT 强化学习已经研究了非线性概率加权下的策略梯度优化^[3,4]；行为金融研究则表明，已实现的收益与损失会改变投资者评价后续结果的基准^[5-7,11]。本文把随账户路径更新的参考点纳入连续策略学习，使这两条研究线索作用于同一个投资过程。有限轨迹预算下的梯度估计为逐期更新提供了一阶信息；在缓变市场中，持续更新比冻结参数积累更少的跟踪误差。参考点适应消融还显示，即使参考点保持静止，在线更新仍然有效，而收益主导的非对称适应可以进一步增强这种优势。参考点影响目标的移动方式，参数更新则决定策略如何响应这种移动。

按时间顺序进行的 A 股回放将比较从一阶跟踪延伸到真实价格路径上的投资后果。DRCPT-PG 与对称参考点方法的平均收益接近，但平均 Sharpe 比率较高，最大回撤、换手和交易成本较低；收益相近时，参考点机制的差异更多表现在持仓风险和调仓强度上。真实投资者的持股决策又提供了行为方面的证据：在相同样本、控制变量和测试时段下，非对称动态参考点提高了样本外减持预测能力，按这一参考点划分的盈亏状态也更贴近实际减持差异。这些差别来自对已观察行为的解释与预测，不涉及参考点对卖出行为的因果识别。以历史行为校准的模拟投资者中，各方法的采纳率相近，采纳后相对“不调仓”的模型前景价值却有所不同。投资者在期初愿意接受一份建议，与五日之后如何评价它，

是两个相继发生但不等同的问题。

现有跟踪结果建立在目标缓慢变化的市场路径上。面对突发且持续的冲击，目标变化与可用轨迹预算都可能更快增加；如何在这种情况下控制一阶跟踪误差，是下一步需要解决的问题。模拟交互中的投资者类型来自历史行为校准，条件满意度则是模型计算的五日前景价值差值。若要进一步研究投资者的真实感受，需要在持续交互中同时观察参考点变化、推荐采纳、实际投资结果和主观评价。本文说明了历史经历如何进入可估计、可跟踪的投资组合目标；把这一目标与可直接观察的人类体验连接起来，仍需相应的行为数据。

参考文献

- [1] KAHNEMAN D, TVERSKY A. Prospect theory: An analysis of decision under risk [J/OL]. *Econometrica*, 1979, 47(2): 263-291. DOI: [10.2307/1914185](https://doi.org/10.2307/1914185).
- [2] TVERSKY A, KAHNEMAN D. Advances in prospect theory: Cumulative representation of uncertainty[J/OL]. *Journal of Risk and Uncertainty*, 1992, 5(4): 297-323. DOI: [10.1007/BF00122574](https://doi.org/10.1007/BF00122574).
- [3] A. P L, JIE C, FU M, et al. Cumulative prospect theory meets reinforcement learning: Prediction and control[A/OL]. 2016. arXiv: [1506.02632](https://arxiv.org/abs/1506.02632). <https://arxiv.org/abs/1506.02632>.
- [4] LEPEL O, BARAKAT A. Policy gradients for cumulative prospect theory in reinforcement learning[A/OL]. 2026. arXiv: [2410.02605](https://arxiv.org/abs/2410.02605). <https://arxiv.org/abs/2410.02605>.
- [5] ARKES H R, HIRSHLEIFER D, JIANG D, et al. Reference point adaptation: Tests in the domain of security trading[J/OL]. *Organizational Behavior and Human Decision Processes*, 2008, 105(1): 67-81. DOI: [10.1016/j.obhdp.2007.04.005](https://doi.org/10.1016/j.obhdp.2007.04.005).
- [6] HE X D, YANG L. Realization utility with adaptive reference points[J/OL]. *Mathematical Finance*, 2019, 29(2): 409-447. DOI: [10.1111/mafi.12182](https://doi.org/10.1111/mafi.12182).
- [7] KONG L, QIN C, YUE X. Realization utility with path-dependent reference points [J/OL]. *SIAM Journal on Financial Mathematics*, 2022, 13(3): 1063-1111. DOI: [10.1137/21M1411457](https://doi.org/10.1137/21M1411457).
- [8] LUXENBERG E, SCHIELE P, BOYD S. Portfolio optimization with cumulative prospect theory utility via convex optimization[J/OL]. *Computational Economics*, 2024, 64: 2765-2785. DOI: [10.1007/s10614-024-10556-x](https://doi.org/10.1007/s10614-024-10556-x).
- [9] CUI X, JIANG R, SHI Y, et al. Decision making under cumulative prospect theory: An alternating direction method of multipliers[J/OL]. *INFORMS Journal on Computing*, 2025, 37(4): 856-873. DOI: [10.1287/ijoc.2023.0243](https://doi.org/10.1287/ijoc.2023.0243).
- [10] WU Z, YANG L, DE SIMONE V. Behavioral portfolio optimization via cumulative prospect theory with a symmetric alternating direction method of multipliers[J/OL]. *Computational Optimization and Applications*, 2026, 93: 303-334. DOI: [10.1007/s10589-025-00721-9](https://doi.org/10.1007/s10589-025-00721-9).

-
- [11] GAO J, LI Y, SHI Y, et al. Multi-period portfolio choice under loss aversion with dynamic reference point in serially correlated market[J/OL]. *Omega*, 2024, 127: 103103. DOI: [10.1016/j.omega.2024.103103](https://doi.org/10.1016/j.omega.2024.103103).
- [12] AN L, ENGELBERG J, HENRIKSSON M, et al. The portfolio-driven disposition effect[J/OL]. *The Journal of Finance*, 2024, 79(5): 3459-3495. DOI: [10.1111/jofi.13378](https://doi.org/10.1111/jofi.13378).
- [13] CHEN S, REN F. Does social media information affect individual investor disposition effect? Evidence from Xueqiu[J/OL]. *PLOS ONE*, 2025, 20(7): e0328547. DOI: [10.1371/journal.pone.0328547](https://doi.org/10.1371/journal.pone.0328547).
- [14] AYDORE S, ZHU T, FOSTER D. Dynamic local regret for non-convex online forecasting[C]//Advances in Neural Information Processing Systems (NeurIPS): Vol. 32. 2019.
- [15] HALLAK N. A sound local regret methodology for online nonconvex composite optimization[R]. *Optimization Online*, 2025.
- [16] LAN G, LI T, XU Y. Projected gradient methods for nonconvex and stochastic smooth optimization: new complexities and auto-conditioned stepsizes[A/OL]. 2026. arXiv: [2412.14291](https://arxiv.org/abs/2412.14291). <https://arxiv.org/abs/2412.14291>.
- [17] FENG S, YIN M, HUANG R, et al. Non-stationary reinforcement learning under general function approximation[A/OL]. 2023. arXiv: [2306.00861](https://arxiv.org/abs/2306.00861). <https://arxiv.org/abs/2306.00861>.
- [18] RHEE C H, GLYNN P W. Unbiased estimation with square root convergence for SDE models[J/OL]. *Operations Research*, 2015, 63(5): 1026-1043. DOI: [10.1287/opre.2015.1404](https://doi.org/10.1287/opre.2015.1404).
- [19] ANDRÉ E, COQUERET G. Dirichlet policies for reinforced factor portfolios[A]. 2021. arXiv: [2011.05381](https://arxiv.org/abs/2011.05381).
- [20] HANAUER M X, JANSEN M, SWINKELS L, et al. Factor models for Chinese A-shares[J/OL]. *International Review of Financial Analysis*, 2024, 91. DOI: [10.1016/j.irfa.2023.102975](https://doi.org/10.1016/j.irfa.2023.102975).
- [21] LIU X Y, XIA Z, YANG H, et al. Dynamic datasets and market environments for financial reinforcement learning[J/OL]. *Machine Learning*, 2024, 113: 2795-2839. DOI: [10.1007/s10994-023-06511-w](https://doi.org/10.1007/s10994-023-06511-w).

- [22] LIU J, TANG Y, YANG Y, et al. Evaluating and aligning human economic risk preferences in LLMs[C/OL]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2025: 18174-18188. DOI: [10.18653/v1/2025.emnlp-main.917](https://doi.org/10.18653/v1/2025.emnlp-main.917).
- [23] TAKAYANAGI T, IZUMI K, SANZ-CRUZADO J, et al. Are generative AI agents effective personalized financial advisors?[C/OL]//Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval. ACM, 2025: 286-295. DOI: [10.1145/3726302.3729897](https://doi.org/10.1145/3726302.3729897).

附录

第一节 主要符号与分析预备结果

固定目标的统计结论均在给定期初信息、所查询参数及冻结模拟模型后，对新生成的蒙特卡洛轨迹成立；文中的条件独立性也相对于这一条件分布而言。令重复次数 M 趋于无穷时，目标和估计器设计 (n, p_{act}, b) 固定；令时期数 K 增长时，各假设中的常数须在时期之间统一；极小极大结论则固定维度 d 和模型类常数，使预算 $B \rightarrow \infty$ 。

附录 1.1 主要符号

表 6-1 状态、目标、估计与在线评价中的主要符号。估计器内部记号及仅用于证明的常数在首次使用处定义。

符号	类型	含义
k, u, h	下标/整数	时期、日历时间及每期的有限时域长度
$s_u, \omega_u, \tilde{\omega}_u$	状态/组合	状态 $(m_u, X_u, r_u, \omega_{u-1})$, 其中 m_u 为市场状态; 执行组合与潜在提议
$z_k, \mathcal{F}_k, r_k$	起点/信息	冻结的非参考点起始状态、期初信息及参考点 r_{t_k}
$\theta, \Theta, \pi_\theta$	向量/集合/策略	策略参数、紧凸参数域与 Dirichlet 策略
$P_k, \tilde{P}_k$	时期模型	真实模型与冻结模拟模型; 固定 (P, z, r) 后, P_θ 表示诱导的增广轨迹分布
$Y_k, v_\pm, w_\pm^\varepsilon$	结果/函数	终端相对结果、正则化 CPT 价值函数及概率权重
$J_k, \tilde{J}_k$	标量函数	真实 CPT 目标与冻结模拟目标
$g_k, \tilde{g}_k$	$\Theta \rightarrow \mathbb{R}^d$	真实梯度映射与冻结模拟梯度映射
$G_{k,\theta}(\tau)$	$\mathbb{R}^d$	参数 θ 下的完整轨迹得分
$\hat{g}_k^{\text{db}}, M_k$	向量/整数	M_k 次独立完整输出的平均去偏梯度
$Q_k; \gamma, \vartheta$	映射/标量	投影残差映射、步长与归一化下界
S_k	Θ 的子集	受约束的一阶驻点集合
ζ_k	$\mathbb{R}_+$	平方投影残差 $\ Q_k(\theta_k)\ _2^2$
$\mathcal{E}_K$	$\mathbb{R}_+$	平均期望平方投影残差
$A_{\rho, W}, \bar{Q}_k$	标量/向量	全窗口指数权重和与时间平滑后的投影残差
$\mathcal{R}_{\rho, W}(K); \rho, W$	标量/参数	动态局部遗憾、折扣系数与窗口长度
$\beta_k, \mathcal{V}_K$	$\mathbb{R}_+$	模拟梯度误差与真实目标的累计变差
T_{call}, B	停止时刻/标量	非负整数值的轨迹查询次数与期望轨迹预算

附录 1.2 Dirichlet 得分矩

引理 6.1 (增广轨迹得分的统一矩界): 在假设 2.1–2.2 下, 存在 $0 < \underline{a} \leq \bar{a} < \infty$, 使对所有 i, u, θ 均有

$$\underline{a} \leq a_{i,u}(\theta) \leq \bar{a}. \quad (6-1)$$

对每个固定的 $1 \leq p < \infty$,

$$\sup_{k, \theta} \mathbb{E} \|G_{k, \theta}\|_2^p < \infty. \quad (6-2)$$

轨迹对数似然的 *Hessian* 矩阵 $\mathcal{H}_{k,\theta}$ 亦满足

$$\sup_{k,\theta} \mathbb{E} \|\mathcal{H}_{k,\theta}\|_{\text{op}} < \infty. \quad (6-3)$$

进一步, 对任意有界可测的轨迹泛函 F , 条件轨迹分布下可交换至二阶求导与积分:

$$\nabla_{\theta} \mathbb{E}_{\theta} F = \mathbb{E}_{\theta}(F G_{k,\theta}), \quad \nabla_{\theta}^2 \mathbb{E}_{\theta} F = \mathbb{E}_{\theta}\{F(G_{k,\theta} G_{k,\theta}^{\top} + \mathcal{H}_{k,\theta})\}. \quad (6-4)$$

证明: Θ 的紧性与 $q_{i,u}$ 的有界性给出式 (6-1)。Dirichlet 分布的每一坐标都具有 Beta 边缘分布, 其两个参数落在 $(0, \infty)^2$ 的紧子集中。因此对任意有限的 $p \geq 1$,

$$\sup_{a,b} \int_0^1 |\log x|^p x^{a-1} (1-x)^{b-1} dx < \infty,$$

其中上确界取遍诱导的紧参数集。digamma 与 polygamma 项在相同的正紧区间上有界。结合式 (2-8)、因子有界性和有限的 (h, N) , 得到式 (6-2); 再对得分求一次导数, 得到式 (6-3)。依假设 2.2, 市场转移核与 $M_u(\cdot | s_u)$ 不贡献似然导数。

为交换求导与轨迹积分, 在仍包含于策略定义域的前提下将 Θ 略微扩张。此邻域中的浓度参数保持在某个 $[a_-, a_+]$ 内, 其中 $a_- > 0$ 。对单次潜在动作 $\tilde{\omega}$, Dirichlet 密度及其关于 θ 的一、二阶导数, 都由与 θ 无关的常数倍下式控制:

$$\prod_{i=0}^N \tilde{\omega}_i^{a_- - 1} \left(1 + \sum_{i=0}^N |\log \tilde{\omega}_i|^2 \right).$$

当 $a_- > 0$ 时, 这一包络在单纯形上可积。有限的 h 次潜在动作相乘后仍构成可积的轨迹包络; 与参数无关的市场核在每步条件积分中均积分为一。因此, 有界 F 与前两阶导数的乘积均被同一可积函数支配。应用控制收敛定理得到式 (6-4)。

□

附录 1.3 CPT 目标的光滑性

引理 6.2 (统一梯度界与光滑界): 在假设 2.1–2.3 下, 存在 $B_g, L < \infty$, 使

$$\sup_{k, \theta \in \Theta} \|g_k(\theta)\|_2 \leq B_g, \quad \|g_k(\theta) - g_k(\theta')\|_2 \leq L \|\theta - \theta'\|_2. \quad (6-5)$$

记

$$C_{G,2} := \sup_{k,\theta} \mathbb{E} \|G_{k,\theta}\|_2^2, \quad C_H := \sup_{k,\theta} \mathbb{E} \|\mathcal{H}_{k,\theta}\|_{\text{op}},$$

则可取

$$B_g = 2B_v C_1 \sqrt{C_{G,2}}, \quad L = 2B_v \{C_2 C_{G,2} + C_1(C_{G,2} + C_H)\}. \quad (6-6)$$

此外, $|J_k(\theta, r_k)| \leq B_v$ 。

证明: 对侧别 σ 与阈值 y , 记 $I_\sigma(y) := \mathbf{1}\{v_\sigma(Y) > y\}$ 。由似然得分恒等式及引理 6.1,

$$\nabla S_\theta^\sigma(y) = \mathbb{E}\{I_\sigma(y)G_\theta\}, \quad \nabla^2 S_\theta^\sigma(y) = \mathbb{E}\{I_\sigma(y)(G_\theta G_\theta^\top + \mathcal{H}_\theta)\}.$$

指标函数有界, 得分矩也有界, 因此可由控制收敛交换求导与期望, 并有

$$\|\nabla S_\theta^\sigma(y)\|_2 \leq \sqrt{C_{G,2}}, \quad \|\nabla^2 S_\theta^\sigma(y)\|_{\text{op}} \leq C_{G,2} + C_H.$$

对 CPT 积分求两次导数, 再用假设 2.3, 得到

$$\nabla^2 \int_0^{B_v} w_\sigma^\varepsilon(S_\theta^\sigma(y)) dy = \int_0^{B_v} \{(w_\sigma^\varepsilon)''(S) \nabla S \nabla S^\top + (w_\sigma^\varepsilon)'(S) \nabla^2 S\} dy.$$

被积函数由上述常数统一控制, 故有式 (6-6); 一阶导数的界同理。最后, $0 \leq w_\sigma^\varepsilon \leq 1$ 且两个积分的共同区间长度为 B_v , 所以 $|J_k| \leq B_v$ 。□

附录 1.4 投影残差与受约束驻点

引理 6.3 (投影残差刻画一阶驻点): 设 Θ 闭且凸, $\theta \in \Theta$, $\gamma, \vartheta > 0$, $g \in \mathbb{R}^d$, 则

$$\Pi_\Theta\{\theta + \gamma \mathbf{d}(g)\} = \theta \iff \langle g \rangle \theta' - \theta \leq 0 \quad \forall \theta' \in \Theta. \quad (6-7)$$

因此, 式 (2-18) 中的两种驻点定义等价。

证明: 投影的变分不等式表明, $x = \Pi_\Theta(y)$ 当且仅当对所有 $\theta' \in \Theta$ 有 $\langle y - x \rangle \theta' - x \leq 0$ 。代入 $y = \theta + \gamma \mathbf{d}(g)$, 并注意 $\mathbf{d}(g) = g / \max\{\|g\|_2, \vartheta\}$ 是 g 的正倍数, 即得结论。□

第二节 参考点机制与 CPT 梯度的证明

附录 2.1 相同期末财富与路径依赖参考点

证明：先分别计算两条路径的期末参考点，再利用确定性 CPT 价值的严格单调性。路径 I 的第一步为收益，因此中间参考点为

$$r_I^{(1)} = (1 - \eta_+)r_0 + \eta_+x_{hi}.$$

命题中的第一个条件使第二步相对这一参考点构成损失，于是

$$r_I = (1 - \eta_-)\{(1 - \eta_+)r_0 + \eta_+x_{hi}\} + \eta_-x_f.$$

路径 II 的第一步为损失，其中间参考点为

$$r_{II}^{(1)} = (1 - \eta_-)r_0 + \eta_-x_{lo}.$$

第二个条件使随后到 x_f 的变化成为收益，因此

$$r_{II} = (1 - \eta_+)\{(1 - \eta_-)r_0 + \eta_-x_{lo}\} + \eta_+x_f.$$

两式相减后， r_0 的系数抵消，得到式 (4-1)。

对确定性相对结果 y ，相应价值幅度以下的生存概率为一，以上为零。由 $w_{\pm}^{\varepsilon}(0) = 0$ 和 $w_{\pm}^{\varepsilon}(1) = 1$ ，其 CPT 价值为 $v_+(y) - v_-(y)$ 。平移幂函数的收益项在 $y > 0$ 时严格递增， $-v_-(y)$ 在 $y < 0$ 时严格递增，且两部分在零点连续相接。因此有符号的确定性 CPT 价值对 y 严格递增。当 $r_I \neq r_{II}$ 时， $x_f - r_I \neq x_f - r_{II}$ ，两条路径的 CPT 价值必然不同。□

附录 2.2 参考点收缩与 CPT 敏感性

证明：固定财富值 x 。映射 $r \mapsto \Phi(r, x)$ 连续，当 $r \leq x$ 时斜率为 $1 - \eta_+$ ，当 $r > x$ 时斜率为 $1 - \eta_-$ 。必要时在 x 处分割区间，即有

$$|\Phi(r, x) - \Phi(r', x)| \leq (1 - \eta_{\min})|r - r'|.$$

在命题所规定的参考点隔离比较中，两条轨迹共享财富路径。将上述不等式迭代 h 次即得到式 (4-3)。期末财富也相同，所以

$$|Y(r) - Y(r')| \leq (1 - \eta_{\min})^h |r - r'|. \quad (6-8)$$

对 $x \geq 0$,

$$\frac{d}{dx}u_{\alpha, \varepsilon_v}(x) = \alpha x(x^2 + \varepsilon_v^2)^{\alpha/2-1} \leq \alpha \varepsilon_v^{\alpha-1},$$

因为 $x \leq (x^2 + \varepsilon_v^2)^{1/2}$ 且 $\alpha \leq 1$ 。从而

$$|v_+(y) - v_+(y')| + |v_-(y) - v_-(y')| \leq L_v |y - y'|.$$

结合式 (6-8), 可控制两侧期末价值幅度差的总和。

若 $V, V' \in [0, B_v]$ 为耦合的非负随机变量, 则由 Tonelli 定理,

$$\begin{aligned} \int_0^{B_v} |\mathbb{P}(V > y) - \mathbb{P}(V' > y)| dy &\leq \mathbb{E} \int_0^{B_v} |\mathbf{1}\{V > y\} - \mathbf{1}\{V' > y\}| dy \\ &= \mathbb{E}|V - V'|. \end{aligned}$$

再用 $|w_\sigma^\varepsilon(p) - w_\sigma^\varepsilon(q)| \leq C_1 |p - q|$, 对收益侧与损失侧分别应用此不等式, 得到式 (4-4)。最后在相邻期目标之差中加减 $J(P_{k+1}, z_{k+1}, r_k; \theta)$, 再对 θ 一致应用三角不等式, 得到式 (4-5)。 $\square$

附录 2.3 CPT 梯度的得分表示

证明: 先看收益部分; 损失部分计算相同, 最后从收益部分减去。记

$$J^+(\theta) = \int_0^{B_v} w_+^\varepsilon(S_\theta^+(y)) dy.$$

对固定的 y , 将引理 6.1 中的似然比恒等式用于有界指标函数, 得到

$$\nabla S_\theta^+(y) = \mathbb{E}\{\mathbf{1}[v_+(Y) > y] G_\theta\}. \quad (6-9)$$

由 Cauchy-Schwarz 不等式和假设 2.1, 右侧范数对所有 y, θ 均不超过 $\sqrt{C_{G,2}}$ 。又因 $(w_+^\varepsilon)' \leq C_1$ 且积分区间有限, 存在可积的共同控制函数。控制收敛定理遂给出

$$\begin{aligned} \nabla J^+(\theta) &= \int_0^{B_v} (w_+^\varepsilon)'(S_\theta^+(y)) \mathbb{E}\{\mathbf{1}[v_+(Y) > y] G_\theta\} dy \\ &= \mathbb{E} \left[G_\theta \int_0^{B_v} (w_+^\varepsilon)'(S_\theta^+(y)) \mathbf{1}[v_+(Y) > y] dy \right]. \end{aligned}$$

第二步可用 Fubini 定理, 因为被积项由 $C_1 B_v \|G_\theta\|$ 控制, 且 $\mathbb{E}\|G_\theta\| < \infty$ 。

得分的期望为零, 因此在积分内减去确定性的 $S_\theta^+(y)$ 不改变期望。这给出式 (4-6) 中的收益项。对损失侧重复同一论证并相减, 便得式 (4-7)。以冻结模拟

模型的轨迹分布替代真实轨迹分布，条件论证不变。 $\square$

第三节 去偏估计器的证明

本附录固定一个冻结目标，简记 $g = \nabla J(\theta)$ 。在相应条件分布下，完整轨迹摘要 $X_1, X_2, \dots$ 独立同分布。对样本 $x = (V^+, V^-, G_x)$ ，记 $I_{x,\sigma}(y) = \mathbf{1}\{V^\sigma > y\}$ 。

附录 3.1 二阶展开与全样本/半样本耦合

引理 6.4 (耦合的全样本/半样本抵消): 在假设 2.1–2.3 下，固定冻结目标与参数，令 $g := \nabla J(\theta)$ 。存在可测函数 $\mathfrak{h}$ 及有限常数 C_{rem}, C_U ，使

$$U_n^{\text{raw}} - g = \frac{1}{n} \sum_{i=1}^n \mathfrak{h}(X_i) + \mathcal{B}_n, \quad \mathbb{E}\mathfrak{h}(X_i) = 0, \quad \mathbb{E}\|\mathcal{B}_n\|_2^2 \leq \frac{C_{\text{rem}}}{n^2}, \quad (6-10)$$

从而

$$\mathbb{E}\|D_{n,\ell}^{\text{raw}}\|_2^2 \leq \frac{9C_{\text{rem}}}{n^2} 2^{-2\ell}, \quad \ell \geq 1, \quad (6-11)$$

且

$$\text{tr Cov}(U_n^{\text{cen}}) \leq \frac{C_U}{n}. \quad (6-12)$$

证明：先从 U_n^{raw} 中分离一阶 Hoeffding 投影，并分别控制退化双样本项与 Taylor 余项。对侧别 σ 和阈值 y ，记

$$S_\sigma(y) = \mathbb{P}(V^\sigma > y), \quad e_{-i,\sigma}(y) = \hat{S}_{-i,n}^\sigma(y) - S_\sigma(y).$$

对 $(w_\sigma^\varepsilon)'$ 应用 Taylor 定理，得到

$$(w_\sigma^\varepsilon)'(S_\sigma + e) = (w_\sigma^\varepsilon)'(S_\sigma) + (w_\sigma^\varepsilon)''(S_\sigma)e + \text{Rem}_\sigma(e), \quad |\text{Rem}_\sigma(e)| \leq \frac{C_3}{2} e^2. \quad (6-13)$$

把式 (6-13) 代入式 (3-4)，统计量分为一阶轨迹项、按顺序计数的双样本项和 Taylor 余项。

定义

$$\begin{aligned} \mathfrak{h}_0(x) &= G_x \sum_{\sigma} \varsigma_{\sigma} \int_0^{B_v} (w_\sigma^\varepsilon)'(S_\sigma(y)) I_{x,\sigma}(y) dy, \\ \mathcal{K}(x, x') &= G_x \sum_{\sigma} \varsigma_{\sigma} \int_0^{B_v} (w_\sigma^\varepsilon)''(S_\sigma(y)) I_{x,\sigma}(y) \{I_{x',\sigma}(y) - S_\sigma(y)\} dy. \end{aligned}$$

由式 (4-7) 和 $\mathbb{E}G = 0$ ，有 $\mathbb{E}\mathfrak{h}_0(X) = g$ 。对独立的 X, X' ， $\mathbb{E}\{\mathcal{K}(X, X') \mid X\} = 0$ ，因

为 $\mathbb{E}\{I_{X',\sigma}(y) - S_\sigma(y)\} = 0$ 。令

$$\mathfrak{h}_1(x') = \mathbb{E}_{\mathbf{X}}\{\mathcal{K}(\mathbf{X}, x')\}.$$

则 $\mathbb{E}\mathfrak{h}_1(\mathbf{X}') = 0$ 。定义 $\mathcal{K}^\circ(x, x') = \mathcal{K}(x, x') - \mathfrak{h}_1(x')$ 后，其两个一阶投影均为零：

$$\mathbb{E}\{\mathcal{K}^\circ(\mathbf{X}, \mathbf{X}') \mid \mathbf{X}\} = 0, \quad \mathbb{E}\{\mathcal{K}^\circ(\mathbf{X}, \mathbf{X}') \mid \mathbf{X}'\} = 0.$$

所以双样本项具有精确分解

$$\frac{1}{n(n-1)} \sum_{i \neq j} \mathcal{K}(\mathbf{X}_i, \mathbf{X}_j) = \frac{1}{n} \sum_{j=1}^n \mathfrak{h}_1(\mathbf{X}_j) + \mathcal{D}_n, \quad (6-14)$$

其中

$$\mathcal{D}_n = \frac{1}{n(n-1)} \sum_{i \neq j} \mathcal{K}^\circ(\mathbf{X}_i, \mathbf{X}_j).$$

指标函数有界、积分区间有限、 $(w_\sigma^\varepsilon)''$ 有界，且 $\mathbb{E}\|G\|_2^2 < \infty$ ，故核函数平方可积。退化性使两项的协方差只有在其有序下标对相同或相反时才可能非零。这样的下标对只有 $O(n^2)$ 个，而分母平方阶为 $n^2(n-1)^2$ ，因此存在有限 C_D ，使

$$\mathbb{E}\|\mathcal{D}_n\|_2^2 \leq \frac{C_D}{n^2}. \quad (6-15)$$

再考察 Taylor 余项。对每个 i ， $e_{-i,\sigma}$ 是由 $n-1$ 个与 $\mathbf{X}_i$ 独立的伯努利变量构成的经验均值。对所有 y ，有

$$\mathbb{E}|e_{-i,\sigma}(y)|^4 \leq \frac{C_e}{(n-1)^2}, \quad (6-16)$$

其中 C_e 是通用有限常数。由式 (6-13)、 y 积分上的 Cauchy-Schwarz 不等式、 G_i 与留一经验生存概率的独立性及得分二阶矩有限，每个 Taylor 项的二阶矩至多为 C_T/n^2 。再对 i 的平均使用 Jensen 不等式，得到平均余项 $\mathcal{T}_n$ 的相同阶界：

$$\mathbb{E}\|\mathcal{T}_n\|_2^2 \leq \frac{C_T}{n^2}. \quad (6-17)$$

合并一阶项、式 (6-14) 和 Taylor 余项，

$$U_n^{\text{raw}} - g = \frac{1}{n} \sum_{i=1}^n \mathfrak{h}(\mathbf{X}_i) + \mathcal{B}_n, \quad \mathfrak{h} = \mathfrak{h}_0 - g + \mathfrak{h}_1, \quad \mathcal{B}_n = \mathcal{D}_n + \mathcal{T}_n.$$

$\mathfrak{h}$ 的期望为零；放大有限常数 C_{rem} 后，由式 (6-15)–(6-17) 得到 $\mathbb{E}\|\mathcal{B}_n\|_2^2 \leq C_{\text{rem}}/n^2$ ，从而证明式 (6-10)。

现在取 $n_\ell = n2^\ell$ ，在同一批 n_ℓ 条轨迹上计算全样本及两个半样本的未中心

化统计量。对全样本与各半样本应用式 (6-10)，有

$$U_{n_\ell}^{\text{raw}} = g + \frac{1}{n_\ell} \sum_{i=1}^{n_\ell} \mathfrak{h}(\mathbf{X}_i) + \mathcal{B}_{n_\ell},$$

以及

$$\frac{1}{2}\{U_{n_\ell/2}^{\text{raw},(1)} + U_{n_\ell/2}^{\text{raw},(2)}\} = g + \frac{1}{n_\ell} \sum_{i=1}^{n_\ell} \mathfrak{h}(\mathbf{X}_i) + \frac{1}{2}\{\mathcal{B}_{n_\ell/2}^{(1)} + \mathcal{B}_{n_\ell/2}^{(2)}\}.$$

一阶影响项完全抵消，留下

$$D_{n,\ell}^{\text{raw}} = \mathcal{B}_{n_\ell} - \frac{1}{2}\{\mathcal{B}_{n_\ell/2}^{(1)} + \mathcal{B}_{n_\ell/2}^{(2)}\}.$$

由 L^2 中的 Minkowski 不等式，

$$(\mathbb{E}\|D_{n,\ell}^{\text{raw}}\|_2^2)^{1/2} \leq \frac{\sqrt{C_{\text{rem}}}}{n_\ell} + \frac{1}{2} \frac{2\sqrt{C_{\text{rem}}}}{n_\ell} + \frac{1}{2} \frac{2\sqrt{C_{\text{rem}}}}{n_\ell} = \frac{3\sqrt{C_{\text{rem}}}}{n_\ell}.$$

两边平方并代入 $n_\ell = n2^\ell$ ，得到式 (6-11)。

最后证明式 (6-12)。将 U_n^{cen} 视为 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 的对称函数，用独立副本 $\mathbf{X}'_i$ 替换第 i 个样本后的统计量记为 $U_n^{\text{cen},(i)}$ 。若 G'_i 为该副本的得分，则单个中心化留一项的系数绝对值不超过 $2B_v C_1$ ，被替换项的贡献范数至多为

$$\frac{2B_v C_1}{n} (\|G_i\|_2 + \|G'_i\|_2).$$

对 $j \neq i$ ，替换 $\mathbf{X}_i$ 使第 j 项的留一生存概率逐点变化不超过 $(n-1)^{-1}$ 。由于

$$\left| \frac{\partial}{\partial p} \{(w_\sigma^\varepsilon)'(p)(I-p)\} \right| \leq C_1 + C_2,$$

乘在 G_j 前的标量系数变化不超过 $2B_v(C_1 + C_2)/(n-1)$ 。因而存在只依赖 B_v, C_1, C_2 的确定常数 C_* ，使

$$\|U_n^{\text{cen}} - U_n^{\text{cen},(i)}\|_2 \leq \frac{C_*}{n} (\|G_i\|_2 + \|G'_i\|_2) + \frac{C_*}{n(n-1)} \sum_{j \neq i} \|G_j\|_2.$$

使用 $(\sum_{j \neq i} x_j)^2 \leq (n-1) \sum_{j \neq i} x_j^2$ 和得分的统一二阶矩界，可取有限的 C_U ，使对所有 i 都有

$$\mathbb{E}\|U_n^{\text{cen}} - U_n^{\text{cen},(i)}\|_2^2 \leq \frac{2C_U}{n^2}.$$

向量形式的 Efron–Stein 不等式遂给出

$$\text{tr Cov}(U_n^{\text{cen}}) = \mathbb{E}\|U_n^{\text{cen}} - \mathbb{E}U_n^{\text{cen}}\|_2^2 \leq \frac{1}{2} \sum_{i=1}^n \mathbb{E}\|U_n^{\text{cen}} - U_n^{\text{cen},(i)}\|_2^2 \leq \frac{C_U}{n}.$$

证毕。 $\square$

附录 3.2 中心化与有限样本偏差

引理 6.5 (中心化与有限样本偏差): 对 $n \geq 2$, 有

$$\mathbb{E}U_n^{\text{cen}} = \mathbb{E}U_n^{\text{raw}} =: \bar{U}_n, \quad (6-18)$$

且

$$\|\bar{U}_n - g\|_2 \leq \frac{\sqrt{C_{\text{rem}}}}{n}, \quad g := \nabla J(\theta). \quad (6-19)$$

证明: 由式 (3-4) 减去式 (3-3), 得到

$$U_n^{\text{raw}} - U_n^{\text{cen}} = \frac{1}{n} \sum_{i=1}^n G_i H_{-i}^{\text{ctr}}, \quad (6-20)$$

其中

$$H_{-i}^{\text{ctr}} = \sum_{\sigma \in \{+, -\}} \varsigma_{\sigma} \int_0^{B_v} (w_{\sigma}^{\varepsilon})'(\hat{S}_{-i,n}^{\sigma}(y)) \hat{S}_{-i,n}^{\sigma}(y) dy.$$

H_{-i}^{ctr} 只依赖下标不为 i 的轨迹, 因而与 G_i 独立。得分恒等式给出 $\mathbb{E}G_i = 0$, 而假设 2.1-2.3 保证 $G_i H_{-i}^{\text{ctr}}$ 可积。所以式 (6-20) 中的每一项期望均为零, 得到 $\mathbb{E}U_n^{\text{cen}} = \mathbb{E}U_n^{\text{raw}} = \bar{U}_n$ 。

再由引理 6.4 中的展开式 (6-10) 及 $\mathbb{E}h(X) = 0$,

$$\|\bar{U}_n - g\|_2 = \|\mathbb{E}\mathcal{B}_n\|_2 \leq (\mathbb{E}\|\mathcal{B}_n\|_2^2)^{1/2} \leq \frac{\sqrt{C_{\text{rem}}}}{n}.$$

这即是式 (6-19)。 □

附录 3.3 无偏性、方差、成本与中心极限定理

证明: 先证明严格无偏。由引理 6.5, 中心化基项的期望为 $\bar{U}_n$ 。未中心化修正项满足

$$\mathbb{E}D_{n,\ell}^{\text{raw}} = \bar{U}_{n2^{\ell}} - \bar{U}_{n2^{\ell-1}}. \quad (6-21)$$

式 (6-11) 推出

$$\sum_{\ell \geq 1} \mathbb{E}\|D_{n,\ell}^{\text{raw}}\|_2 \leq \frac{3\sqrt{C_{\text{rem}}}}{n} \sum_{\ell \geq 1} 2^{-\ell} < \infty,$$

故可交换期望与无限随机级数。又由式 (6-19), $\bar{U}_{n2^{\ell_{\max}}} \rightarrow g$, 于是

$$\mathbb{E}Z_n^{\text{db}} = \bar{U}_n + \sum_{\ell \geq 1} \mathbb{E}D_{n,\ell}^{\text{raw}}$$

$$= \bar{U}_n + \lim_{\ell_{\max} \rightarrow \infty} (\bar{U}_{n2^{\ell_{\max}}} - \bar{U}_n) = g.$$

这证明式 (4-9)。

激活变量、层级变量与修正样本独立，因此修正项的二阶矩为

$$\begin{aligned} \mathbb{E} \left\| \frac{\mathbf{A}}{p_{\text{act}} \nu_{\ell^*}} D_{n, \ell^*}^{\text{raw}} \right\|_2^2 &= \frac{1}{p_{\text{act}}} \sum_{\ell \geq 1} \frac{\mathbb{E} \|D_{n, \ell}^{\text{raw}}\|_2^2}{\nu_{\ell}} \\ &\leq \frac{9C_{\text{rem}}}{p_{\text{act}} n^2} \sum_{\ell \geq 1} \frac{4^{-\ell}}{\nu_{\ell}} = \frac{9C_{\text{rem}} \Xi_b}{p_{\text{act}} n^2}. \end{aligned}$$

因 $b < 2$ ，级数 Ξ_b 有限。基项与修正项独立，协方差为零；结合式 (6-12)，得到式 (4-10)。

一次基项输出恰好使用 n 条完整轨迹。若修正被激活且抽到层级 ℓ ，只需额外模拟一批 $n2^{\ell}$ 条轨迹，两个半样本复用同一批轨迹。因此

$$\mathbb{E} \text{cost}(Z_n^{\text{db}}) = n + p_{\text{act}} n \sum_{\ell \geq 1} \nu_{\ell} 2^{\ell} = n(1 + p_{\text{act}} \Upsilon_b).$$

由 $b > 1$ 知 $\Upsilon_b < \infty$ ；对几何级数直接求和便得式 (4-8) 中的闭式。

若 $Z_{n,1}^{\text{db}}, \dots, Z_{n,M}^{\text{db}}$ 独立同分布，则严格无偏与独立性给出

$$\mathbb{E} \|\hat{g}_{M,n}^{\text{db}} - g\|_2^2 = \frac{1}{M} \text{tr Cov}(Z_n^{\text{db}}) \leq \frac{C_{\text{var}}(n, p_{\text{act}}, b)}{M}.$$

故式 (4-12) 成立。 $\square$

证明：固定目标与 (n, p_{act}, b) 后，定理 4.2 保证 $Z_{n,m}^{\text{db}}$ 独立同分布，均值为 g ，协方差 Σ_n 有限。对任意固定 $t \in \mathbb{R}^d$ ，标量 $t^{\top}(Z_{n,m}^{\text{db}} - g)$ 独立同分布且方差有限。经典标量中心极限定理给出

$$\sqrt{M} t^{\top} (\hat{g}_{M,n}^{\text{db}} - g) \rightsquigarrow \mathcal{N}(0, t^{\top} \Sigma_n t).$$

由 Cramér–Wold 装置得到式 (4-13)。

因为 $\mathbb{E} \|Z_n^{\text{db}}\|_2^2 < \infty$ ，矩阵 $Z_n^{\text{db}} (Z_n^{\text{db}})^{\top}$ 的每个元素都可积。大数定律使 $\hat{\Sigma}_{M,n}$ 逐元素依概率收敛于 Σ_n ；在固定维度下，这也给出算子范数收敛。若 Σ_n 非奇异，则 $\mathbb{P}\{\lambda_{\min}(\hat{\Sigma}_{M,n}) > \lambda_{\min}(\Sigma_n)/2\} \rightarrow 1$ 。在该事件上，逆平方根映射于 Σ_n 的邻域中有定义且连续。将 Slutsky 定理用于式 (4-13)，便得到式 (4-14)。 $\square$

第四节 在线残差与驻点跟踪的证明

附录 4.1 归一化投影上升

引理 6.6 (单步归一化投影上升): 设 J 在非空闭凸集 Θ 上为 L -光滑。固定 $x \in \Theta$, 令 $g = \nabla J(x)$ 且 $\|g\|_2 \leq B_g$, $\hat{g}$ 为任意有限向量。记

$$x^+ = \Pi_{\Theta}\{x + \gamma \mathbf{d}(\hat{g})\}, \quad Q(x) = \gamma^{-1}[\Pi_{\Theta}\{x + \gamma \mathbf{d}(g)\} - x].$$

若 $\gamma L \leq \vartheta$, 且 $C_g := \max\{B_g, \vartheta\}$, 则

$$J(x^+) - J(x) \geq \frac{\vartheta\gamma}{8}\|Q(x)\|_2^2 - \frac{5C_g\gamma}{4\vartheta^2}\|\hat{g} - g\|_2^2. \quad (6-22)$$

证明: 先用估计梯度产生的实际位移建立上升界, 再将其与总体梯度产生的投影位移比较。令

$$\Delta x = x^+ - x, \quad c_g = \max\{\|g\|_2, \vartheta\}, \quad \mathbf{e} = \mathbf{d}(\hat{g}) - \mathbf{d}(g).$$

以可行点 x 为比较对象, 投影变分不等式给出

$$\langle \mathbf{d}(\hat{g}), \Delta x \rangle \geq \frac{\|\Delta x\|_2^2}{\gamma}. \quad (6-23)$$

由 $g = c_g \mathbf{d}(g)$ 、 L -光滑函数的下二次界及式 (6-23),

$$\begin{aligned} J(x + \Delta x) - J(x) &\geq \langle g, \Delta x \rangle - \frac{L}{2}\|\Delta x\|_2^2 \\ &= c_g \langle \mathbf{d}(\hat{g}) - \mathbf{e}, \Delta x \rangle - \frac{L}{2}\|\Delta x\|_2^2 \\ &\geq \left(\frac{c_g}{\gamma} - \frac{L}{2} \right) \|\Delta x\|_2^2 - c_g \|\mathbf{e}\|_2 \|\Delta x\|_2 \\ &\geq \left(\frac{3c_g}{4\gamma} - \frac{L}{2} \right) \|\Delta x\|_2^2 - c_g \gamma \|\mathbf{e}\|_2^2 \\ &\geq \frac{c_g}{4\gamma} \|\Delta x\|_2^2 - c_g \gamma \|\mathbf{e}\|_2^2. \end{aligned} \quad (6-24)$$

倒数第二步使用 $uv \leq u^2/(4\gamma) + \gamma v^2$, 最后一步使用 $\gamma L \leq \vartheta \leq c_g$ 。

再令

$$t = \Pi_{\Theta}\{x + \gamma \mathbf{d}(g)\} - x = \gamma Q(x).$$

欧氏投影非扩张, 故 $\|\Delta x - t\|_2 \leq \gamma \|\mathbf{e}\|_2$ 。由 $\|t\|_2^2 \leq 2\|\Delta x\|_2^2 + 2\|\Delta x - t\|_2^2$,

$$\|\Delta x\|_2^2 \geq \frac{1}{2}\|t\|_2^2 - \gamma^2 \|\mathbf{e}\|_2^2.$$

代入式 (6-24) 得到

$$J(x^+) - J(x) \geq \frac{c_g \gamma}{8} \|Q(x)\|_2^2 - \frac{5c_g \gamma}{4} \|\mathbf{e}\|_2^2.$$

最后, $\mathbf{d}(g) = \Pi_{\{u: \|u\|_2 \leq 1\}}(g/\vartheta)$, 由单位球投影非扩张性,

$$\|\mathbf{e}\|_2 \leq \vartheta^{-1} \|\hat{g} - g\|_2.$$

对正项使用 $c_g \geq \vartheta$, 负项使用 $c_g \leq C_g = \max(B_g, \vartheta)$, 即得式 (6-22)。 $\square$

附录 4.2 期望平均平方投影残差

证明: 先连接最终估计量与真实梯度。在给定 $\mathcal{F}_k$ 后, 定理 4.2 给出

$$\mathbb{E}(\hat{g}_k^{\text{db}} - \tilde{g}_k(\theta_k) \mid \mathcal{F}_k) = 0, \quad \mathbb{E}(\|\hat{g}_k^{\text{db}} - \tilde{g}_k(\theta_k)\|_2^2 \mid \mathcal{F}_k) \leq \frac{C_{\text{var}}(n, p_{\text{act}}, b)}{M_k}.$$

与条件确定向量 $\tilde{g}_k(\theta_k) - g_k(\theta_k)$ 的交叉项因此为零。于是

$$\begin{aligned} \mathbb{E}\|\hat{g}_k^{\text{db}} - g_k(\theta_k)\|_2^2 &= \mathbb{E}\|\hat{g}_k^{\text{db}} - \tilde{g}_k(\theta_k)\|_2^2 + \mathbb{E}\|\tilde{g}_k(\theta_k) - g_k(\theta_k)\|_2^2 \\ &\leq \frac{C_{\text{var}}(n, p_{\text{act}}, b)}{M_k} + \mathbb{E}\beta_k^2, \end{aligned}$$

即式 (4-18)。

现在对真实时期目标 J_k , 在 $x = \theta_k$ 和 $\hat{g} = \hat{g}_k^{\text{db}}$ 处应用引理 6.6。记

$$\mathbf{j}_k = J_k(\theta_{k+1}) - J_k(\theta_k).$$

取期望后有

$$\frac{\vartheta \gamma}{8} \mathbb{E}\zeta_k \leq \mathbb{E}\mathbf{j}_k + \frac{5C_g \gamma}{4\vartheta^2} \mathbb{E}\|\hat{g}_k^{\text{db}} - g_k(\theta_k)\|_2^2. \quad (6-25)$$

跨越移动目标时, 目标增量满足逐路径的望远镜恒等式

$$\begin{aligned} \sum_{k=1}^K \mathbf{j}_k &= J_K(\theta_{K+1}) - J_1(\theta_1) \\ &\quad + \sum_{k=1}^{K-1} \{J_k(\theta_{k+1}) - J_{k+1}(\theta_{k+1})\}. \end{aligned} \quad (6-26)$$

由于 $|J_k| \leq B_v$, 第二行的上界为 $\mathcal{V}_K$, 所以

$$\sum_{k=1}^K \mathbf{j}_k \leq 2B_v + \mathcal{V}_K. \quad (6-27)$$

将式 (6-25) 逐期相加, 代入式 (4-18) 和式 (6-27), 再除以 $\vartheta \gamma K/8$, 得到式 (4-19)。

$\square$

附录 4.3 动态局部遗憾

证明：按约定， $t \leq 0$ 时 $Q_t(\theta_t) = 0$ 。系数 $\rho^j/A_{\rho,W}$ 对 $j = 0, \dots, W-1$ 非负，且和为一。利用 $x \mapsto \|x\|_2^2$ 的凸性，

$$\|\bar{Q}_k\|_2^2 \leq \frac{1}{A_{\rho,W}} \sum_{j=0}^{W-1} \rho^j \|Q_{k-j}(\theta_{k-j})\|_2^2.$$

对 $k \leq K$ 求和并重排下标，

$$\mathcal{R}_{\rho,W}(K) \leq \sum_{t=1}^K \zeta_t \left\{ \frac{1}{A_{\rho,W}} \sum_{j=0}^{\min\{W-1, K-t\}} \rho^j \right\} \leq \sum_{t=1}^K \zeta_t.$$

这证明式 (4-20)；取期望并除以 K 即得式 (4-21)。 $\square$

独立评估流。 对固定迭代点 θ ，写

$$\mathcal{Q}_\theta(g) := \gamma^{-1}[\Pi_\Theta\{\theta + \gamma d(g)\} - \theta].$$

由投影非扩张性与 d 的 ϑ^{-1} -Lipschitz 性，

$$\|\mathcal{Q}_\theta(\hat{g}) - \mathcal{Q}_\theta(g)\|_2 \leq \vartheta^{-1} \|\hat{g} - g\|_2. \quad (6-28)$$

若 $\hat{g}^{(1)}, \hat{g}^{(2)}$ 为相互独立的梯度估计，且满足 $\mathbb{E}\|\hat{g}^{(j)} - g\|_2^2 \leq \varepsilon_g^2$ ，记 $\hat{Q}^{(j)} = \mathcal{Q}_\theta(\hat{g}^{(j)})$ ，则

$$\left| \mathbb{E}\langle \hat{Q}^{(1)} \rangle \hat{Q}^{(2)} - \|\mathcal{Q}_\theta(g)\|_2^2 \right| \leq \frac{2\varepsilon_g}{\vartheta} + \frac{\varepsilon_g^2}{\vartheta^2}. \quad (6-29)$$

令 $\text{Bias}_j := \mathbb{E}\hat{Q}^{(j)} - \mathcal{Q}_\theta(g)$ 。由独立性，

$$\mathbb{E}\langle \hat{Q}^{(1)} \rangle \hat{Q}^{(2)} = \langle \mathcal{Q}_\theta(g) + \text{Bias}_1 \rangle \mathcal{Q}_\theta(g) + \text{Bias}_2.$$

Jensen 不等式和式 (6-28) 给出 $\|\text{Bias}_j\|_2 \leq \varepsilon_g/\vartheta$ 。又因 $\|d(g)\|_2 \leq 1$ ，有 $\|\mathcal{Q}_\theta(g)\|_2 \leq 1$ 。故

$$\left| \langle \mathcal{Q}_\theta(g) + \text{Bias}_1 \rangle \mathcal{Q}_\theta(g) + \text{Bias}_2 - \|\mathcal{Q}_\theta(g)\|_2^2 \right| \leq \|\mathcal{Q}_\theta(g)\|_2 (\|\text{Bias}_1\|_2 + \|\text{Bias}_2\|_2) + \|\text{Bias}_1\|_2 \|\text{Bias}_2\|_2,$$

从而得到式 (6-29)。

对截至第 K 期的在线路径，令 $\mathcal{C}_K$ 为独立评估抽样前由已实现迭代点和各期目标生成的 σ -域。设两条完整评估流在给定 $\mathcal{C}_K$ 后条件独立。对 $1 \leq t \leq K$ ，

令 $\hat{g}_t^{(j)}$ 为第 $j = 1, 2$ 条评估流在时期 t 的独立梯度估计, 并定义

$$\hat{Q}_t^{(j)} := \mathcal{Q}_{\theta_t}(\hat{g}_t^{(j)}), \quad \mathbb{E}[\|\hat{g}_t^{(j)} - g_t(\theta_t)\|_2^2 \mid \mathcal{C}_K] \leq \varepsilon_{g,t}^2,$$

其中 $\varepsilon_{g,t}$ 是非负的 $\mathcal{C}_K$ -可测误差上界。对 $t \leq 0$, 令 $\hat{Q}_t^{(j)} = 0$ 、 $\varepsilon_{g,t} = 0$, 与式 (2-20) 一致。对 $1 \leq k \leq K$, 定义

$$\hat{\bar{Q}}_k^{(j)} = A_{\rho,W}^{-1} \sum_{r=0}^{W-1} \rho^r \hat{Q}_{k-r}^{(j)}, \quad \bar{\varepsilon}_k = A_{\rho,W}^{-1} \sum_{r=0}^{W-1} \rho^r \varepsilon_{g,k-r}.$$

条件 Jensen 不等式与式 (6-28) 将各平滑评估流的平均误差控制在 $\bar{\varepsilon}_k/\vartheta$ 。由于 $\|\bar{Q}_k\|_2 \leq 1$, 结合条件独立性与相同的交叉乘积论证,

$$\left| \mathbb{E}[\langle \hat{\bar{Q}}_k^{(1)}, \hat{\bar{Q}}_k^{(2)} \rangle \mid \mathcal{C}_K] - \|\bar{Q}_k\|_2^2 \right| \leq \frac{2\bar{\varepsilon}_k}{\vartheta} + \frac{\bar{\varepsilon}_k^2}{\vartheta^2}. \quad (6-30)$$

再取期望, 仍以上式右侧的期望控制交叉乘积的期望与 $\mathbb{E}\|\bar{Q}_k\|_2^2$ 的差。

附录 4.4 驻点集合的推论

引理 6.7 (驻点集合的漂移): 若式 (4-22) 成立, 定义

$$\delta_k^g := \sup_{\theta \in \Theta} \|g_{k+1}(\theta) - g_k(\theta)\|_2. \quad (6-31)$$

以 d_H 表示 Hausdorff 距离, 则

$$d_H(\mathbf{S}_{k+1}, \mathbf{S}_k) \leq \frac{\kappa}{\vartheta} \delta_k^g. \quad (6-32)$$

证明: [推论 4.2 的证明] 由式 (4-22), 逐点有

$$\text{dist}^2(\theta_k, \mathbf{S}_k) \leq \kappa^2 \|Q_k(\theta_k)\|_2^2 = \kappa^2 \zeta_k.$$

取期望并对 k 求平均, 即得式 (4-23)。进一步代入式 (4-19) 便得到有限期控制。

□

证明: [引理 6.7 的证明] 归一化方向映射是将 g/ϑ 投影至闭单位球, 故具有 ϑ^{-1} -Lipschitz 性。再由 Π_Θ 非扩张和式 (2-17),

$$\begin{aligned} \sup_{\theta \in \Theta} \|Q_{k+1}(\theta) - Q_k(\theta)\|_2 &\leq \sup_{\theta \in \Theta} \|\mathbf{d}(g_{k+1}(\theta)) - \mathbf{d}(g_k(\theta))\|_2 \\ &\leq \frac{\delta_k^g}{\vartheta}. \end{aligned}$$

若 $\theta \in S_k$, 则 $Q_k(\theta) = 0$ 。对第 $k+1$ 期应用式 (4-22), 得到

$$\text{dist}(\theta, S_{k+1}) \leq \kappa \|Q_{k+1}(\theta)\|_2 \leq \frac{\kappa \delta_k^g}{\vartheta}.$$

对 $\theta \in S_k$ 取上确界, 得到单向 Hausdorff 界。交换 k 与 $k+1$, 由于统一梯度差异界对称, 得到反向界; 取两者较大值, 即是式 (6-32)。□

证明: [推论 4.3 的证明] 在式 (4-19) 中, 端点项为 $O(K^{-1})$, 而 $\mathbb{E}\mathcal{V}_K = o(K)$ 使目标变化项在除以 K 后趋于零。由于 $C_{\text{var}}(n, p_{\text{act}}, b)$ 固定, 假设中的 Cesàro 条件给出

$$\frac{1}{K} \sum_{k=1}^K \left(\frac{C_{\text{var}}(n, p_{\text{act}}, b)}{M_k} + \mathbb{E}\beta_k^2 \right) \rightarrow 0.$$

故 $\mathcal{E}_K \rightarrow 0$ 。由式 (4-21) 得到动态局部遗憾结论; 若局部误差界 (4-22) 成立, 再由式 (4-23) 得到驻点集合的结论。□

半合成环境中的目标变化。 令 c_k^{ret} 收集半合成收益规律在第 k 期的系数。E3 中期初账户状态的变化满足

$$|\log X_{t_{k+1}} - \log X_{t_k}| + |r_{k+1} - r_k| + \|\omega_{t_{k+1}-1} - \omega_{t_k-1}\|_1 = O(\varpi_k), \quad \varpi_k = k^{-3/4},$$

而 c_k^{ret} 只在市场阶段边界及有限的过渡区间内变化, 因此 $\sum_k \|c_{k+1}^{\text{ret}} - c_k^{\text{ret}}\| < \infty$ 。若冻结目标在紧分析域上对这些期初输入一致 Lipschitz, 则存在有限常数 $L_{\text{acct}}, L_{\text{ret}}$, 使

$$\begin{aligned} \sup_{\theta \in \Theta} |J_{k+1}(\theta, r_{k+1}) - J_k(\theta, r_k)| &\leq L_{\text{acct}} (|\log X_{t_{k+1}} - \log X_{t_k}| + |r_{k+1} - r_k| \\ &\quad + \|\omega_{t_{k+1}-1} - \omega_{t_k-1}\|_1) + L_{\text{ret}} \|c_{k+1}^{\text{ret}} - c_k^{\text{ret}}\|. \end{aligned}$$

在这一正则性条件下, $\mathcal{V}_K = O(\sum_{k < K} \varpi_k) + O(1) = O(K^{1/4}) = o(K)$ 。该半合成构造的训练与执行使用同一条件因子块和收益规律, 因此总体层面的模拟梯度差异项为零。

第五节 固定维度极小极大速率的证明

证明: 上下界采用相同的完整轨迹查询接口与期望轨迹预算。下界通过 $\mathfrak{C}$ 中一个两点子模型构造: 两模型的 CPT 梯度相距 $B^{-1/2}$ 阶, 而停止后的查询记录在总变差距离下仍难以区分。上界则由定理 4.2 中的无偏、有限方差且有限期

望成本的输出给出。

第一步：可由 CPT 投资轨迹实现的单股票子模型。 考虑一只风险股票和现金，取 $h = 1$ ，交易成本为零，期初财富与参考点均为一。前期组合全部持有现金，可行性映射取恒等映射。风险股票的特征为 $\mathbb{R}^d$ 中的第一标准基向量 e_1 ，现金特征为零。在查询点 θ 下，潜在风险资产权重满足

$$U \sim \text{Beta}(e^{\theta^{[1]}}, 1),$$

其中 $\theta^{[1]}$ 是参数的第一坐标。经式 (2-7) 的惯性映射后，执行的风险资产权重为 χU 。

令风险收益 $R = R_* \xi$ ，其中 $R_* > 0$ 固定且足够小， $\xi \sim \text{Bernoulli}(p)$ 与 U 独立。期末财富与参考点为

$$X_{\text{end}} = 1 + \chi R_* U \xi, \quad r_{\text{end}} = 1 + \eta_+ \chi R_* U \xi,$$

故期末相对结果为

$$Y = v U \xi, \quad v = (1 - \eta_+) \chi R_* > 0. \quad (6-33)$$

这是定义 4.1 下可行的投资轨迹模型，其损失侧价值恒为零。

第二步：CPT 梯度的局部分离。 令 $v = v_+$ ，并定义

$$\mathbf{m}(t) = v v'(vt), \quad 0 \leq t \leq 1.$$

平移幂函数满足 $\mathbf{m}(0) = 0$ ， $\mathbf{m}(t) > 0$ 对 $t \in (0, 1]$ 成立，且 $\mathbf{m}$ 有界。由 $\mathbb{P}(U > t) = 1 - t^{e^{\theta^{[1]}}}$ ，在收益侧 CPT 积分中作变量替换 $y = v(vt)$ ，得到

$$J_p(\theta) = \int_0^1 \mathbf{m}(t) w_+^\varepsilon \left(p \{1 - t^{e^{\theta^{[1]}}}\} \right) dt. \quad (6-34)$$

在目标点 $\theta_0 = 0$ 附近的紧邻域中， $t^{e^{\theta^{[1]}}} |\log t|$ 在 $(0, 1)$ 上有可积包络，且 $(w_+^\varepsilon)'$ 有界，故可交换求导与积分。因此

$$\nabla J_p(0) = \mathbf{g}(p) e_1, \quad \mathbf{g}(p) = p \int_0^1 \mathbf{m}(t) (w_+^\varepsilon)'(p(1-t)) (-t \log t) dt. \quad (6-35)$$

记

$$A_v = \int_0^1 \mathbf{m}(t) (-t \log t) dt > 0, \quad c_{w,0} = (w_+^\varepsilon)'(0) > 0.$$

由于 $|(w_+^\varepsilon)''| \leq C_2$, 对式 (6-35) 关于 p 求导, 可得

$$\begin{aligned} \mathbf{g}'(p) &= \int_0^1 \mathbf{m}(t)(-t \log t) [(w_+^\varepsilon)'(p(1-t)) + p(1-t)(w_+^\varepsilon)''(p(1-t))] dt \\ &\geq (c_{w,0} - 2C_2 p) A_v. \end{aligned}$$

取充分小的 $p_* > 0$, 使

$$\mathcal{I} = [p_*/2, 3p_*/2] \subset (0, 1/2], \quad 3C_2 p_* \leq c_{w,0}/2, \quad c_* = c_{w,0} A_v/2.$$

于是

$$\mathbf{g}'(p) \geq c_* > 0 \quad \text{对所有 } p \in \mathcal{I}. \quad (6-36)$$

第三步：自适应停止查询记录中的信息量。 当 B 足够大时, 取

$$p_{\pm} = p_* \pm \delta, \quad \delta = \delta_*/\sqrt{B},$$

并选择 $\delta_* > 0$ 使 $p_{\pm} \in \mathcal{I}$ 。对固定内部区间 $\mathcal{I}$ 上的伯努利分布, 存在只依赖 $\mathcal{I}$ 的有限常数 C_I 。由基本界 $\text{kl}(p\|q) \leq (p-q)^2/\{q(1-q)\}$,

$$\text{kl}(p_+ \| p_-) \leq C_I \delta^2. \quad (6-37)$$

考虑式 (4-16) 中的任意可行估计器。分别以 $\mathbb{P}_+^{\text{tr}}$ 、 $\mathbb{P}_-^{\text{tr}}$ 表示两个模型下停止后的查询记录分布。每次查询位置可以依赖此前记录, 但在给定任意查询点后, 两模型的潜在 Dirichlet 动作分布完全相同; 只有伯努利收益核不同。算法自身的随机化也可纳入查询记录, 并在两模型之间保持相同。数据决定的查询次数 T_{call} 是查询记录滤过下的停止时刻。停止似然比的链式法则给出

$$\text{KL}(\mathbb{P}_+^{\text{tr}} \| \mathbb{P}_-^{\text{tr}}) = \mathbb{E}_+ T_{\text{call}} \text{kl}(p_+ \| p_-) \leq B C_I \delta^2 = C_I \delta_*^2. \quad (6-38)$$

上式等号可通过在事件 $\{T_{\text{call}} \geq j\}$ 上逐次求和条件对数似然增量得到; 该事件在第 j 次新收益观测前可测。由于 $p_{\pm}$ 处于紧的内部区间且 $\mathbb{E}_+ T_{\text{call}} < \infty$, 这些增量一致可积。

选取足够小的 δ_* , 使 $C_I \delta_*^2 \leq 1/8$ 。由 Pinsker 不等式,

$$\text{TV}(\mathbb{P}_+^{\text{tr}}, \mathbb{P}_-^{\text{tr}}) \leq \frac{1}{4}. \quad (6-39)$$

第四步：将估计问题化为检验问题。 由式 (6-36) 及均值定理, 两个梯度目标的

距离满足

$$\text{Sep}_B := \|\mathbf{g}(p_+)e_1 - \mathbf{g}(p_-)e_1\|_2 \geq 2c_*\delta. \quad (6-40)$$

给定任意估计量 $\hat{g}$ ，以其更靠近的目标定义一次二元检验。若检验错误，则估计量距真实目标至少为 $\text{Sep}_B/2$ 。两个检验错误概率之和至少为一减去总变差距离，故

$$\begin{aligned} \max_{s \in \{+, -\}} \mathbb{E}_s \|\hat{g} - \mathbf{g}(p_s)e_1\|_2^2 &\geq \frac{(\text{Sep}_B)^2}{8} \{1 - \text{TV}(\mathbb{P}_+^{\text{tr}}, \mathbb{P}_-^{\text{tr}})\} \\ &\geq \frac{3c_*^2\delta_*^2}{8B}. \end{aligned}$$

两模型均属于 $\mathfrak{C}$ ，对所有可行程序取下确界，即得到式 (4-17) 的下界，其中 $c_{\text{lb}} = 3c_*^2\delta_*^2/8$ 。

第五步：匹配预算的上界。 固定定理 4.2 中任意可行的估计器设计 (n, p_{act}, b) 。

定义 4.1 中的共同模型类常数使

$$\sup_{P \in \mathfrak{C}} \text{tr Cov}_P(Z_n^{\text{db}}) \leq C_{\text{var}}(n, p_{\text{act}}, b) < \infty, \quad C_{\text{cost}} = n(1 + p_{\text{act}}\Upsilon_b) < \infty$$

对所有 $P \in \mathfrak{C}$ 一致成立。取

$$M = \left\lfloor \frac{B}{C_{\text{cost}}} \right\rfloor,$$

在 θ_0 处独立运行 M 次未截断去偏估计，并求平均。其完整轨迹的总期望数为 $MC_{\text{cost}} \leq B$ ，故该程序可行。当 $B \geq 2C_{\text{cost}}$ 时， $M \geq B/(2C_{\text{cost}})$ ，因此

$$\sup_{P \in \mathfrak{C}} \mathbb{E}_P \|\hat{g}_{M,n}^{\text{db}} - g_P\|_2^2 \leq \frac{C_{\text{var}}(n, p_{\text{act}}, b)}{M} \leq \frac{2C_{\text{var}}(n, p_{\text{act}}, b)C_{\text{cost}}}{B}.$$

于是式 (4-17) 的上界成立，可取 $C_{\text{ub}} = 2C_{\text{var}}(n, p_{\text{act}}, b)C_{\text{cost}}$ 及充分大的 B_0 。上下界针对相同的目标、轨迹查询接口、损失函数和期望原始轨迹预算，定理得证。 $\square$

致谢

个人简历