



学校代码: 10272

学 号: 2025213357

上海财经大学

SHANGHAI UNIVERSITY OF FINANCE AND ECONOMICS

硕 士 学 位 论 文

MASTER DISSERTATION

(专 业 硕 士)

论文题目: 基于动态参考点的 CPT-PG 在线
策略优化

培养院系: 统计与数据科学学院

论文类别: 应用统计硕士专业学位论文

论文作者: 董祉含

指导教师: 张智恒

完成日期: 2026 年 6 月

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品成果。对本人的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

论文作者签名：

日期： 年 月 日

学位论文版权使用授权书

(硕士学位论文用)

本人完全了解上海财经大学关于收集、保存、使用学位论文的规定，即：按照有关要求提交学位论文的印刷本和电子版本。上海财经大学有权保留并向国家有关部门或机构送交本论文的复印件和扫描件，允许论文被查阅和借阅。本人授权上海财经大学可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

论文作者签名：

导师签名：

日期： 年 月 日

日期： 年 月 日

摘要

投资者对随机结果的评价受到历史盈利、亏损及回撤经历的影响。累积前景理论通过参考依赖、价值变换与概率权重刻画这种评价，但当参考点沿投资路径适应、市场规律与期初状态持续变化时，策略需要面对一系列时变的非凸目标。本文研究动态参考点下的累积前景策略梯度方法，建立从轨迹结果定义、梯度估计到在线一阶残差控制的分析框架。

本文构造包含股票、现金和交易成本的非平稳有限时域投资模型，以固定初始财富为单位记录账户价值。策略参数在每个时期内保持不变，各候选轨迹沿自身财富路径递推非对称参考点，终端财富与该轨迹终端参考点之差形成 CPT 评价的随机结果。模型允许市场转移规律在时期内部与时期之间变化；梯度计算则固定期初信息与当期拟合的模拟模型。策略采用指数 Dirichlet 因子参数化，随机采样用于学习，分布均值用于账户执行。

针对经验生存概率代入非线性权重导数时产生的偏差，本文构造内外层独立的多层去偏梯度估计器。完整内层样本及其两个半样本共享同一条外层轨迹与得分，以抵消一阶近似误差。在有界特征、紧参数域及固定正则化条件下，本文推导 Dirichlet 得分矩与似然支配条件，建立 CPT 梯度恒等式和目标光滑性，进而证明未截断的随机层估计器对冻结模拟梯度无偏，且具有有限方差与有限期望轨迹成本。有限截断、重复抽样与模拟偏差分别进入均方误差界；固定时期的独立重复还满足相应的中心极限定理。

在线算法采用带正阈值的梯度归一化及参数投影。通过单步上升不等式和跨期目标的望远镜展开，本文将平均投影残差平方控制在由初始目标范围、累计目标变化与平均梯度估计均方误差共同决定的上界内，并得到窗口残差形式的动态局部遗憾界。参考点隔离耦合进一步给出显式的参考点变化项；在附加统一误差界下，残差控制可转换为到移动一阶驻点集合的平均距离界。另在固定维度、精确轨迹观测与期望调用预算下，本文证明梯度估计具有预算倒数阶

的匹配极小极大界。

受控数值实验检验了路径依赖、层间误差抵消及完整在线更新。8192 次截断估计器输出的分组结果显示，完整重复数从 1 增至 64 时，经验均方误差由 9.572×10^{-2} 降至 1.824×10^{-3} 。在此基础上，本文设计半合成市场、真实数据回放及行为对照实验，比较参考机制与风险目标对策略响应和投资结果的影响。研究为动态参考依赖的策略学习提供了明确的统计误差分解与在线分析依据。

关键词： 动态参考点；累积前景理论；策略梯度；去偏估计；非平稳在线优化

Abstract

Investors evaluate uncertain outcomes in light of earlier gains, losses, and drawdowns. Cumulative prospect theory (CPT) captures reference-dependent evaluation, but adaptive references and changing market conditions lead to a sequence of nonconvex policy objectives. This thesis develops dynamic-reference CPT policy gradients through a joint analysis of trajectory outcomes, gradient estimation, and online first-order residuals.

The finite-horizon portfolio model includes stocks, cash, and transaction costs. Wealth is normalized by the fixed initial account value. Each candidate trajectory updates its own asymmetric reference and contributes terminal wealth minus its terminal reference to the CPT outcome distribution. Market kernels may vary within and between episodes. Differentiation fixes the initial context and the fitted simulation model. An exponential Dirichlet factor policy uses random allocations for learning and mean allocations for execution.

To address bias from empirical survival probabilities inside nonlinear weight derivatives, an antithetic multilevel estimator couples a full inner sample with its two halves using the same independent outer trajectory and score. Bounded features and compact parameter domains yield the score moments and likelihood domination needed for the CPT gradient identity and smoothness. Randomized precision levels give an estimator that is unbiased for the frozen simulation gradient, with finite variance and finite expected trajectory cost. Replication variance, finite-level truncation, and simulation error enter separate mean squared error terms. Independent replications at a fixed episode admit a central limit theorem.

Thresholded gradient normalization and parameter projection yield an average constrained-residual bound governed by objective variation and direction

error. The bound also controls a windowed dynamic local regret. Reference-isolated coupling identifies an explicit reference component of variation, while an additional uniform error bound converts residual control into average distance to moving stationary sets. A separate exact-oracle analysis establishes a matching inverse-budget minimax rate for gradient estimation at fixed dimension.

Controlled computations examine path dependence, multilevel error cancellation, and a complete online replay. Grouping 8192 truncated outputs into averages of 1 to 64 replications reduces empirical mean squared error from 9.572×10^{-2} to 1.824×10^{-3} . Further experiments are planned to evaluate policy responses and investment outcomes in semi-synthetic markets, historical replay, and behavioral comparisons. The framework provides explicit statistical and online foundations for learning with adaptive reference-dependent objectives.

Keywords: Dynamic reference points; Cumulative prospect theory; Policy gradients; Debiased estimation; Nonstationary online optimization

目 录

摘要	I
Abstract	III
第一章 引言	1
1.1 研究背景	1
1.2 文献综述	3
1.2.1 累积前景理论与强化学习	3
1.2.2 参考点适应性变化	4
1.2.3 非平稳环境中的非凸在线优化	4
1.2.4 非线性估计的去偏与统计精度	5
1.2.5 因子投资与连续组合策略	5
1.3 研究框架	6
1.4 研究贡献	7
1.5 结构安排	7
第二章 问题设定与假设	9
2.1 非平稳有限时域投资组合马尔可夫决策过程	9
2.2 非对称动态参考点	11
2.3 正则化累积前景目标	12
2.4 移动驻点集合与动态局部遗憾	13
2.5 分析假设	15
第三章 算法设计	20
3.1 投资组合单纯形上的 Dirichlet 策略	20
3.2 去偏 CPT 策略梯度更新	22
3.3 组合案例中的连续运行流程	25

第四章 主要结论与理论分析	27
4.1 参考点递推的路径依赖与敏感性	27
4.2 CPT 策略梯度恒等式	28
4.3 有限样本方差与渐近分布	31
4.4 动态局部遗憾	32
4.5 极小极大下界	35
第五章 实验设计与结果分析	37
5.1 参考点机制与路径依赖	37
5.2 梯度估计的偏差、方差与成本	38
5.2.1 可解析模型与层级误差	38
5.2.2 独立重复平均与成本校准	39
5.2.3 等预算比较与预期检验	40
5.3 合成非平稳市场中的在线跟踪	41
5.3.1 环境与算法设置	41
5.3.2 分阶段跟踪与评价方法	42
5.4 半合成 A 股市场回放设计	42
5.4.1 数据组织与市场机制	42
5.4.2 比较方法与共同控制	44
5.4.3 优化表现、财富表现与共同评价	44
5.4.4 消融、敏感性与研究预期	45
5.5 异质投资者的评估设计	46
5.5.1 历史路径与策略响应	46
5.5.2 出售行为与投资者评价	46
5.6 优化性质与投资评价的联系	47
第六章 结论与讨论	48
6.1 研究结论	48

6.2 适用范围与研究局限	49
6.3 进一步研究方向	49
参考文献	51
附录	53
附录 1 主要符号与记号约定	53
附录 2 参考点机制的证明	54
附录 2.1 命题 4.1 的证明	54
附录 3 CPT 梯度与估计量的证明	55
附录 3.1 定理 4.1 的证明	55
附录 3.2 命题 4.2 的证明	58
附录 3.3 定理 4.2 的证明	60
附录 3.4 定理 4.3 的证明	61
附录 4 驻点集合漂移与动态局部遗憾的证明	61
附录 4.1 引理 4.1 的证明	61
附录 4.2 投影上升不等式	62
附录 4.3 定理 4.4 的证明	63
附录 4.4 推论 4.1 的证明	64
附录 4.5 推论 4.2 的证明	64
附录 5 极小极大下界的证明	65
附录 5.1 定理 4.5 的证明	65
附录 6 实验复现细节	68
附录 6.1 多项式权重诊断中的解析偏差	68
附录 6.2 有限样本统计量的精确积分	69
附录 6.3 独立数值梯度检验	69
附录 6.4 回放步长的适用区域	70
附录 6.5 数值精度	70

致谢	71
个人简历	72

第一章 引言

第一节 研究背景

强化学习（Reinforcement Learning, RL）为序贯决策问题提供了一套通用的优化框架：智能体通过与环境交互收集反馈信号，逐步调整策略以最大化累积奖励的期望值。在标准 RL 范式中，策略通常以预先指定的奖励期望作为评价准则。这一框架在工程控制、游戏博弈等领域已取得显著成功。然而，当智能体的决策需要与人类交互、为人类提供建议或模拟人类行为时，如何使奖励目标反映人的风险评价，成为需要进一步处理的问题。

根据行为经济学，人类在不确定性条件下的决策会系统性地偏离期望效用理论的预测。Kahneman 和 Tversky 提出的前景理论及其后续扩展累积前景理论（Cumulative Prospect Theory, CPT），刻画了风险决策中的三个重要心理特征^[1,2]。其一为参考点依赖：决策者根据结果相对于心理参考点的变化进行评价，高于参考点的部分被视为收益，低于参考点的部分被视为损失。其二为损失厌恶：在幅度相近时，损失通常具有更强的心理影响；经典参数化中常用的损失厌恶系数为 2.25，该数值是一种经验校准设定。其三为概率权重扭曲：决策者对结果概率的主观加权具有非线性，可能高估小概率事件，并低估部分中高概率事件。经典 CPT 通过收益域凹、损失域凸的价值函数及非线性概率权重函数，将这些特征纳入同一分布评价框架。本文在此基础上规定适合梯度分析的固定平滑形式，并在后文说明平滑所改变的函数性质。

近年来，CPT 已从对决策结果的评价进入强化学习的策略优化。相关研究通过轨迹分布估计和策略梯度，将概率权重与参考依赖纳入可计算的学习过程^[3,4]。这一方法也被用于人类风险态度和多智能体交互行为的建模^[5,6]。随着评价准则进入连续决策，心理比较基准在学习期间是否保持固定，成为连接行为模型与策略优化的关键问题。

现有 CPT 策略梯度分析中的一个重要基准情形，是在给定环境与参考水平

下优化同一个目标。在真实投资过程中,评价结果的心理基准可能随着盈利、亏损和回撤经历而移动。Arkes 等通过证券交易实验直接度量了参考点的适应幅度,发现盈利后的适应大于同等幅度亏损后的适应^[7];其后续跨文化研究进一步考察了美国、中国和韩国样本中的这一现象^[8]。这些证据提示,参考点的动态变化应当作为模型中的显式状态加以描述。

He 和 Yang 在包含实现效用的动态交易模型中研究非对称适应,说明参考点变化可以影响出售盈利资产和亏损资产的相对倾向^[9]。Qin 等进一步研究路径依赖参考点,将投资历史纳入实现效用与交易决策的建模^[10]。在这类问题中,即使两位投资者最终拥有相同财富,其历史经历也可能使当前评价不同。这为本文在轨迹内部递推参考点提供了行为动机。

考虑一个现实场景示例:某投资者初始财富为 1000 元。路径 A 为先涨后跌,财富升至 1400 元后回落至 1200 元;路径 B 为先跌后涨,财富跌至 800 元后回升至 1200 元。两条路径具有相同的起点和终点,却可能形成不同的比较基准。以本文采用的递推规则为例,初始参考点为 1000 元,盈利方向适应率为 0.4,亏损方向适应率为 0.1,则两条路径最终的参考点分别为 1176 元和 1068 元。对应的相对结果分别为 24 元和 132 元。这里两条路径均被评价为盈利,但盈利的感知幅度明显不同;是否跨入损失域,取决于适应速度及具体历史。将初始财富归一化为 1 后,这一例子与后文的目标定义完全一致。

上述场景引出了三个相互联系的困难。首先,参考点沿每条候选轨迹递推,终端财富与参考点共同决定 CPT 的输入。其次,市场分布和当期起始状态也随时间变化,使策略需要持续适应一系列条件目标。最后,CPT 的分布评价与策略参数化共同产生一般非凸的优化问题,有限样本又使策略梯度只能通过估计得到。为此,本文研究动态参考点下的在线 CPT 策略优化:先明确当期究竟优化哪个随机结果的 CPT,再构造误差可控的梯度估计,进而分析策略与当期一阶驻点条件之间的关系。

第二节 文献综述

1.2.1 累积前景理论与强化学习

在 CPT-RL 研究中, Prashanth 等较早研究了 CPT 目标下的预测和控制, 指出目标估计需要掌握随机结果的分布, 并据此设计经验分布估计与同时扰动随机逼近控制算法^[3]。这说明 CPT 进入强化学习后, 结果分布的估计与策略学习需要共同处理。Jie 等进一步讨论 CPT 框架下的随机优化^[11]。与普通期望回报相比, 概率扭曲使样本的贡献取决于其在整体结果分布中的位置, 因此不能只给每条轨迹附加一个与总体分布无关的固定奖励。

Lepel 和 Barakat 推导了 CPT 目标下的策略梯度, 并提出基于顺序统计量的蒙特卡洛估计方法^[4]。其核心思路是利用采样轨迹估计分布相关的 CPT 权重, 再结合轨迹得分函数形成策略梯度。本文同样以 CPT 作为策略优化目标, 并通过轨迹采样进行学习。在这一基础上, 本文进一步处理轨迹内动态参考点、连续 Dirichlet 策略的似然正则性, 以及经验生存概率代入非线性权重导数时产生的有限样本偏差。研究重点由给定目标下的梯度优化, 延伸至带有估计误差和目标漂移的在线过程。

更近期的研究开始把 CPT 引入自主系统、多智能体强化学习和博弈场景。Ramasubramanian 等强调人类风险态度对于行为学习的重要性, 将 CPT 用于描述偏离期望评价的决策方式^[5]。Lalmohammed 等提出 CPT-MADDPG, 在竞争追逐、协作覆盖和一价拍卖等任务中研究 CPT 对交互行为的影响, 并在拍卖任务中考察过度竞价现象^[6]。这些工作说明 CPT 可以成为智能体风险行为的建模工具, 也提示行为有效性需要落实到具体任务和可观测决策。

本文关注的差别在于, 投资历史既改变财富, 也改变此后评价财富的参考水平。固定参考水平下得到的策略梯度结果提供了必要基础, 但轨迹内递推、跨期目标变化及其对误差传播的影响, 需要单独进入数学定义与证明。与此同时, 模型内 CPT 改善和真实投资者满意度具有不同的观测要求; 这一差别决定了本文在理论验证、市场回放和行为评估中采用分层实验设计。

1.2.2 参考点适应性变化

参考点会随决策者的经历而移动。Arkes 等通过递进的证券交易实验考察了适应的幅度与方向^[7]。在其中一项实验中，一只以 30 美元买入的股票涨至 36 美元后，被试平均认为价格还需涨至 40.24 美元，才会获得与第一次上涨相当的满足；由此推算的参考点上调幅度为 4.24 美元。股票跌至 24 美元后，对应的等量痛苦价格为 21.49 美元，推算的下调幅度为 2.51 美元。研究还在投资组合情境及带有经济激励的设计中考察了这一非对称性。后续跨文化研究将相关问题扩展至美国、中国和韩国样本^[8]。这些结果为区分盈利与亏损方向的适应率提供了经验依据，具体数值仍依赖实验情境和测量方法。

He 和 Yang 将非对称参考点适应引入动态交易问题^[9]。在其模型中，参考点根据买入成本和此后的财富水平调整，投资者同时评价终端财富及交易实现的盈亏。该研究分析了适应性参考点对交易时机的影响，发现相较于不适应的情形，投资者更不愿意实现损失，并由此形成较高的盈利实现比例和较低的亏损实现比例。其重要启示在于，处置效应需要结合参考点、价值评价和出售机制共同分析。本文吸收盈利与亏损适应速度可不同的建模思想，采用逐日递推的参考点；具体递推公式与该文的交易模型分别定义。

Kong、Qin 和 Yue 研究了路径依赖参考点下的实现效用问题^[10]。参考点包含历史信息，使终点相同的路径仍可能具有不同的经济评价。这一思路为本文的路径对照实验提供了依据：先固定终端财富，只改变到达该终点的经历，再考察参考点、相对结果和策略响应。本文的有限维递推将历史压缩进当前参考点状态；它保留了由递推生成的历史依赖，同时便于与有限时域轨迹和策略梯度结合。

1.2.3 非平稳环境中的非凸在线优化

在时变非凸问题中，目标的全局最大化点通常难以直接求得。局部遗憾研究因而使用一阶信息评价在线过程。Hazan 等先对最近若干期目标函数作平均，再在当前参数处计算投影梯度，由此定义窗口局部遗憾^[12]。Aydore 等面向在线

预测，将历史目标的梯度分别保留在各期自身参数处，再进行时间加权并累计平方范数^[13]。Hallak 等进一步研究时变非凸复合目标下的近端更新与遗憾界^[14]。这些准则围绕不同的一阶条件展开，评价位置、约束处理及时间权重共同决定其优化含义。

本文首先控制每一期在自身参数处的真实投影残差平方，再构造窗口加权的动态局部遗憾。这样，逐期残差对应当前优化问题的一阶条件，窗口诊断反映近期方向的综合变化。目标变化预算进入单步上升关系的跨期求和，采样与模拟误差进入梯度估计均方误差项。若进一步具有统一误差界，便可把残差控制转化为到移动一阶驻点集合的平均距离控制。这条分析路线使估计精度、环境变化与跟踪含义具有可追溯的联系。

1.2.4 非线性估计的去偏与统计精度

随机化望远镜求和为消除有限精度近似的偏差提供了工具。Rhee 和 Glynn 研究了有限期望成本下的无偏估计构造^[15]；Goda 和 Kitade 将相关方法用于条件随机优化中的无偏梯度估计^[16]。这些方法的有效性依赖相邻精度层之间的误差衰减速度，以及实现高精度样本所需的计算成本。

本文将这一思想用于 CPT 梯度中的经验生存概率。完整内层样本及其两个半样本共享同一条外层轨迹和得分，使一阶误差在层间差分中抵消。由具体统计量的二阶余项得到层差矩界后，才能选择兼顾方差与期望成本的随机层概率。进一步利用独立重复的中心极限定理^[17]和两点检验方法^[18]，分别讨论固定时期的渐近分布与轨迹预算下的极小极大精度。统计分析因而始终围绕实际可采样的组合轨迹展开。

1.2.5 因子投资与连续组合策略

投资组合理论和因子模型为资产配置及信息表示提供了基础^[19,20]。André 和 Coqueret 将公司特征与 Dirichlet 策略结合，推导策略梯度并用于因子组合学习^[21]。这一表示适合非负、权重和为一的组合：学习参数表达对因子的重视程度，资产的具体权重则由因子取值和策略分布共同决定。

本文采用指数浓度映射，使资产得分对应严格为正的 Dirichlet 参数。学习层采样组合以估计轨迹分布，执行层取分布均值形成确定的组合配置。由于 Dirichlet 得分含有权重的对数，权重接近零时会出现较大的样本得分。本文通过有界特征、紧参数域及有限时域推导所需矩条件，并据此衔接 CPT 梯度分析。这一处理同时保留连续组合策略的表达与似然估计的数学依据。

第三节 研究框架

本文研究的核心问题是：当市场规律、投资状态和参考点共同变化时，如何构造可实施的 CPT 策略学习方法，并量化其对当期受约束一阶条件的逼近程度？研究围绕问题定义、梯度估计与在线优化展开。

首先，以股票与现金组成的投资组合为场景，规定财富、交易成本和非对称参考点的逐日递推。每个时期包含 h 个决策步，时期内参数保持固定，每条随机轨迹独立演化财富与参考点。其终端归一化财富减去自身终端参考点，构成当前 CPT 评价的随机结果。给定期初信息后，市场分布可以在有限时域内部变化；下一时期的新信息则改变后续条件目标。

其次，以 Dirichlet 因子策略描述连续动作，在似然比恒等式下构造内外层独立的 CPT 梯度统计量。通过完整样本与半样本的耦合，再对精度层随机化，得到具有明确偏差、方差和成本性质的估计器。该过程把“根据分布评价投资结果”转化为“根据采样方向调整因子权重”的计算步骤。

最后，以当期梯度估计的归一化方向更新参数，并将参数投影回给定紧凸域。理论分析先建立平均投影残差界，再得到窗口形式的动态局部遗憾界；在附加误差界下，进一步说明到移动驻点集合的平均距离。数值实验依次检验参考点递推、估计器统计性质和在线过程，并设计动态、对称、静态参考点及两种期望效用基线的市场比较。行为实验用于考察路径依赖及出售行为是否随参考机制变化，从而补充优化指标无法直接回答的经济解释。

第四节 研究贡献

本文的理论贡献体现在三个相互衔接的方面。第一，建立包含逐路径非对称参考点递推的条件 CPT 目标，并给出参考点扰动到目标值及梯度的定量敏感性界。在隔离参考点的耦合条件下，该界进一步形成在线目标变化预算中的显式参考点项，使历史适应机制与后续跟踪分析相连接。

第二，从指数 Dirichlet 策略的原始条件出发推导似然正则性，构造多层去偏 CPT 梯度估计器。未截断构造对冻结模拟目标具有精确无偏性、有限方差与有限期望轨迹成本；有限层级、重复样本量和模拟误差则共同给出可用于算法选择的均方误差界。固定维度与精确轨迹信息下的匹配极小极大界，进一步说明所达到的预算倒数阶统计精度。

第三，对归一化投影更新建立包含目标变化与梯度估计误差的在线残差上界，并据此给出动态局部遗憾与固定目标极限结论。在统一残差误差界成立时，所得控制可转换为移动一阶驻点集合的平均距离界。理论因此同时说明非平稳条件下可以控制的对象，以及采样精度和环境变化对该控制的影响。

实际价值在于，将参考点适应这一行为机制落实为可计算的目标、可解释的因子参数和可复现的策略更新。财富与参考点采用统一单位，模型能够在相同期末财富、不同历史经历下比较风险评价及后续配置。拟开展的市场与行为实验将考察这种参考依赖能否在交易成本、收益和风险之间形成有意义的权衡，并通过独立数据测量投资者的适应参数与建议采纳情况。理论给出的误差分解也为应用提供了计算依据：可以分别考察增加采样投入和改善市场模型带来的精度变化。

第五节 结构安排

全文由六章及证明附录组成。第一章介绍研究背景，梳理 CPT 强化学习、参考点适应、非凸在线优化及去偏估计等相关研究，明确研究问题与贡献。第二章建立非平稳有限时域投资模型，定义目标、一阶残差与动态局部遗憾，并说明各项假设的作用和可检验范围。第三章介绍 Dirichlet 因子策略、多层梯度估计

器及在线更新，以连续投资案例说明执行与学习的衔接。

第四章给出参考点敏感性、梯度恒等式、有限样本误差、在线残差及统计精度结论，并解释主要证明思路。第五章报告已有的受控数值验证，提出非平稳市场比较、消融、敏感性及行为评估的实验设计，说明各实验要回答的问题。第六章总结研究结论与适用范围，讨论进一步的数据校准与理论拓展。附录集中列出符号表、完整定理证明和数值复现细节。

第二章 问题设定与假设

投资者的连续决策构成一系列有限时域优化问题。每期开始时，已观测的市场信息、财富、持仓和参考点构成当前情境；在这一情境下，给定策略产生一组可能的未来投资路径。本文以这些路径终端相对结果的分布定义条件 CPT 目标，并用投影残差衡量策略对当期一阶最优性条件的满足程度。市场与投资状态的变化由此进入同一在线优化问题。

第一节 非平稳有限时域投资组合马尔可夫决策过程

将一次有限时域决策称为一个时期 (episode)，编号为 $k = 1, \dots, K$ ，每个时期包含固定的 $h \geq 1$ 个决策步。第一个时期从 $t_1 = 1$ 开始，此后满足 $t_{k+1} = t_k + h$ 。本文用 u 表示日历年时点；实验中的上涨、震荡等市场阶段可以跨越多个时期，也可以在时期内部切换。一个时期内部的状态和投资组合动作分别写为

$$s_u = (m_u, X_u, r_u, \omega_{u-1}), \quad \omega_u \in \Delta_N := \{\omega \in \mathbb{R}_+^{N+1} : \sum_{i=0}^N \omega_i = 1\}.$$

其中， m_u 包含市场因子， X_u 表示账户财富与固定初始财富之比， r_u 是采用相同归一化单位表示的参考点，资产 0 表示现金。令现金收益率 $R_{0,u+1} = 0$ ，交易成本系数 $c_{tc} \geq 0$ ，则财富递推为

$$X_{u+1} = X_u (1 + \omega_u^\top R_{u+1} - c_{tc} \|\omega_u - \omega_{u-1}\|_1), \quad X_1 = 1. \quad (2-1)$$

式中， $\omega_u^\top R_{u+1}$ 是该期组合收益， $\|\omega_u - \omega_{u-1}\|_1$ 衡量相邻两期组合权重的变动。市场模型包含条件收益与状态转移核，该转移核可以随时期 k 以及时期内时点变化。在给定状态和动作后，转移核不直接依赖策略参数。所有随机变量和条件转移核均可测，状态空间与动作空间均为标准 Borel 空间。初始参考点非负。允许的收益与交易成本应使式 (2-1) 中的财富总增长因子严格为正，并满足后文给出的有界分析域。

在时期 k 开始时，信息集 $\mathcal{F}_k$ 包含已经观测到的历史、当前参数、初始状态

以及已经拟合的模拟器。记

$$z_k = (m_{t_k}, X_{t_k}, \omega_{t_k-1}).$$

本文仅将 $r_k := r_{t_k}$ 用作时期起点参考点的简写；按日历时间记录的参考点仍使用下标 u 或明确日期 $t_k + j$ 。对 $0 \leq j \leq h$ ，定义时期内记号 $r_{k,j} := r_{t_k+j}$ 与 $X_{k,j} := X_{t_k+j}$ 。因此， $r_k = r_{k,0}$ ，且 $r_{k+1} = r_{k,h}$ 。真实目标与模拟目标分别为

$$J_k(\theta, r_k) = J(P_k, z_k, r_k; \theta), \quad \tilde{J}_k(\theta, r_k) = J(\tilde{P}_k, z_k, r_k; \theta). \quad (2-2)$$

全文对 $J_k(\theta, r_k)$ 和 $\tilde{J}_k(\theta, r_k)$ 求梯度时，只对 θ 求导，并固定 r_k 与 z_k 。学习样本生成前，模拟器和初始状态也保持冻结。下文所有条件期望均表示在这些信息给定时的正则条件期望。 θ_k 、 M_k 以及选定的截断层级均为 $\mathcal{F}_k$ 可测。新时期可以纳入新观测数据重新拟合模拟器，但时期 k 的模拟器一旦冻结，在该时期采样期间便不再改变。这样的条件化处理明确区分了时期之间的信息更新与时期内部的梯度采样。

冻结模拟器意味着在本期学习采样中保持拟合规则与参数不变。该规则仍可包含不同日期的转移核、预先给定的市场阶段以及状态依赖的收益分布。因此，有限时域内部允许非平稳变化；模拟器与真实过程之间的差异由后文的模拟梯度误差刻画。

目标的跨期变化有不同来源。外生非平稳指市场收益分布或条件转移规律本身随日历时间变化，例如市场冲击使同一状态和动作下的收益规律发生改变。另一方面，过去的配置决定已实现财富和持仓，财富经历又决定参考点；这些内生形成的起始信息通过 z_k, r_k 改变当期条件目标。这些状态由此前的策略与市场实现共同生成，使目标变化具有内生来源。即使市场转移规律保持不变，从不同财富、持仓或参考点出发，也可能面对不同的条件目标。将财富和参考点纳入状态后，固定的递推规则仍可构成时间齐次的状态转移。因此，状态随路径演化与转移核本身随时间变化需要分别判断，二者对目标的共同影响由后文的变化预算记录。

第二节 非对称动态参考点

参考点表示投资者评价财富时使用的比较水平。例如，账户价值从初始 100 万元增长到 120 万元时，归一化财富为 1.2；若经历上涨后形成的参考点为 1.15，则当前相对结果为 0.05。该量始终以初始财富为单位，保留了此前财富积累与参考适应的共同影响。现金与股票都属于总账户，现金收益设为零，现金比例仍会改变财富分布和未来风险。

固定 $\eta_+, \eta_- \in [0, 1]$ ，定义参考点更新映射

$$\Phi(r, x) = \begin{cases} (1 - \eta_+)r + \eta_+x, & x \geq r, \\ (1 - \eta_-)r + \eta_-x, & x < r. \end{cases} \quad r_{u+1} = \Phi(r_u, X_{u+1}). \quad (2-3)$$

一种常见的行为设定是 $\eta_+ > \eta_-$ ，即参考点在财富高于原参考点时调整得更快。这一设定与盈利后适应较快的行为动机一致^[7]。本文将两侧适应率作为给定的模型参数，优化定理适用于所声明区间内的取值；个体参数的校准属于行为实验的测量内容。

每条模拟轨迹都必须沿自身的财富序列递归生成对应参考点，并据此定义时期末相对结果

$$Y_k(\tau) = X_{k,h}(\tau) - r_{k,h}(\tau), \quad (2-4)$$

其中， $X_{k,h}(\tau) = X_{t_k+h}(\tau)$ 与 $r_{k,h}(\tau) = r_{t_k+h}(\tau)$ 分别是轨迹 τ 的期末财富和期末参考点。每条轨迹均从已保存的时期 k 起点信息初始化。式 (2-1) 中的 $X_1 = 1$ 只适用于整个实验的最初时点，后续时期继承上一时期结束时的财富。若将真实执行路径上观测到的同一个期末参考点用于所有模拟轨迹，模拟轨迹的相对结果会随之改变，进而定义出另一个目标函数。

下文将 Y_k 统一称为终端相对结果，其单位与归一化财富相同。整个账户自实验开始的累计收益率为归一化财富减 1，而 Y_k 减去的是随路径变化的参考点，两者分别用于投资表现与 CPT 评价。动态参考点包括对称适应和非对称适应：前者使用相同的两侧适应率，后者允许二者不同。静态参考点则在执行路径和所有模拟路径中均令 $\eta_+ = \eta_- = 0$ 。动态描述递推机制，即使某一步财富恰好等

于参考点，该机制仍属于动态设定。

第三节 正则化累积前景目标

一条轨迹提供一个终端相对结果，多条可能轨迹共同定义一个随机变量。CPT 对这一随机变量的分布进行评价：先计算每个结果在收益侧或损失侧的效用幅度，再考察超过各效用水平的概率，最后分别加权累积两侧贡献。这样，收益大小与其出现机会共同影响目标。有限样本实现中的排序用于表示经验分布，属于总体目标的估计步骤。

记 $y^+ = \max(y, 0)$ 、 $y^- = \max(-y, 0)$ 。固定 $\varepsilon_v > 0$ ，对 $x \geq 0$ 定义

$$u_{\alpha, \varepsilon_v}(x) = (x^2 + \varepsilon_v^2)^{\alpha/2} - \varepsilon_v^\alpha, \quad v_+(y) = u_{\alpha_+, \varepsilon_v}(y^+), \quad v_-(y) = \lambda u_{\alpha_-, \varepsilon_v}(y^-), \quad (2-5)$$

其中 $0 < \alpha_+, \alpha_- \leq 1$ ， $\lambda > 1$ 。收益侧与损失侧的效用幅度在零点均为零，并且作为 y 的函数在包括零点在内的定义域上连续可微；本文不要求它们关于 y 具有全局二阶导数。两侧的全局 Lipschitz 常数可以分别取为

$$L_v^+ = \alpha_+ \varepsilon_v^{\alpha_+ - 1}, \quad L_v^- = \lambda \alpha_- \varepsilon_v^{\alpha_- - 1}. \quad (2-6)$$

这里的平滑是价值函数设定的一部分，会影响所有正效用幅度。经典幂价值函数在收益侧的凹性与损失侧的凸性，也不能直接沿用到这一平滑形式：在零点附近，平滑后的收益侧变换具有局部凸性，对应的带符号损失侧具有局部凹性。本文使用的是式 (2-5) 明确定义的正则化模型，后续证明依赖其可微性、Lipschitz 性及分析域内的效用界。固定平滑参数时所得结论均针对这一目标；逼近未平滑 CPT 的极限还需要单独分析。

给定严格递增且归一化分母为正的基础权重函数 $w_\pm$ ，定义

$$w_\pm^\varepsilon(p) = \frac{w_\pm(\varepsilon + (1 - 2\varepsilon)p) - w_\pm(\varepsilon)}{w_\pm(1 - \varepsilon) - w_\pm(\varepsilon)}, \quad 0 < \varepsilon < \frac{1}{2}. \quad (2-7)$$

本文的行为设定采用 Tversky 与 Kahneman 提出的函数族

$$w_\pm(p) = \frac{p^{\beta_\pm}}{\{p^{\beta_\pm} + (1 - p)^{\beta_\pm}\}^{1/\beta_\pm}},$$

并选择参数，使权重函数在正则化区间上递增。理论结果同样适用于满足上述条件的其他基础权重函数；受控数值验证采用 $w(p) = p^3$ 。由归一化定义可得

$w_{\pm}^{\varepsilon}(0) = 0$ 和 $w_{\pm}^{\varepsilon}(1) = 1$ 。所有价值参数与权重参数在不同样本量和多层层级之间保持固定。当收益侧与损失侧采用不同权重函数时，归一化可能改变两侧的相对尺度，这种尺度变化属于模型设定本身。

在真实轨迹分布或模拟轨迹分布下，记收益侧与损失侧效用超过阈值的尾概率（即生存函数）为

$$S_{k,\theta}^{\pm}(z) = \mathbb{P}_{k,\theta}\{v_{\pm}(Y_k) > z\}.$$

若 $0 \leq v_{\pm}(Y_k) \leq B_v$ ，则对应的时期目标为

$$J_k(\theta, r_k) = \int_0^{B_v} w_{+}^{\varepsilon}(S_{k,\theta}^{+}(z)) dz - \int_0^{B_v} w_{-}^{\varepsilon}(S_{k,\theta}^{-}(z)) dz. \quad (2-8)$$

模拟分布下的生存概率相应定义 $\tilde{J}_k$ 。全文统一采用严格不等式定义生存概率，因此允许效用分布存在原子，也允许样本出现并列值。特别地， $|J_k|, |\tilde{J}_k| \leq B_J := B_v$ 。对一条固定轨迹而言，其效用泛函不显式依赖 θ ；策略参数只通过轨迹的概率分布影响目标。

第四节 移动驻点集合与动态局部遗憾

在第 k 期，数学优化问题是对 $\theta \in \Theta$ 最大化 $J_k(\theta, r_k)$ 。策略在这一期内保持同一组参数，下一期则面对新的条件目标。一般非凸目标的全局最大点难以直接求得，本文先考察可行参数扰动是否还具有一阶改进空间。若参数位于边界，即使原始梯度不为零，其指向也可能全部被约束排除，因此评价时需要同时考虑目标梯度和参数域。

记 $g_k = \nabla J_k(\theta_k, r_k)$ 、 $\tilde{g}_k = \nabla \tilde{J}_k(\theta_k, r_k)$ 。固定 $a_0 > 0$ 和 $\gamma > 0$ ，定义归一化方向映射与归一化投影残差映射，后者在下文简称投影残差：

$$d(g) = \frac{g}{\max\{\|g\|_2, a_0\}}, \quad Q_k(\theta) = \frac{\Pi_{\Theta}(\theta + \gamma d(\nabla J_k(\theta, r_k))) - \theta}{\gamma}. \quad (2-9)$$

其中，阈值 a_0 与现金资产对应的 Dirichlet 浓度参数 $a_{0,u}$ 是两个不同对象。受约束的一阶驻点集合定义为

$$S_k = \{\theta \in \Theta : \langle \nabla J_k(\theta, r_k), u - \theta \rangle \leq 0 \text{ for every } u \in \Theta\} = \{\theta \in \Theta : Q_k(\theta) = 0\}. \quad (2-10)$$

上述两个集合相等，可由投影变分不等式以及梯度的正比例缩放得到。连续目标函数在紧集 Θ 上能够取得最大值，其最大化点满足该一阶条件，因此 S_k 非空。 Q_k 的连续性进一步保证 S_k 为闭集。该集合也可能包含鞍点和非全局驻点，所以后续结论针对受约束一阶驻点，而不把它们统一解释为全局最优解。

梯度范数平方 $\|g_k\|_2^2$ 衡量目标关于参数的一阶敏感程度，投影残差平方 $\|Q_k(\theta_k)\|_2^2$ 还包含方向归一化与参数约束的作用。若候选更新点位于 Θ 内，投影不改变该点，此时 $Q_k(\theta_k) = g_k / \max\{\|g_k\|_2, a_0\}$ ；再满足 $\|g_k\|_2 \leq a_0$ 时，才有 $\|Q_k(\theta_k)\|_2^2 = \|g_k\|_2^2 / a_0^2$ 。因此，比较两类曲线时必须保留归一化阈值和触边信息。梯度估计 $\hat{g}_k$ 的范数平方还含有采样误差，其时间曲线需要与总体梯度的性质分开解释。

本文使用的主要评价准则是逐时期真实投影残差平方的平均值

$$\mathcal{E}_K = \frac{1}{K} \sum_{k=1}^K \mathbb{E} \|Q_k(\theta_k)\|_2^2. \quad (2-11)$$

进一步参考 Aydore 等在各期自身参数处加权历史梯度的思路^[13]，固定窗口长度 $w \geq 1$ 、衰减系数 $0 < \rho \leq 1$ ，并令 $A_k = \sum_{j=0}^{\min(w-1, k-1)} \rho^j$ ，定义加权窗口诊断量

$$\bar{Q}_k = A_k^{-1} \sum_{j=0}^{\min(w-1, k-1)} \rho^j Q_{k-j}(\theta_{k-j}), \quad (2-12)$$

据此定义投影残差形式的动态局部遗憾，下文未作特别说明时均指这一量：

$$\mathcal{R}_{\rho, w}^Q(K) = \sum_{k=1}^K \|\bar{Q}_k\|_2^2. \quad (2-13)$$

相较于 Aydore 等的定义，式 (2-13) 作了两项明确调整。其一，将无约束梯度替换为与本文归一化投影更新相对应的 Q_k ；其二，在最初不足 w 期时，只对已经出现的时期按 A_k 归一化。原文使用完整窗口的固定权重和，并把初始缺少的历史项设为零；两种归一化在窗口填满后相同。这些调整保留了在历史自身参数处评价的思路，其上界由第 4 章单独建立。

计算式 (2-13) 时，先对近期残差向量加权平均，再取范数平方，最后对所有时期累加。直接把各期梯度范数平方相加，会得到另一个累计一阶指标；先对范

数平方做滑动平均, 也会失去向量之间的方向信息。只有窗口宽度为 1 时, 动态局部遗憾才退化为逐期投影残差平方的累计和。不同时期的向量可能抵消, 故较小的窗口量需要结合式 (2-11) 共同判断。

通常的动态遗憾累计的是各期目标值与该期比较策略目标值之间的差额; 取逐期最优策略为比较对象时, 对应最优值差额。本文采用的一阶局部准则与这种目标值差额具有不同含义, 到驻点集合的参数距离则另由假设 2.5 联系起来。式 (2-13) 本身是随机累计量, 理论上界对其取期望; 实验中除以已经运行的时期数得到平均动态局部遗憾。所谓次线性增长, 是指 $\mathbb{E}\mathcal{R}_{\rho,w}^Q(K) = o(K)$, 也就是该期望累计量除以 K 后趋于零。这一增长性质表示单位时期的累计一阶偏离趋于零。

Q_k 使用真实目标梯度定义, 含噪参数更新产生的实际位移则取决于梯度估计。比较同一目标下的估计器时, 固定 a_0 、 γ 、 Θ 和目标设定; 比较动态、静态参考点或不同效用方法时, 目标本身随方法改变, 残差数值须结合各自目标尺度解释。

第五节 分析假设

梯度估计与在线跟踪依赖不同层次的正则性。首先, 有界分析域和似然条件保证 CPT 梯度存在, 固定正则化控制有限样本估计中的非线性余项。其次, 目标变化与模拟误差决定在线上界中的时变项和统计项。参考点敏感性、驻点距离及极小极大精度则分别引入额外的耦合、几何和观测条件。

以下各常数对所分析的时期、参数以及真实模型和模拟模型一致成立。关于 $K \rightarrow \infty$ 的陈述还要求这些常数对所有 K 保持统一。模型定义和解析界用于确立这些条件, 有限样本诊断用于考察实际运行是否接近相应边界。

假设 2.1 (有界定义域与似然正则性): 参数集 $\Theta \subset \mathbb{R}^d$ 非空、紧且凸, 并包含于一个定义策略的开参数邻域。特征可测, 不显式依赖 θ , 且满足 $\|q_{i,u}\|_2 \leq Q_f$ 。时域长度和资产数量均有限且固定。初始状态以及所分析的全部真实轨迹和模拟轨迹满足统一界 $0 < X_u \leq B_X$ 、 $0 \leq r_u \leq B_r$ 与 $0 \leq v_{\pm}(Y_k) \leq B_v$ 。似然计算

使用 Θ 的一个有界开邻域 O ，其闭包包含于参数定义域。求导时固定初始信息，并且轨迹分布对 θ 的唯一显式依赖来自式 (3-2) 的 *Dirichlet* 动作密度；条件市场转移核与参数无关。引理 6.1 从这些原始条件出发，证明轨迹积分下两次求导的可积支配条件以及一致的固定阶得分矩。将其中的得分二阶矩界与对数似然 *Hessian* 的期望界分别记为 $C_{G,2}$ 和 C_H 。二者是推导得到的有限常数，并非得分函数的逐点上界。

该条件为似然比求导与可积性提供依据。参数集紧性和特征有界性可以从定义直接检查，财富界与价值界则来自给定市场模型、有界定义域或经过分析的停止规则。样本得分矩能够显示极端权重对数值计算的影响，总体矩界仍由后文的似然分析建立。若实际模型超出这一分析域，使用梯度恒等式与有限方差结论需要重新验证支配条件；有限回放所得到的界还须考察其对总时长的依赖。

假设 2.2 (固定的正则化 CPT): 归一化权重函数递增且属于 $C^3([0, 1])$ ，并满足

$$C_j := \max_{\pm} \sup_{p \in [0, 1]} |(w_{\pm}^{\varepsilon})^{(j)}(p)| < \infty, \quad j = 1, 2, 3.$$

所有价值参数和权重参数保持固定。价值函数严格采用式 (2-5) 的形式，并使用其中固定的正数 ε_v 。定理 4.1 根据引理 6.1 推导出共同的目标梯度 *Lipschitz* 界 $L = 2B_v[C_2C_{G,2} + C_1(C_{G,2} + C_H)]$ 。因此，目标函数的光滑性来自原始似然条件。价值函数平滑用于获得关于参考点的线性敏感性，关于策略参数的求导则通过轨迹似然进行。

上述导数界用于证明 CPT 目标可微，并控制乘子 $f(p, I) = (w^{\varepsilon})'(p)(I - p)$ 的二阶余项。固定正则化区间上的端点值和各阶导数可以解析检查。实现时，不同层级必须使用相同的权重函数及其导数；数值 *Hessian* 检查只能作为诊断，不能代替统一光滑性证明。若正则化参数随样本量变化，目标本身也随之变化，后文针对同一固定目标的多层去偏推导便需要重新论证。端点处奇异且未经正则化的权重函数不属于该假设的范围。

假设 2.3 (分别刻画目标变化与模拟误差): 对 $k < K$ ，定义下列有限可测

量：

$$\delta_k^J = \sup_{\theta \in \Theta} |J_{k+1}(\theta, r_{k+1}) - J_k(\theta, r_k)|, \quad V_K = \sum_{k=1}^{K-1} \delta_k^J, \quad (2-14)$$

$$\delta_k^g = \sup_{\theta \in \Theta} \|\nabla J_{k+1}(\theta, r_{k+1}) - \nabla J_k(\theta, r_k)\|_2. \quad (2-15)$$

在被查询参数处，模拟误差满足

$$\|\tilde{g}_k - g_k\|_2 \leq \beta_k^{\text{sim}}, \quad (2-16)$$

其中 β_k^{sim} 为 $\mathcal{F}_k$ 可测。每个界中使用的期望均有限。除非在某个渐近陈述中另行明确规定，否则不预设这些量足够小或关于 K 次线性增长。

函数值变化用于望远镜求和，梯度变化用于驻点集合漂移，模拟偏差则进入梯度估计均方误差。在给定市场模型下，可以解析控制这些量；使用观测数据时，可以借助拟合模型差异和独立梯度估计对其进行估计，但这些估计也带有自身误差。若变化预算随 K 线性增长，或模拟误差持续存在，理论上界中可能保留不消失的项。时期内的真实变化由 P_k 描述，模拟器对这部分变化的遗漏通过 β_k^{sim} 评价。 β_k^{sim} 衡量同一期两个模型之间的差异， V_K 衡量真实条件目标的跨期差异。

假设 2.4 (参考点隔离耦合)：讨论参考点敏感性时，固定 P, z, θ ，只改变初始参考点，并要求策略特征与市场转移核不直接依赖该初始参考点或其后续递推值。因此，使用相同的策略随机数和市场随机数时，两条耦合轨迹具有相同的财富路径和投资组合路径。允许的初始参考点区间覆盖变化分解中使用的全部分解。

该条件允许在共享得分函数与财富路径的条件下，逐路径比较两条参考点递推。可以通过检查状态到特征的映射以及市场转移核来判断条件是否满足。例如，算法 3-1 所列因子可以不包含 r ，同时学习参数仍可通过 CPT 梯度对参考点作出响应。若特征使用 $X - r$ 或直接使用 r ，基本的估计器结论和残差定理仍然可用，但在没有新的联合耦合论证时，不再主张隔离参考点的敏感性结论及其显式变化分解成立。

假设 2.5 (残差误差界, 可选条件): 对式 (2-9) 中固定的 a_0, γ, Θ , 存在统一常数 $\kappa < \infty$, 使得

$$\text{dist}(\theta, S_k) \leq \kappa \|Q_k(\theta)\|_2, \quad \theta \in \Theta. \quad (2-17)$$

这一附加几何条件把小残差转换为参数到驻点集合的距离界。它必须来自给定目标函数的数学性质。采用多个初始点的局部搜索可以探查该条件, 但不能构成证明; 如果只在某个邻域内成立, 还需要证明迭代点与比较点始终位于该邻域。不具备该条件时, 主要残差界与估计器结果仍然有效, 只是不能进一步推出驻点集合距离界。例如, $-x^4$ 一类平坦目标在驻点附近可能不满足线性残差误差界。

假设 2.6 (统计模型类与精确轨迹信息): 固定 $d \geq 1$ 、内部目标参数 $\theta_0 = 0 \in \Theta$ 、有限上界 $\bar{h}, \bar{N} \geq 1$, 以及假设 2.1 和假设 2.2 中的共同常数。固定本文的平滑价值函数和归一化权重函数, 并要求 $(w_+^\varepsilon)'(0) > 0$ 。考虑条件投资组合模型类 $\mathfrak{C}$, 其中模型满足 $1 \leq h \leq \bar{h}$ 、 $1 \leq N \leq \bar{N}$ 以及上述共同界。时域长度、资产数量、特征、参考点参数和起始信息均已知, 市场分布未知。选取的常数应覆盖附录 5 在固定市场概率区间内构造的单期模型; 在该子模型中, 参考点适应率、收益幅度和起始财富也均为已知量。

关于未知市场分布的全部信息均来自精确预言机。算法可以在任意选定的 $\theta \in \Theta$ 处调用预言机, 每次调用返回该策略下的一条全新完整轨迹。在给定查询参数与模型条件下, 不同调用相互独立。估计器可以自适应选择查询参数, 可以使用与模型无关的随机化, 并可以在其观测历史对应的停止时刻 N_{call} 停止, 但必须满足

$$\sup_{P \in \mathfrak{C}} \mathbb{E}_P N_{\text{call}} \leq B.$$

模型不提供关于未知市场分布的免费观测、已知市场分布参数, 或包含额外未知分布观测的拟合模型辅助信息。估计目标是共同欧氏参数坐标下的 $g_P = \nabla J_P(\theta_0)$ 。当 $B \rightarrow \infty$ 时, 维度与全部定义域常数保持固定。

该假设确定了极小极大分析的观测实验。每条完整轨迹计为一次调用, 未

知市场分布的信息通过这些调用逐步获得；模型类和维度固定，使不同估计程序能够在同一期望预算下比较。权重函数的正端点斜率可以直接检查，并使后文两点子模型中的 CPT 梯度具有局部可识别性。端点斜率为零时，估计上界仍成立，下界则需要另行构造可识别的子模型。使用拟合模拟器、额外市场观测、确定性预算或增长维度，会改变这里的观测条件和比较范围，需要相应的统计分析。

前两项假设支撑梯度与估计器结果。目标变化和模拟精度进入在线优化界。参考点隔离条件与残差误差界分别用于敏感性结论和驻点集合距离结论。精确预言机假设只用于极小极大定理。这样的分工使每项结论依赖的前提保持清楚，也避免把理想化统计实验与实际拟合模拟器的误差混在同一条件中。

第三章 算法设计

上一章确定了每期需要优化的条件目标。本章依次回答三个计算问题：如何把因子参数转化为组合，如何从有限轨迹得到梯度方向，以及如何把该方向用于下一时期。算法 3-1 负责生成动作，算法 3-3 负责一次梯度统计量的计算，算法 3-2 负责串联执行、估计和参数更新。三个层次共享同一套财富与参考点定义。

第一节 投资组合单纯形上的 Dirichlet 策略

对资产 $i = 0, \dots, N$ ，使用有界特征 $q_{i,u}$ 表示策略在时点 u 可获得的资产信息。特征可以包括动量、反转、波动率、价值因子、现金指示变量与上一期持仓。本文不要求每个应用都使用完全相同的特征集合，但假设 2.1 要求实际采用的特征满足统一有界性。定义线性得分、Dirichlet 浓度参数及浓度总和为

$$z_{i,u} = \theta^\top q_{i,u}, \quad a_{i,u} = e^{z_{i,u}}, \quad a_{\Sigma,u} = \sum_{i=0}^N a_{i,u}, \quad (3-1)$$

并令随机投资组合服从

$$\omega_u \sim \pi_\theta(\cdot \mid s_u) = \text{Dirichlet}(a_{0,u}, \dots, a_{N,u}). \quad (3-2)$$

指数映射保证每个浓度参数严格为正，因此从该分布产生的权重位于投资组合单纯形内部。实际执行时使用确定性的策略均值

$$\bar{\omega}_{i,u} = a_{i,u} / a_{\Sigma,u}. \quad (3-3)$$

这一区分使真实账户执行路径由明确的均值组合产生，同时使学习层能够从随机策略分布抽取轨迹。均值执行的目标值与随机策略的 CPT 目标值通常不是同一对象，后续分析针对后者建立梯度估计。

以一只股票和现金为例，若两项资产的得分分别为 $\log 2$ 与 0 ，则浓度分别为 2 与 1 ，均值组合中的股票权重为 $2/3$ 、现金权重为 $1/3$ 。采样模式每次从同一分布生成不同组合，其均值仍为上述比例。只有各资产浓度相同时，均值配置才表现为等权。学习过程中，参数改变各因子的重要性；同一因子在不同股票上的取值不同，因此同一组参数能够产生不同的资产得分。现金指示特征则使模

算法 3-1: 用于生成投资组合的 Dirichlet 因子策略

Require: 状态 s_u , 因子 $q_{i,u}$, 参数 θ , 以及模式 $e \in \{\text{sample}, \text{mean}\}$ 。

```

1: for  $i = 0, \dots, N$  do
2:   计算  $z_{i,u} = \theta^\top q_{i,u}$  与  $a_{i,u} = \exp(z_{i,u})$ 。
3: end for
4: if  $e = \text{sample}$  then
5:   抽取  $\omega_u \sim \text{Dirichlet}(a_{0,u}, \dots, a_{N,u})$ 。
6:   记录式 (3-4) 中用于学习的得分贡献。
7: else
8:   令  $\bar{\omega}_{i,u} = a_{i,u} / \sum_{j=0}^N a_{j,u}$ , 并置  $\omega_u = \bar{\omega}_u$ 。
9: end if
10: return  $\omega_u \in \Delta_N$ 。

```

型能够区分保留预算与承担股票风险。

记 ψ_0 为双伽马函数。时期 k 内一条完整轨迹的得分函数为

$$G_{k,\theta}(\tau) = \sum_{u=t_k}^{t_k+h-1} \sum_{i=0}^N a_{i,u} q_{i,u} \{\log \omega_{i,u} - \psi_0(a_{i,u}) + \psi_0(a_{\Sigma,u})\}. \quad (3-4)$$

该式等于轨迹对数似然关于 θ 的梯度，并且在开单纯形上几乎处处有定义。它与资产线性得分 $z_{i,u}$ 含义不同：资产得分用于形成浓度，轨迹得分函数衡量路径概率对参数的敏感程度，CPT 策略梯度再由轨迹得分与结果评价共同构成。由于权重可以任意接近零， $\log \omega_{i,u}$ 可以趋向负无穷，其绝对值没有逐样本统一上界。假设 2.1 下的紧浓度范围控制的是后续需要的固定阶矩，因而理论使用得分矩和似然支配条件。

算法 3-1 汇总了两种运行模式。采样模式产生用于学习的随机动作并记录得分贡献；均值模式产生真实执行层采用的确定性组合。两种模式使用同一套特征、参数和浓度映射，其差别只在于从分布采样还是取分布均值。

算法 3-2: 动态参考点 CPT 策略梯度算法 (DRCPT-PG)

Require: $\theta_1 \in \Theta$, $X_1 = 1$, $r_1 \geq 0$, 时域长度 h , 固定的 CPT 参数与参考点参数, 满足 $\gamma L \leq a_0$ 的 $a_0, \gamma > 0$, $N_0 \geq 1$, $1 < a < 2$, 重复次数 $M_k \geq 1$, 以及截断上限 $L_{k,\max} \in \{0, 1, \dots\} \cup \{\infty\}$ 。

- 1: 初始化 $\omega_0 = (1, 0, \dots, 0)$ 。
- 2: **for** $k = 1, \dots, K$ **do**
- 3: 记录 z_k, r_k, θ_k , 并且只使用 $\mathcal{F}_k$ 中的信息冻结 $\tilde{P}_k$ 。
- 4: **执行层:** 对 $u = t_k, \dots, t_k + h - 1$, 以均值模式运行算法 3-1, 再根据式 (2-1) 和式 (2-3) 更新财富与参考点。
- 5: 令 $r_{k+1} = r_{t_k+h}$, 保存观测到的下一时期信息。
- 6: **学习层:** 从已保存的时期起点信息和 $\tilde{P}_k$ 出发, 以截断上限 $L_{k,\max}$ 独立运行算法 3-3 共 M_k 次。
- 7: 对输出求平均: $\hat{g}_k^{\text{db}} = M_k^{-1} \sum_{b=1}^{M_k} Z_{k,b}^{\text{db},(L_{k,\max})}$ 。
- 8: 归一化方向 $d_k = \hat{g}_k^{\text{db}} / \max\{\|\hat{g}_k^{\text{db}}\|_2, a_0\}$ 。
- 9: 更新 $\theta_{k+1} = \Pi_{\Theta}(\theta_k + \gamma d_k)$ 。
- 10: 转入已保存的下一时期信息, 并为时期 $k+1$ 重新拟合模拟器。
- 11: **end for**
- 12: **return** 投资组合、财富与参考点路径、参数和诊断量。

第二节 去偏 CPT 策略梯度更新

算法将真实执行与策略学习分成两个层次。执行层使用策略均值生成观测到的投资组合路径, 并由这条路径形成下一时期的财富、参考点和持仓信息。学习层则返回已经保存的时期起点, 从该起点出发按随机策略采样, 并优化 $J_k(\theta, r_k)$ 或其模拟目标。由于均值执行路径与随机学习轨迹服从不同的分布, 二者的 CPT 值一般不同, 不能用执行层单条路径的结果替代学习层目标。

M_k 与 $L_{k,\max}$ 均为 $\mathcal{F}_k$ 可测。由于执行层和学习层都使用已经保存的时期起点信息, 且学习所用分布在时期内保持冻结, 所以学习计算可以在执行前完成,

也可以与执行并行进行。在线分析中，将实际方向估计器简记为 $\hat{g}_k = \hat{g}_k^{\text{db}}$ 。因此，算法实际实施的参数更新为

$$\theta_{k+1} = \Pi_{\Theta} \left(\theta_k + \gamma \frac{\hat{g}_k}{\max\{\|\hat{g}_k\|_2, a_0\}} \right). \quad (3-5)$$

分母中的 a_0 避免在估计梯度很小时将其强制归一化为单位方向，外层投影则保证更新后的参数仍属于 Θ 。该更新不使用历史梯度平滑。式 (2-13) 中的窗口只用于事后诊断；若在更新方向中加入过往梯度，还需要另行控制这些滞后梯度相对于当前 g_k 的均方误差。

这一更新保留了方向信息，并限制一次参数调整的尺度。当估计梯度的范数超过 a_0 时，归一化后方向的长度为 1；低于该阈值时，方向长度随估计梯度减小，因而在接近一阶驻点时允许较小更新。投影处理作用于因子参数 θ ，Dirichlet 分布则负责组合权重的非负性与归一化。两者在算法中各自承担明确的任务。

下面给出去偏估计器的一次重复。所有采样定义均以 $\mathcal{F}_k, \theta_k$ 为条件，并使用冻结的模拟分布。暂时省略重复编号 b ，将一次带截断的输出记为 $Z^{\text{db},(L_{\max})}$ ，无截断时记为 $Z = Z^{\text{db},(\infty)}$ 。首先独立抽取一条外层轨迹 $\tau^{(0)}$ ，由其得到轨迹得分 G_0 以及指标函数 $I_0^{\pm}(z) = \mathbf{1}\{v_{\pm}(Y(\tau^{(0)})) > z\}$ 。再独立抽取内层轨迹 $\tau^{(1)}, \dots, \tau^{(n)}$ ，定义经验生存概率与非线性乘子

$$\hat{S}_n^{\pm}(z) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{v_{\pm}(Y(\tau^{(i)})) > z\}, \quad f_{\pm}(p, I) = (w_{\pm}^{\varepsilon})'(p)(I - p). \quad (3-6)$$

由同一条外层轨迹与一组内层轨迹构造

$$T_k^{(n)} = G_0 \left[\int_0^{B_v} f_+(\hat{S}_n^+(z), I_0^+(z)) dz - \int_0^{B_v} f_-(\hat{S}_n^-(z), I_0^-(z)) dz \right]. \quad (3-7)$$

式中，内层样本估计生存概率，外层样本提供指标函数和似然得分；两层样本彼此独立。令 $n_{\ell} = N_0 2^{\ell}$ ，并将 $T_k^{(n_{\ell})}$ 简记为 $T_{k,\ell}$ 。当 $\ell \geq 1$ 时，将同一组内层样本分为前后两个等大的半样本，分别形成两个低一层统计量。完整样本统计量和两个半样本统计量使用完全相同的外层轨迹与外层得分，构造多层估计中的 antithetic coupling^[16]。本文按其具体计算方式称为全样本与半样本耦合，差分定义为

$$\Delta_{k,0} = T_{k,0}, \quad \Delta_{k,\ell} = T_{k,\ell} - \frac{1}{2}(T_{k,\ell-1}^{(1)} + T_{k,\ell-1}^{(2)}). \quad (3-8)$$

算法 3-3: 一次多层去偏 CPT 梯度重复

Require: 冻结的时期起点信息与模型, θ_k , $N_0 \geq 1$, $1 < a < 2$, 截断上

限 $L_{\max} \in \{0, 1, \dots\} \cup \{\infty\}$ 。

1: 对 $\ell = 0, 1, \dots$, 令 $p_\ell = (1 - 2^{-a})2^{-a\ell}$ 。

2: **if** $L_{\max} < \infty$ **then**

3: 对 $0 \leq \ell \leq L_{\max}$, 令 $q_\ell = p_\ell / \sum_{j=0}^{L_{\max}} p_j$ 。

4: **else**

5: 对每个 $\ell \geq 0$, 令 $q_\ell = p_\ell$ 。

6: **end if**

7: 相互独立地抽取 $\mathcal{L} \sim q$ 、一条外层轨迹以及 $N_0 2^\mathcal{L}$ 条内层轨迹。

8: 使用外层得分 G_0 , 根据式 (3-7) 计算 $T_{k,\mathcal{L}}$ 。

9: **if** $\mathcal{L} = 0$ **then**

10: 令 $\Delta_{k,0} = T_{k,0}$ 。

11: **else**

12: 将内层样本等分为两半; 计算 $T_{k,\mathcal{L}-1}^{(1)}$ 与 $T_{k,\mathcal{L}-1}^{(2)}$ 时, 复用完全相同的外层结果与得分。

13: 令 $\Delta_{k,\mathcal{L}} = T_{k,\mathcal{L}} - \frac{1}{2}(T_{k,\mathcal{L}-1}^{(1)} + T_{k,\mathcal{L}-1}^{(2)})$ 。

14: **end if**

15: **return** $Z_k^{\text{db},(L_{\max})} = \Delta_{k,\mathcal{L}}/q_\mathcal{L}$, 以及成本 $1 + N_0 2^\mathcal{L}$ 。

两个半样本统计量共享外层样本, 因此在无条件意义下相互依赖; 在给定该外层样本后, 两个内层半样本相互独立。这一共享结构用于抵消经验生存概率代入非线性权重导数时的一阶误差, 不能用两条独立重抽的外层轨迹替换。

算法 3-3 先按几何衰减概率选择一个层级, 再只计算该层级的重加权差分。有限截断时, q_ℓ 是 p_ℓ 在 0 至 $L_{\max}$ 上重新归一化后的概率; 无截断时直接使用 p_ℓ 。一次重复的原始轨迹调用包括一条外层轨迹与 $N_0 2^\mathcal{L}$ 条内层轨迹, 因此成本严格记为 $1 + N_0 2^\mathcal{L}$ 。算法 3-2 在同一时期独立重复这一过程 M_k 次, 然后对输

出求平均。

式 (3-7) 中的积分可以通过排序内层和外层效用值，对由此形成的阶梯函数精确求和。排序后的相邻效用值给出区间长度，区间内的经验尾概率与指标保持常数；因此，排序与经验尾概率在此描述同一个统计量的计算过程。本文固定式 (2-7) 的正则化函数，各层均使用这一函数及其导数。计算过程中保留共享外层得分结构，并按所有效用断点求和，不再增加依赖 n 的秩下限或额外求积近似。

作为比较，代入估计器 $\hat{g}_{n,m}^{\text{pl}}$ 使用一个大小为 n 的内层样本，以及与该内层样本独立的 m 条外层轨迹，并对式 (3-7) 的结果取平均。由于这 m 项共同使用同一组内层样本，它们并非完全相互独立；后续方差分析保留了这种依赖关系。

分拆与耦合分别解决不同的估计问题。内外层独立使经验概率可以在给定外层结果后单独分析；全样本与半样本共享外层结果，则使相邻精度之间形成有利的误差抵消。例如，若本次抽到的层级对应 8 条内层轨迹，就用这 8 条轨迹计算一次统计量，再分别用前 4 条和后 4 条计算两次统计量。三次计算评价同一条外层轨迹，只改变用于估计分布的样本规模。因此，额外计算重用已经生成的数据，无需再产生两条外层投资路径。随机层重加权把不同精度的修正量合并到一个具有正确期望的统计构造中。

第三节 组合案例中的连续运行流程

以初始资金为 100 万元的组合说明三个算法的衔接。将初始财富归一化为 $X_1 = 1$ ，初始持仓为全现金组合 $\omega_0 = (1, 0, \dots, 0)$ ，初始参考点为 $r_1 = 1$ ，每个时期包含 $h = 5$ 个交易日。在第 $k = 1$ 期的起点，系统保存市场因子、归一化财富、原持仓和参考点，并用当时可获得的信息冻结模拟器 $\tilde{P}_1$ 。以下示意场景按输入、执行、采样和更新的顺序说明状态如何连续传递。

真实执行层在第 1 至第 5 个交易日依次运行算法 3-1 的均值模式。每个交易日先根据当前资产特征计算 $z_{i,u}$ 和 $a_{i,u}$ ，再按式 (3-3) 输出现金与各风险资产的权重。市场收益实现后，账户先按式 (2-1) 扣除交易成本并更新财富，再按

式 (2-3) 更新该条真实路径上的参考点。五日结束时，实际观测得到的 $X_{1,5}$ 、 $r_{1,5}$ 和末日持仓共同进入下一时期信息，其中 $r_2 = r_{1,5}$ 。整个执行层只产生一条真实财富与参考点路径。

学习层始终从时期 1 已保存的起点出发，并使用冻结的 $\tilde{P}_1$ 。对于一次算法 3-3 重复，系统先抽取层级 $\mathcal{L}$ ，再独立生成一条外层轨迹与 $N_0 2^{\mathcal{L}}$ 条内层轨迹。每条模拟轨迹均以同一个起点财富、起点持仓和起点参考点初始化，但在五个交易日内分别采样自己的 Dirichlet 组合和市场结果，并沿自身财富路径递推参考点。因此，每条轨迹最终形成自己的 $X_{1,5}(\tau)$ 、 $r_{1,5}(\tau)$ 与 $Y_1(\tau)$ 。内层轨迹给出式 (3-6) 的经验生存概率，外层轨迹给出 I_0^+ 与 G_0 ，完整样本和两个半样本共同形成式 (3-8) 的多层差分。

在独立完成 M_1 次重复后，算法 3-2 将去偏输出平均为 $\hat{g}_1^{\text{db}}$ ，按阈值 a_0 归一化方向，并通过投影更新得到 θ_2 。进入第二时期时，策略参数改为 θ_2 ，真实账户从第一时期末保存的财富、参考点和持仓继续运行，模拟器则可以使用新增观测重新拟合后再次冻结。此后各时期重复同一流程。真实执行路径负责传递实际账户状态，模拟轨迹负责估计当前冻结目标的方向；两者共享时期起点信息，但模拟轨迹不会把各自的期末状态写入真实账户，也不会共用真实执行路径的期末参考点。

第四章 主要结论与理论分析

本章的结论沿着参考点、估计器和在线更新展开。参考点敏感性说明历史适应如何改变优化目标；梯度恒等式与多层误差界使这一目标具有可计算的更新方向；在线定理再把方向误差与跨期目标变化共同转化为一阶残差界。最后的极小极大结果讨论单期统计精度，为采样成本提供独立的比较尺度。正文陈述正式结论并解释证明思路，全部推导见附录 附录 2至附录 附录 5。

第一节 参考点递推的路径依赖与敏感性

定义 $\eta_{\min} = \min(\eta_+, \eta_-)$ 和 $\chi_h = (1 - \eta_{\min})^h$ 。下文使用的连续模为

$$\Omega(s) = (L_v^+ + L_v^-)s, \quad s \geq 0. \quad (4-1)$$

它满足 $|v_+(y) - v_+(y')| + |v_-(y) - v_-(y')| \leq \Omega(|y - y'|)$ 。进一步记 $D_h(s) = \Omega(\chi_h s)$ ，并以 $C_{G,2}$ 表示 $\mathbb{E}\|G\|_2^2$ 的一个共同上界。这里， χ_h 描述初始参考点差异经过 h 步递推后的收缩程度， Ω 则把相对结果的差异传递到收益侧与损失侧的价值变换。

命题 4.1 (相同期末财富、不同 CPT 输入与参考点敏感性): 设 $0 < L_w < r_0 < C < H$ 。考虑两条财富路径 $A: r_0 \rightarrow H \rightarrow C$ 与 $B: r_0 \rightarrow L_w \rightarrow C$ ，并假设 $C < (1 - \eta_+)r_0 + \eta_+H$ 且 $C > (1 - \eta_-)r_0 + \eta_-L_w$ 。则

$$r_A - r_B = \eta_+(1 - \eta_-)H - \eta_-(1 - \eta_+)L_w + (\eta_- - \eta_+)C. \quad (4-2)$$

若该差值不为零，则两条路径的终端相对结果不同。当每条路径均对应一个确定性结果时，在本文严格递增的带符号价值变换下，其 CPT 值也不同。

对于任意一条共同财富路径以及两个不同的初始参考点，有

$$|r_h - r'_h| \leq \chi_h |r_0 - r'_0|. \quad (4-3)$$

在假设 2.1、2.2 和 2.4 下，固定 P, z, θ ，对任意允许的 r, r' ，有

$$|J(P, z, r; \theta) - J(P, z, r'; \theta)| \leq C_1 D_h(|r - r'|), \quad (4-4)$$

$$\|\nabla J(P, z, r; \theta) - \nabla J(P, z, r'; \theta)\|_2 \leq \sqrt{C_{G,2}}(C_1 + C_2)D_h(|r - r'|). \quad (4-5)$$

以上结论对冻结模拟器同样成立。

命题中的第一部分直接刻画了路径依赖：两条路径具有相同的期末财富 C ，中间财富经历却使终端参考点不同。后两部分给出定量敏感性，说明初始参考点扰动如何依次影响终端参考点、CPT 值及其梯度。任意两个不同的随机结果分布未必对应不同的标量 CPT 值。严格收缩要求 $\eta_{\min} > 0$ ；当两个适应率都等于 1 时， Y 恒等于零，此时目标会改变并可能变得平坦，不能据此推断目标得到改善。

证明从同一财富输入下的参考点映射开始。两个参考点可能位于财富的不同侧，但分段仿射映射在连接处连续，各段斜率均不超过 $1 - \eta_{\min}$ ，因此初始差异经过 h 次递推后至多保留 χ_h 倍。价值函数的 Lipschitz 性把参考点差异转化为效用差异；对两条耦合轨迹的阈值指标求积分，恰好可以用效用幅度之差控制。最后结合权重导数界与共同得分的二阶矩界，得到目标值和梯度的敏感性。完整论证见附录 附录 2。

从投资场景理解，初始参考点的差别可以在共同经历下逐步缩小，但每期财富和市场状态仍会改变后续目标。命题定量描述了其中能够单独归因于参考点的部分，为在线变化预算提供输入。适应较快还会改变当期相对结果的尺度，故敏感性减小与投资表现改善需要分别评价。

第二节 CPT 策略梯度恒等式

定理 4.1 (正则化 CPT 策略梯度恒等式): 在假设 2.1 和 2.2 下，令

$$\begin{aligned} \psi_{k,\theta}(y) = & \int_0^{B_v} (w_+^\varepsilon)'(S_{k,\theta}^+(z))\{\mathbf{1}[v_+(y) > z] - S_{k,\theta}^+(z)\} dz \\ & - \int_0^{B_v} (w_-^\varepsilon)'(S_{k,\theta}^-(z))\{\mathbf{1}[v_-(y) > z] - S_{k,\theta}^-(z)\} dz. \end{aligned} \quad (4-6)$$

则

$$\nabla J_k(\theta, r_k) = \mathbb{E}_{k,\theta}[\psi_{k,\theta}(Y_k(\tau))G_{k,\theta}(\tau)]. \quad (4-7)$$

将其中的生存函数与期望替换为模拟模型对应的量, 可得到 $\nabla \tilde{J}_k$ 的同一恒等式。在真实模型与模拟模型中均有

$$\|\nabla J_k(\theta, r_k)\|_2 \leq B_g := 2B_v C_1 \sqrt{C_{G,2}}. \quad (4-8)$$

此外, J_k 和 $\tilde{J}_k$ 在 Θ 上的梯度均为 L -Lipschitz 连续, 其中

$$L = 2B_v \{C_2 C_{G,2} + C_1 (C_{G,2} + C_H)\}. \quad (4-9)$$

所需的似然界由引理 6.1 给出。

式 (4-7) 将 CPT 目标对策略参数的导数写成轨迹得分与分布权重乘子的期望。该结论使用假设 2.1 中的有界分析域、似然条件及固定概率权重函数的正则性, 参考点隔离耦合、时期漂移条件和残差误差界均未参与这一恒等式的推导。

证明的关键在于先对轨迹概率求导。固定期初信息后, 终端财富和参考点都是轨迹的函数; 即使市场核在时期内部变化, 参数仍只通过动作密度进入轨迹似然。引理 6.1 给出交换导数与期望所需的支配条件, 由此得到每个阈值处生存概率的导数。再对概率权重应用链式法则并对阈值积分, 得到 CPT 梯度。得分期望为零, 允许在指标函数中减去生存概率而保持总体梯度不变。对似然再求一次导数, 并控制权重的前两阶导数, 则得到目标梯度的共同 Lipschitz 常数。

式 (4-6) 中的乘子评价轨迹结果在分布中的贡献, 得分 $G_{k,\theta}$ 则描述该轨迹发生的概率如何随参数变化。二者的乘积将投资结果的评价传递为因子参数的更新方向。目标式 (2-8) 始终使用概率权重本身, 梯度恒等式中的导数由上述链式求导产生。

4.2.0.0.1 有限经验生存函数产生偏差的原因。式 (4-6) 中的理想乘子含有真实生存函数。若在非线性的 $(w^\epsilon)'$ 内部直接用经验生存函数替换真实生存函数, 其期望一般会发生改变。式 (3-7) 中的非线性乘子给出了这一代入偏差的具体来源, 下一命题据此建立偏差界与去偏构造。

命题 4.2 (代入偏差与去偏估计量): 在假设 2.1、2.2 以及算法 3-3 的抽样

构造下, 令

$$\begin{aligned} H_f &= C_3 + 2C_2, \quad A_b = \frac{B_v H_f \sqrt{C_{G,2}}}{4}, \quad A = \frac{A_b}{N_0}, \\ C_0 &= 4B_v^2 C_1^2 C_{G,2}, \quad D = \frac{3B_v^2 H_f^2 C_{G,2}}{16N_0^2}. \end{aligned}$$

在给定 $\mathcal{F}_k$ 的条件下,

$$\|\mathbb{E}T_k^{(n)} - \tilde{g}_k\|_2 \leq A_b/n, \quad (4-10)$$

$$\mathbb{E}\|\Delta_{k,0}\|_2^2 \leq C_0, \quad \mathbb{E}\|\Delta_{k,\ell}\|_2^2 \leq D2^{-2\ell} \quad (\ell \geq 1). \quad (4-11)$$

令 $r_a = 2^{-a}$ 、 $q_a = 2^{a-2}$, 并定义

$$C_{\text{db}} = \frac{C_0 + Dq_a/(1 - q_a)}{1 - r_a}, \quad C_{\text{cost}} = 1 + N_0 \frac{1 - r_a}{1 - 2r_a}. \quad (4-12)$$

当 $1 < a < 2$ 时, 未截断输出 $Z = \Delta_{k,\mathcal{L}}/p_{\mathcal{L}}$ 满足

$$\mathbb{E}[Z \mid \mathcal{F}_k] = \tilde{g}_k, \quad (4-13)$$

以及

$$\mathbb{E}[\|Z\|_2^2 \mid \mathcal{F}_k] \leq C_{\text{db}}, \quad \mathbb{E}[\text{cost}_{\text{traj}}(Z) \mid \mathcal{F}_k] = C_{\text{cost}} < \infty. \quad (4-14)$$

对于有限层级上限 $L_{\max}$ 及算法 3-3 中规定的概率, 有

$$\begin{aligned} \mathbb{E}[Z^{\text{db},(L_{\max})} \mid \mathcal{F}_k] &= \mathbb{E}[T_{k,L_{\max}} \mid \mathcal{F}_k], \\ \|\mathbb{E}Z^{\text{db},(L_{\max})} - \tilde{g}_k\|_2 &\leq A2^{-L_{\max}}, \quad \mathbb{E}\|Z^{\text{db},(L_{\max})}\|_2^2 \leq C_{\text{db}}. \end{aligned} \quad (4-15)$$

上述两个衰减阶是由梯度恒等式、 $w^\varepsilon \in C^3$ 、外层得分二阶矩、内层样本独立性以及共享外层轨迹共同推出的结论。轨迹成本把一条完整的 h 步路径计为一次调用。由于 $\sum_\ell p_\ell n_\ell \log(n_\ell + 1) < \infty$, 包含排序的算术成本同样可积。未截断构造的单次成本随随机层增长, 其有限性在期望意义下成立; 有限 $L_{\max}$ 则限制单次轨迹成本, 并保留式 (4-15) 给出的截断偏差。

去偏证明分为两步。首先, 在给定外层轨迹后, 对经验生存概率代入的非线性函数作二阶展开。经验概率本身无偏, 一阶项取期望后消失, 二阶余项给出 n^{-1} 阶的期望偏差。完整样本经验概率又恰好等于两个半样本经验概率的平均值, 因而全样本与半样本耦合差分中的一阶项逐样本抵消; 结合 Bernoulli 样本均值的四阶矩, 可得层差二阶矩的 $2^{-2\ell}$ 衰减。

其次,对层差按随机选择概率重加权,期望成为逐层相加的望远镜和。层概率衰减得过快会放大高层的重加权方差,过慢则导致高层成本难以控制。 $1 < a < 2$ 同时保证二阶矩求和与期望成本求和收敛,因此无限层构造能够在有限期望工作量下恢复冻结模拟梯度。有限截断时,望远镜和停留在最高保留层,其偏差正好由该层近似误差控制。

第三节 有限样本方差与渐近分布

定理 4.2 (有限样本方差与目标均方误差): 在命题 4.2 的条件下, 固定 k, θ_k , 取 M 个条件独立的完整重复样本, 并记 $\hat{g}_{k,M} = M^{-1} \sum_{b=1}^M Z_{k,b}^{\text{db}}, \hat{g}_{k,M}^{(L_{\max})} = M^{-1} \sum_{b=1}^M Z_{k,b}^{\text{db},(L_{\max})}$ 。未截断样本均值满足

$$\mathbb{E}[\hat{g}_{k,M} | \mathcal{F}_k] = \tilde{g}_k, \quad \text{tr Var}(\hat{g}_{k,M} | \mathcal{F}_k) \leq C_{\text{db}}/M. \quad (4-16)$$

当 $L_{\max} \in \{0, 1, \dots\} \cup \{\infty\}$ 且约定 $2^{-\infty} = 0$ 时, 由假设 2.3 可得

$$\mathbb{E}[\|\hat{g}_{k,M}^{(L_{\max})} - g_k\|_2^2 | \mathcal{F}_k] \leq \frac{C_{\text{db}}}{M} + 2(\beta_k^{\text{sim}})^2 + 2A^2 2^{-2L_{\max}}. \quad (4-17)$$

使用一组共享内层样本和 m 个外层样本的样本分拆代入估计量满足

$$\mathbb{E}[\|\hat{g}_{k,n,m}^{\text{pl}} - g_k\|_2^2 | \mathcal{F}_k] \leq \frac{C_{\text{in}}}{n} + \frac{C_0}{m} + \frac{2A_b^2}{n^2} + 2(\beta_k^{\text{sim}})^2, \quad C_{\text{in}} = 2B_v^2(C_1 + C_2)^2 C_{G,2}. \quad (4-18)$$

式 (4-17) 依次保留了重复抽样方差、模拟误差与有限层级截断偏差。该式中的真实目标项还使用式 (2-16), 相邻时期的漂移不进入单期内部的方差恒等式。

这一分解直接对应三种计算决策。增加独立重复数 M 可以降低抽样方差; 提高最大层级可以减小有限精度偏差; 提高模拟器对真实市场的刻画能力才会减小模拟误差。三者各有作用, 增加重复次数无法消除一个系统性偏离真实市场的模拟模型。对共享内层样本的代入估计器, 条件方差分解还保留了内层样本引起的共同随机性, 因此只增加外层样本数也无法消去所有采样误差。证明见附录 附录 3。

定理 4.3 (去偏梯度估计量的渐近正态性): 在命题 4.2 的条件下, 固定

k, d, θ_k 、正则化参数以及条件模拟分布。对未截断的独立同分布重复样本，令 $\Sigma_k = \text{Var}(Z_k^{\text{db}} | \mathcal{F}_k)$ 。对几乎处处成立的固定条件环境，有

$$\sqrt{M}(\hat{g}_{k,M} - \tilde{g}_k) \rightsquigarrow N(0, \Sigma_k). \quad (4-19)$$

若 Σ_k 正定，则 $\sqrt{M}\Sigma_k^{-1/2}(\hat{g}_{k,M} - \tilde{g}_k) \rightsquigarrow N(0, I_d)$ ，且用样本协方差替换 Σ_k 后极限保持不变。有限二阶矩已经足够。仅在模拟精确时，中心才能改为 g_k 。

该条件极限固定维度、时期及模拟分布，只让独立重复数 M 增大。固定层级上限时，相应极限以 $\mathbb{E}T_{k,L_{\max}}$ 为中心。若层级上限随 M 变化，要使估计量以 $\tilde{g}_k$ 为中心，还需要额外证明乘以 $\sqrt{M}$ 后的偏差趋于零，并建立适用的三角阵列论证。固定层级与未截断构造分别使用上述各自的中心。

渐近正态性建立在完整重复之间的条件独立性上。固定时期起点与模拟分布后，每个重复都重新生成随机层、外层轨迹和内层轨迹，因而其均值可应用多元独立同分布中心极限定理。层差分析提供了所需有限二阶矩，样本协方差则由大数定律估计总体协方差。这一结论为固定目标下的误差区间与重复实验设计提供依据，也说明应把完整多层重复作为统计单位。

第四节 动态局部遗憾

引理 4.1 (受约束驻点集合的漂移): 在假设 2.1、2.2、假设 2.3 中的梯度变化条件，以及两个相邻时期均满足的假设 2.5 下，若两个时期使用相同的 a_0, γ, Θ ，则

$$d_H(S_{k+1}, S_k) \leq \frac{\kappa}{a_0} \delta_k^g. \quad (4-20)$$

该集合漂移界依赖残差误差界、梯度变化界，以及归一化与投影的非扩张性。假设 2.5 是把一阶残差转换为驻点集合距离所需的额外统一条件，下述基本在线定理直接控制投影残差，进一步讨论集合距离时再使用这一几何条件。

直观地，旧时期的驻点在旧残差映射下为零。如果相邻时期的梯度变化较小，归一化和投影的 Lipschitz 性便保证它在新时期的残差也较小。新时期的误差界将这个小残差转化为到新驻点集合的距离；交换两个时期，便得到 Hausdorff 距离的双向控制。这里比较的是两个完整集合，允许最优方向及驻点位置随时期

移动。

定理 4.4 (基于投影残差的动态局部遗憾): 设 Θ 为假设 2.1 中的非空紧凸参数集。假设 $|J_k| \leq B_J$ 、 $\|\nabla J_k\|_2 \leq B_g$ ，每个 J_k 在 Θ 上均为 L 光滑，并且

$$\mathbb{E}[\|\hat{g}_k - g_k\|_2^2 | \mathcal{F}_k] \leq e_k^2.$$

对算法 3-2，固定 $a_0, \gamma > 0$ ，满足 $\gamma L \leq a_0$ ，并令 $C_g = \max(B_g, a_0)$ ，则

$$\mathcal{E}_K \leq \frac{8(2B_J + \mathbb{E}V_K)}{a_0\gamma K} + \frac{10C_g}{a_0^3 K} \sum_{k=1}^K \mathbb{E}e_k^2. \quad (4-21)$$

在假设 2.1 至 2.3 以及算法 3-3 下，可以取

$$e_k^2 = \frac{C_{\text{db}}}{M_k} + 2(\beta_k^{\text{sim}})^2 + 2A^2 2^{-2L_{k,\max}}. \quad (4-22)$$

此外， $K^{-1}\mathbb{E}\mathcal{R}_{\rho,w}^Q(K) \leq w\mathcal{E}_K$ 。

若要显式分离参考点引起的变化，进一步假设 2.4 成立，并定义

$$\delta_k^{\text{nr}} = \sup_{\theta \in \Theta} |J(P_{k+1}, z_{k+1}, r_k; \theta) - J(P_k, z_k, r_k; \theta)|. \quad (4-23)$$

则将 V_K 替换为

$$U_K + C_1 \sum_{k=1}^{K-1} D_h(|r_{k+1} - r_k|), \quad U_K = \sum_{k=1}^{K-1} \delta_k^{\text{nr}} \quad (4-24)$$

后，同一上界仍成立。

式 (4-21) 给出平均投影残差平方的定量控制。常数随固定维度、时域长度、浓度参数域、价值尺度与正则化确定。显式参考点分解进一步使用命题 4.1，驻点集合的统一误差界则用于后续距离推论。基本在线结论因而适用于满足上述有界性与光滑性条件的非凸目标序列。

式 (4-23) 中的 δ_k^{nr} 固定比较时的参考点，只改变市场模型与其余起始状态。下文将它表述为固定参考点后的目标变化。由于 z_k 包含受历史配置影响的财富和持仓， U_K 同时可能包含外部市场变化与内生状态变化。式 (4-24) 单独提取参考点的敏感性项，并没有把全部变化划分为两个互不重叠的外生、内生来源。

定理的主要含义可以从上界的三部分理解。初始目标范围形成随 K^{-1} 衰减的项；目标变化以 $\mathbb{E}V_K/K$ 的平均强度进入；估计器以平均梯度估计均方误差进入。只要目标的累计变化相对于时期数较慢，且计算精度足以压低平均误差，

平均一阶残差就能得到相应控制。市场结构变化较快时，上界允许算法保持更大的跟踪误差。固定采样与有限截断下，结论自然保留精度项，这为稳定跟踪的有限精度解释提供了依据。

证明先固定某一期目标。投影变分不等式把可行位移与更新方向联系起来，目标光滑性则把这段位移转化为目标上升量。估计方向偏离真实归一化方向时，利用归一化映射和投影的非扩张性，将其代价控制为梯度估计误差的平方，得到附录中的单步上升引理。随后对各期求和，同一目标内的改进量通过望远镜展开化为首尾目标差以及相邻目标在同一参数处的差，后者恰由 V_K 控制。该代数关系对已经实现的目标序列逐路径成立，因此允许期初财富与参考点由此前执行内生生成。

最后，窗口权重非负且和为一，由 Jensen 不等式可将窗口向量平均的平方范数控制为窗口内平方范数的加权平均。每个逐期残差至多出现在 w 个窗口中，从而得到动态局部遗憾界。证明由逐期残差推向平滑诊断；实验中同时记录这两类量，能够识别平滑导致的方向抵消。显式参考点预算则通过插入同一旧参考点下的中间目标，并应用敏感性界得到。

推论 4.1 (固定目标极限与次线性变化情形): 在定理 4.4 的条件下，若完整条件目标固定，即 $J_k \equiv J$ ，且 $K^{-1} \sum_{k=1}^K \mathbb{E} e_k^2 \rightarrow 0$ ，则对固定且满足 $\gamma L \leq a_0$ 的 γ ，有

$$\frac{1}{K} \sum_{k=1}^K \mathbb{E} \|Q(\theta_k)\|_2^2 \rightarrow 0. \quad (4-25)$$

更一般地，当 $\mathbb{E} V_K = o(K)$ 且平均均方误差趋于零时， Q_k 也有相同结论。在精确且未截断的模拟下， $M_k \rightarrow \infty$ 几乎处处成立足以使平均采样误差趋于零。固定的非零误差界使残差上界保留误差项，因而不足以保证残差趋于零。

这里的固定目标极限要求完整的条件目标满足 $J_k \equiv J$ 。一个充分的基准设定是每期使用相同的市场模型、起始信息、参考点递推机制和 CPT 参数。参考点递推机制保持固定时，轨迹内部仍可动态适应；静态参考点只是令两侧适应率均为零的一个特例。单独冻结参考点后，市场模型与起始财富的变化仍可能

使条件目标移动。

对固定的诊断窗口 w ，结合定理中的 $K^{-1}\mathbb{E}\mathcal{R}_{\rho,w}^Q(K) \leq w\mathcal{E}_K$ ，推论的误差消失条件进一步给出动态局部遗憾的次线性增长。若窗口随总时期数增大，使用这一上界还须验证 $w\mathcal{E}_K \rightarrow 0$ 。固定有限重复数、固定截断上限或持续模拟偏差通常使现有误差上界保留常数项，因而本定理不能据此保证次线性增长；这一保留项也没有证明实际误差必然达到某个正的下限。有限长度曲线的下降趋势和增长斜率可用作经验诊断，渐近结论仍需上述条件。

推论 4.2 (移动一阶驻点集合的跟踪): 在定理 4.4 的条件下，若假设 2.5 也成立，则

$$\frac{1}{K} \sum_{k=1}^K \mathbb{E} \text{dist}^2(\theta_k, S_k) \leq \kappa^2 \mathcal{E}_K. \quad (4-26)$$

右端由式 (4-21) 控制；在推论 4.1 的误差消失条件下，右端收敛到零。

这一距离结论依赖额外的残差误差界，不能从较小的窗口向量平均值直接推出。

两个推论说明了同一上界如何覆盖不同环境。在完整目标固定时，跨期变化项消失，平均估计误差趋零即可推出平均残差趋零；在目标持续变化时，同一结论要求平均变化强度也趋零。若给定目标类还满足残差误差界，逐点距离不等式经过平方、期望与时期平均即可得到集合跟踪。因而，基础定理提供可计算的一阶准则，附加几何条件为“接近合理解”提供更强的参数距离解释。

第五节 极小极大下界

本节的“极小极大”是指：在原始轨迹观测的期望预算约束下，估计单个固定时期 CPT 梯度时能够达到的最小最坏情形均方误差。该统计准则与可达到的最大 CPT 值、投资组合财富及在线遗憾最优值分别衡量不同对象。

定理 4.5 (固定维度下 CPT 梯度估计的极小极大界): 在假设 2.6 下，存在有限常数 $c_{\text{lb}}, C_{\text{ub}} > 0$ 和 $B_0 \geq 1$ ，它们均与 B 无关，使得对任意 $B \geq B_0$ ，

$$\frac{c_{\text{lb}}}{B} \leq \inf_{\hat{g}: \sup_{P \in \mathfrak{C}} \mathbb{E}_P N_{\text{call}} \leq B} \sup_{P \in \mathfrak{C}} \mathbb{E}_P \|\hat{g} - g_P\|_2^2 \leq \frac{C_{\text{ub}}}{B}. \quad (4-27)$$

下确界遍历所有具有上述自适应预言机访问权限的可测程序。在 θ_0 处，将算

法 3-3 的 $M = \lfloor B/C_{\text{cost}} \rfloor$ 个独立未截断重复样本取平均，即可达到上界，其中 $B_0 = \max(1, 2C_{\text{cost}})$, $C_{\text{ub}} = 2C_{\text{db}}C_{\text{cost}}$ 。统一常数在固定模型类上选取。即使允许自适应策略查询与停止规则，下界仍然成立。

在固定维度与固定正则化下，该误差阶为 $\Theta(B^{-1})$ ，相应常数可以依赖 d 、时域长度、特征与正则化。在精确模拟下，令 n 和 m 都与 B 成比例，代入估计界也给出 $O(B^{-1})$ 的均方误差上界；随机化估计量进一步具有有限期望成本下的精确无偏性。因此，匹配的误差阶确定了这一统计实验的预算尺度，无偏性与有限成本表现仍为具体方法的比较提供额外维度。

下界证明构造两个十分接近的股票收益模型。在两个模型中，动作分布和已知输入相同，区别仅在一个未知收益概率。概率相差预算平方根的倒数时，真实 CPT 梯度仍具有同阶的可识别差异，但期望预算内的轨迹不足以将两个模型可靠区分。将任意梯度估计程序转换成两点判别程序，即可由信息界推出 B^{-1} 的均方误差下界。上界则直接用每次重复的有限期望成本校准可执行重复数，并利用独立平均的方差界。上下界由此对应同一轨迹观测实验，完整构造见附录 附录 5。

该统计最优性定理的下界构造在单个固定参数 $\theta_0 = 0$ 处分离梯度。定理 4.2 的均方误差界则在声明的参数域上一致成立，因而可用于每个可预测的在线迭代点 θ_k 。固定目标下界不会代入逐时期上界。这里的预算是期望轨迹调用预算，结论也限定在固定维度下。

第五章 实验设计与结果分析

本章围绕三个问题组织实验：参考点递推是否产生可识别的历史依赖，梯度估计是否呈现理论预测的误差与成本关系，以及算法能否在变化的市场中保持较小的一阶残差。受控模型提供可独立计算的总体梯度，适合检验统计量和更新公式；半合成市场保留真实因子结构，同时控制收益生成机制，适合比较不同目标下的在线响应；真实数据与行为评估进一步考察方法的应用价值。

受控实验包括两条财富路径的精确递推、9600 组层级统计量、8192 次截断估计器重复和一次 36 期非平稳回放，分别考察路径评价、层间误差与在线更新。进一步拟开展半合成市场及真实数据回放，在统一的投资评价下比较不同参考机制和效用目标；行为对照则考察历史经历如何影响后续配置与出售决策。以下先报告受控计算结果，再给出市场和行为比较的实验设计与研究预期。

实验固定 $\alpha_+ = \alpha_- = 0.88$ 、 $\lambda = 2.25$ 、 $\eta_+ = 0.4$ 、 $\eta_- = 0.1$ 。概率权重采用基函数 $w_{\pm}(p) = p^3$ 经式 (2-7) 归一化后的形式， $\varepsilon = 0.05$ ；价值平滑参数为 $\varepsilon_v = 0.01$ 。三次权重属于前述光滑权重类，便于推导总体比较值。它在这里用于数学计算检验，没有通过行为数据拟合。多层估计器统一使用 $N_0 = 2$ 、尾指数 $a = 1.5$ ，随机种子与逐次估计记录随源文件保存。

第一节 参考点机制与路径依赖

从 $r_0 = X_0 = 1$ 出发，比较财富路径 $(1, 1.4, 1.2)$ 和 $(1, 0.8, 1.2)$ 。第一条路径到达 1.4 后，参考点更新为 $1 + 0.4(1.4 - 1) = 1.16$ ；当财富回到 1.2 时，仍高于参考点，故再次按收益分支更新至 $1.16 + 0.4(1.2 - 1.16) = 1.176$ 。第二条路径到达 0.8 时，参考点按损失分支降至 $1 + 0.1(0.8 - 1) = 0.98$ ；随后财富升至 1.2，参考点按收益分支升至 $0.98 + 0.4(1.2 - 0.98) = 1.068$ 。两条路径的终端相对结果分别为 0.024 和 0.132。

这些路径具有相同的期末财富，且可以在无交易成本、总收益因子为正的情形下实现。对于确定性结果，端点归一化使 CPT 退化为该结果的有符号价值

变换，因此严格单调性保证两个不同相对结果对应不同的 CPT 值。需要注意，这组具体数值的第一条路径在最后一步使用收益分支，不满足命题 4.1 中路径 A 的第二步损失分支条件。因此，此处通过逐步递推计算，没有直接套用式 (4-2) 的特殊分支表达式。

该例在固定期末财富后识别了参考点的历史记忆。动态方法保留两条路径的不同参考水平；将两侧适应率都设为零时，两条路径的参考点均保持为 1，相对结果均为 0.2。因而，参考点递推直接改变了进入效用函数的输入。后续行为比较进一步区分这种输入差异、学习方向差异与实际出售决策，具体设计见本章末节。

第二节 梯度估计的偏差、方差与成本

5.2.1 可解析模型与层级误差

首先考虑可解析的一期模型：初始财富和参考点均为 1，交易成本为零，股票收益恒为 $r_* = 1/3$ ，参数 $\theta = 0$ 。此时股票权重 U 在 $(0, 1)$ 上均匀分布，参考点沿收益分支更新，故相对结果为 $Y = cU$ ，其中 $c = 0.2$ ，得分函数为 $G = 1 + \log U$ 。总体标量梯度可以独立表示为

$$g = \int_0^1 c v'_+(ct) (w_+^\varepsilon)'(1-t) (-t \log t) dt. \quad (5-1)$$

数值积分得到 $g = 0.0643115914$ 。将积分阶数从 512 增加到 1024，发布环境中的差异约为 1.804×10^{-16} 。这一比较用于检查数值稳定性，没有给出经过严格认证的积分误差界。

对于本实验的三次基权重，将归一化权重的导数写成 $(w^\varepsilon)'(p) = b_{w,0} + b_{w,1}p + b_{w,2}p^2$ 。有限内层样本的总体偏差有精确表达式

$$\mathbb{E}T_k^{(n)} - g = B_1/n, \quad B_1 = b_{w,2} \int_0^1 c v'_+(ct) t(1-t) (-t \log t) dt > 0. \quad (5-2)$$

附录 附录 6 给出其推导。本例 $B_1 = 0.0289720186$ ，所以能够在不使用经验偏差曲线的情况下计算各样本规模对应的真实偏差。每一层独立采集 1600 组内外层样本，并以真实全样本及半样本统计量计算耦合差。表 5-1 报告结果。经验偏差

是估计均值与总体梯度的差，仍带有蒙特卡洛误差；其正负不必与有限样本总体偏差逐次一致。

表 5-1 各层耦合统计量诊断，括号内为蒙特卡洛标准误

n	解析偏差	经验偏差 (标准误)	$\Delta_{k,\ell}^2$ 均值 (标准误)
4	7.243×10^{-3}	7.087×10^{-3} (4.033×10^{-3})	2.309×10^{-3} (3.260×10^{-4})
8	3.622×10^{-3}	3.026×10^{-4} (3.379×10^{-3})	4.855×10^{-4} (6.550×10^{-5})
16	1.811×10^{-3}	9.245×10^{-4} (3.010×10^{-3})	1.241×10^{-4} (1.633×10^{-5})
32	9.054×10^{-4}	-2.300×10^{-3} (2.837×10^{-3})	5.643×10^{-5} (2.124×10^{-5})
64	4.527×10^{-4}	1.621×10^{-3} (3.062×10^{-3})	1.344×10^{-5} (3.352×10^{-6})
128	2.263×10^{-4}	-7.934×10^{-3} (2.445×10^{-3})	1.462×10^{-6} (1.823×10^{-7})

5.2.2 独立重复平均与成本校准

随后运行 8192 次截断于 $L_{\max} = 7$ 的完整随机层估计器。对于给定的重复数 M ，将连续且互不重叠的 M 次输出取均值，以该均值相对式 (5-1) 的平方误差作为一组观测。不同 M 使用同一批 8192 次记录重新分组，因此表中各行不构成彼此独立的实验。MSE 标准误由组间平方误差的样本标准差除以组数平方根得到。轨迹成本统计全部内层和外层调用。

表 5-2 截断估计器的批均值误差与实际轨迹调用成本

M	组数	经验 MSE	MSE 标准误	平均轨迹调用数
1	8192	9.572×10^{-2}	7.053×10^{-3}	5.146
4	2048	2.403×10^{-2}	1.900×10^{-3}	20.586
16	512	6.303×10^{-3}	6.145×10^{-4}	82.344
64	128	1.824×10^{-3}	2.611×10^{-4}	329.375

本次截断估计的期望相对 g 仍有 $B_1/(2 \cdot 2^7) = 1.132 \times 10^{-4}$ 的偏差。表 5-2 与独立平均降低方差的结论相容，但有限层计算不能验证无限层估计器的严格无偏性。相应地，若对固定截断估计做正态诊断，应以其自身期望为中心。定

理 4.3 陈述的是固定时期、无限层独立重复的渐近结论，当前表格没有替代该定理所需的极限分析。

随着 M 从 1 增至 64，表中经验 MSE 由 9.572×10^{-2} 降至 1.824×10^{-3} ，相应的平均调用成本从 5.146 增至 329.375。该变化体现了用更多完整重复换取较低随机误差的机制。层级表同时表明，经验偏差较容易受外层轨迹噪声影响，而耦合差分的二阶矩能更直接地检验层间抵消效果。因此，实验同时报告解析偏差、经验偏差标准误和层差二阶矩，分别对应不同的理论对象。

5.2.3 等预算比较与预期检验

进一步的估计器比较以完整轨迹调用数作为共同成本。多层方法计入随机层内全部样本，代入方法计入共享内层样本及全部外层样本；积分排序耗时和峰值内存作为计算性能另行记录。比较保持同一期初状态、策略参数、参考点递推和正则化不变，并利用独立的解析积分计算真梯度。每组配置重复独立试验，报告偏差、方差、MSE 及其蒙特卡洛不确定性。

理论预期包括三个方面。内层样本增加时，代入偏差按已推导的阶减小；共享外层得分的耦合差分表现出比单层误差更快的二阶矩衰减；完整重复平均的方差随重复数增加而下降。有限截断的误差比较同时保留其理论偏差，正态诊断以截断估计自身的期望为中心。对未截断估计器，可以检验多组独立均值的标准化分布；若实际程序设置了层级上限，实验标签和比较中心也相应保持为有限截断。

极小极大结果由第四章及附录中的统计模型与证明建立。这里的预算曲线检验具体估计器是否呈现相容的精度阶，并比较有限成本下的常数和运行稳定性。由于代入方法在精确模拟下也能达到同阶 MSE，上述比较的研究问题是无偏性、方差及实际成本之间的权衡。

第三节 合成非平稳市场中的在线跟踪

5.3.1 环境与算法设置

在线验证包含 36 个时期，每个时期长度 $h = 1$ ，配置对象为一个股票和现金。交易成本为零，参数域为 $\Theta = [-2, 2]$ ，初始条件为 $X_1 = r_1 = 1$ 、 $\theta_1 = 0$ 。股票收益为 ± 0.04 ，上涨概率在第 1 至 12 期为 0.7，第 13 至 24 期为 0.3，第 25 至 36 期为 0.6。学习时使用当期真实收益分布的模拟器，因此本实验 $\beta_k^{\text{sim}} = 0$ 。执行时使用均值权重，并通过独立收益抽样更新实际财富和参考点。

每期使用 $M_k = 64$ 次完整估计器重复，截断层数为 6，归一化阈值 $a_0 = 1$ 。对整个有限回放区间推导的保守光滑常数为 $L = 177.783288$ ，步长取 $\gamma = 1/(2L) = 0.00281241$ ，满足定理的充分条件。附录 附录 6 给出财富界与 Beta 似然矩对应的计算。这一选择便于核查理论条件，但步长较保守，实际参数位移很小。

表 5-3 一次完整在线回放的数值结果

指标	观测值
数值积分残差 Q_k^2 的均值	1.144×10^{-4}
梯度估计平方误差的均值	2.101×10^{-4}
最终参数 θ_{37}	0.00031455
最终归一化财富	1.03335402
最终参考点	1.09220849
学习层累计轨迹调用数	11324

实际收益流的随机种子为 88177。目标值与真实梯度通过对当前条件目标独立数值积分得到，再据其计算真实归一化梯度的投影残差。梯度积分另与目标函数的中心差分核对：在 $\theta = 0.2$ 、起始参考点为 0.98, 1, 1.02 时，差异均小于 2×10^{-7} 。回放中将积分阶数从 128 增加到 256，目标或梯度的最大变化约为 3.902×10^{-6} 。

这次回放将估计方向与独立计算的总体方向连接起来，验证了执行、估计

和参数更新的完整流程。最终参数接近初始值，与由保守光滑界选取的小步长相符。表中的残差平均对应单条市场实现，完整的期望型跟踪评价还需要对独立市场路径重复计算。后续设计因此增加多个市场与学习随机种子，并扩大到 $h > 1$ 的有限时域，以覆盖轨迹内部参考点和状态递推的影响。

5.3.2 分阶段跟踪与评价方法

在线比较同时保存逐期真实梯度、投影残差、梯度估计、归一化方向、参数、财富和参考点。在能够数值积分的低维环境中，先用独立总体梯度构造 $Q_k(\theta_k)$ ，再按式 (2-12) 计算窗口向量，最后得到动态局部遗憾及其时期平均。有限采样的实际参数位移作为算法执行记录保留，与真实目标残差分开使用。

评价按全程与市场阶段两个层次展开。全程记录累计量及除以已运行时期数后的平均量；阶段分析以市场切换点为起点，观察逐期残差、相对结果和配置响应。窗口宽度 w 与时期长度 h 分别指定，所有方法采用相同窗口权重。跨种子的算术平均用于估计期望指标，中位数及 25% 至 75% 分位带用于展示典型路径与离散程度，两者同时保留。

主定理将平均投影残差平方与累计目标变化、平均梯度估计误差联系起来，实验据此比较不同变化强度和采样投入下的全程一阶表现。阶段切换后的逐期响应另作为研究假设检验：外部冲击或参考点变化加快时，残差可能上升，并在后续调整中回落。该时间响应及其持续长度由实验记录评价，平均上界本身未给出恢复时间。动态与静态参考点具有不同目标，因此比较原始梯度时还需结合目标尺度、配置变化和共同投资评价。

第四节 半合成 A 股市场回放设计

5.4.1 数据组织与市场机制

半合成实验以沪深 300 成分股的历史信息构造真实因子，以预先规定的市场机制生成投资收益。数据按交易日排列，股票池采用相应时点已知的成分记录，并保存纳入及剔除条件。动量、反转、波动率与价值等因子只使用决策时可得的信息计算；涉及财务指标时按披露日期对齐。缺失数据的筛选规则在实验

前固定，训练与检验区间按时间先后分开。若为获得固定维度而要求全区间完整数据，应同时报告由此产生的事后筛选范围，并将该版本解释为受控实验样本。

受控半合成比较从声明的因子面板中固定选择 N 只股票，所有方法在同一实验内使用相同名单和维度，以对应假设 2.1。真实市场样本的成分变化和数据的完整性另行记录；如果实际回放必须改变资产数量或动作支持，则需要先核对相应模型条件，再解释理论结论的适用范围。

收益生成分为上涨、震荡、市场冲击和风格切换四个阶段。上涨阶段提高动量暴露的收益贡献；震荡阶段增强反转成分；冲击阶段加入负向公共冲击并提高波动；风格切换阶段改变有效因子，使低波动或质量相关暴露发挥更大作用。公共扰动与个股扰动共同保留横截面相关性，扰动分布和系数在实验配置中明确给出。为核验有界分析域，收益支持和交易成本须保证财富增长因子为正，并根据给定总时长推导可用的财富及价值界。

主比较拟采用 $h = 5$ 、 $K = 100$ 的 500 步设计，使用预先固定的 10 个随机种子。该设置允许每个时期包含多次动作与参考点更新。市场阶段按日历步定义，报告时同步标明其对应时期；阶段长度、冲击幅度和因子系数在运行前锁定。需要延长运行时，可以重复已声明的阶段机制，并单独考察周期切换是否带来新的目标变化。实际执行和所有学习轨迹均从同一时期起点初始化，遵循算法 3-2 的条件化方式。

受控半合成版本直接提供已知市场机制，以便单独检验估计器与优化过程；拟合模拟器版本仅使用期初已知数据估计收益规律，用于观察模拟误差的影响。两个版本分别报告，便于解释误差来自采样还是模型。真实 A 股回放再将生成收益替换为后续实际收益，冻结模拟器只使用当时可得历史。训练样本始终由冻结模型中的当前随机策略生成，真实未来价格仅用于执行评估。

5.4.2 比较方法与共同控制

方法比较包含非对称动态参考点 CPT-PG、对称动态参考点 CPT-PG、静态参考点 CPT-PG、期望财富 PG 和指数期望效用 PG。非对称方法保留 $\eta_+ = 0.4$ 、 $\eta_- = 0.1$ 的基准设置。对称方法先将两侧适应率设为 0.25，使其算术平均适应率与非对称设置一致，再通过多个对称速度检验结论是否取决于这一选择；该匹配仅控制名义速度，实际参考点变化仍取决于盈亏路径。静态方法在执行与模拟中均令两侧适应率为零。

两种 PG 基线采用相同的终端归一化财富随机变量。期望财富方法优化其条件期望，指数效用方法优化固定风险厌恶系数下的期望指数效用。所有方法共享资产特征、初始参数、参数域、时期长度、交易成本和执行方式。CPT 方法使用同一组固定价值函数和概率权重，改变的部分明确限制在参考机制或估计器。基线的效用尺度另行记录，以便解释梯度归一化阈值对不同目标的影响。

计算比较按期望原始轨迹预算匹配，并记录实际调用量。学习流与执行流分别设置种子；不同方法共享可比的市场随机实现，避免将市场路径差异误认为策略差异。多层方法按每个重复的完整成本计数，代入方法按内外层调用计数。步长在给定模型能够推导 L 时按 $\gamma L \leq a_0$ 选择；应用性调参使用时间靠前的验证区间，并在最终检验区间固定配置。对每个方法，均值执行与随机策略评估各自保存结果。

5.4.3 优化表现、财富表现与共同评价

优化指标围绕各自目标的一阶条件构造。在小规模受控环境中采用独立数值积分计算真实残差；维度较高时，使用额外独立大样本评估，并同时报告其估计不确定性。逐期残差平方、累计和、时期平均及窗口动态局部遗憾共同展示目标切换后的响应。对不同 CPT 目标的梯度，分析时同时检查价值幅度、参考点距离和参数触边情况，避免把尺度缩小直接解释为更快优化。

投资表现包括扣除成本后的归一化财富、累计收益、最大回撤、Sharpe 比率、组合权重变动及累计交易成本。最大回撤按历史财富峰值与之后财富的相

对下降计算；Sharpe 比率使用执行层相同频率的账户收益，年化因子明确随观测频率给出。换手相关统计沿用式 (2-1) 中的权重变动口径，并完整记录现金维度。交易成本在每一步进入财富递推，随后影响该路径上的参考点与终端相对结果。

共同 CPT 评价另行固定参考点和价值、概率权重参数，对不同方法的执行结果分布重评估。比较终端财富分布时，以各独立市场回放的终端财富构成样本，统一参考点取初始归一化财富 1；比较某一期候选策略时，则固定相同起点和市场模型，另外采集足量轨迹。前者回答跨回放的最终投资结果如何被同一偏好评价，后者回答同一情境下策略分布如何被评价。逐日财富观测具有时间依赖，不能直接充当独立终端轨迹。

主要展示采用按方法的残差图、动态与静态对比图以及共同市场背景下的财富图。每个图给出种子数、样本单位、市场阶段、执行方式及成本设定。若不同方法的财富相近，则进一步比较均值权重、浓度总和与因子参数，判断是否由近似配置产生；若梯度差异明显而财富相近，则分别分析目标评价变化与真实配置变化。该分析不预设方法排名。

5.4.4 消融、敏感性与研究预期

参考点消融检验动态机制是否影响路径评价，并将非对称性与平均适应速度分开比较。估计器消融在相同参考机制下比较多层方法与代入方法，检查有限预算下的偏差、方差和运行成本。模拟误差实验固定生成市场，改变拟合样本或模型设定，观察增大 M_k 后仍然保留的误差。三组比较分别对应参考点敏感性、估计器误差界和在线定理中的模拟项。

敏感性分析围绕 M_k 、 $L_{k,\max}$ 、 γ 、 a_0 、 h 、参考点适应率及固定正则化参数展开。每次先控制其余设置，再报告所改参数同时影响的理论量。例如，增加 h 会改变参考点差异的传播、轨迹得分矩和采样成本；减小正则化幅度会改变目标及导数常数；改变 a_0 会同时改变实际更新与残差的尺度。因此，敏感性图记录配置变化，并在固定评价口径下补充比较，避免将不同残差定义混合排序。

本研究预期，在给定变化强度与计算预算下，动态参考机制能够产生区别于静态机制的相对结果评价和在线响应，非对称适应进一步改变盈利与亏损经历的影响。是否改善共同评价下的财富风险权衡，由比较实验判断。多层去偏的理论贡献则体现为明确的统计性质；其实际优势可能随采样预算、正则化及模拟质量变化。若比较结果显示优势有限，仍可据误差分解说明限制来自何处，而无需改变已证明结论的范围。

第五节 异质投资者的评估设计

5.5.1 历史路径与策略响应

行为检验先使用成对历史情境：两条路径具有相同的期末财富、市场信息和原持仓，差别仅在历史经历形成的参考点。为隔离参考点作用，首轮比较固定同一策略参数与未来市场模型，考察 CPT 值及梯度的变化；再在各自目标下进行同样次数的学习，比较下一期均值组合。若特征不直接包含参考点，更新前同一参数的动作分布应一致，差异应通过目标评价和后续学习传递。这样能够辨别参考点究竟在哪一步影响决策。

静态参考点作为对照，检验消除参考适应后成对差异是否缩小；对称参考点用于检验方向非对称是否影响差异的持续时间。成对路径随后接受相同的新市场经历，连续记录参考点间距、CPT 差异和配置差异。对于固定参数且满足参考点隔离条件的诊断，可以与命题 4.1 中的收缩关系比较；允许参数分别学习后，配置差异则同时包含学习路径的影响。

5.5.2 出售行为与投资者评价

处置效应评价沿用盈利实现比例与亏损实现比例的次数思路^[22]，需要资产层面的买入成本和出售记录。实验在决策时使用已知价格与账面成本区分盈利、亏损状态，按资产是否发生实际出售记录实现次数，并对同一出售时点的未售持仓记录账面盈利和亏损机会。盈利实现比例取盈利实现次数除以盈利实现与账面盈利机会之和，亏损实现比例采用对应损失口径。份额减少用于识别出售，价格变化造成的权重下降单独处理。指标采用预先固定的并列、部分出售与零

分母规则，并报告有效观测数。

这一实验检验参考机制是否改变出售倾向，同时保留市场趋势、成本和持仓历史作为共同控制。账户层面的相对财富与单只资产相对买入成本的盈亏具有不同含义，因此结果解释分别对应二者。He 和 Yang 的实现效用模型提供了行为动机^[9]，但本文优化的是终端相对财富分布的 CPT；所观察到的出售行为需要由当前模型的实验记录支持。

异质性评估改变预先测量的价值参数、概率权重和参考点适应率，比较同一市场下的建议差异。若使用模拟投资者，其评分明确由设定模型生成，用于考察不同偏好之间的相容程度。真实满意度、采纳率、信任和退出行为采用独立问卷或交易决策数据测量，参数拟合与最终评价使用分开的观测；同一投资者的重复决策按个体聚类处理。由此，算法内的心理评价、可观测交易行为与真实建议接受度形成逐层验证关系。

第六节 优化性质与投资评价的联系

受控计算表明，轨迹内部的参考点递推能够区分期末财富相同的路径；共享外层轨迹的多层差分呈现与误差分析相容的统计规律。36 期回放进一步将梯度估计接入参数更新，并用独立积分得到的总体梯度评价一阶残差。由这些计算可以观察模型机制及统计精度，市场与行为设计则将其延伸到实际配置的比较。后续实验将分别考察同一目标下的精度与成本、目标变化时的一阶响应，以及统一执行评价下的财富与出售行为，从而连接理论性质和投资用途。

第六章 结论与讨论

第一节 研究结论

本文围绕具有轨迹依赖参考点的条件 CPT 目标，建立了从似然梯度、多层估计到在线一阶残差的分析。每条策略轨迹递推自己的参考点，使相同终端财富能够因经历不同而产生不同相对结果。在固定起始信息后，参考点递推是确定的轨迹泛函，参数微分通过轨迹概率律进行。这个处理使参考依赖能够进入 CPT 梯度，同时将跨时期起始状态变化留在目标变化预算中。

在紧参数域与有界特征下，指数 Dirichlet 策略的浓度落在正的紧区间内。虽然逐样本得分仍可因极小权重而增大，所需固定阶矩与似然前两阶导数的支配条件能够得到控制。固定平滑价值函数给出线性的参考点敏感性，固定正则化概率权重则提供估计器余项所需的导数界。共享外层得分的全样本和半样本耦合，使经验生存概率的一阶误差消项，由此得到随机化估计所需的有限方差与有限期望成本。

在线定理通过真实梯度构造投影残差，评价当期受约束的一阶最优性条件。单步投影上升关系经跨期求和后，将平均残差平方控制在初始目标范围、累计目标变化与梯度估计均方误差共同确定的上界内。在累计目标变化次线性、平均估计误差消失且常数对时期一致时，平均残差趋于零，固定窗口下的动态局部遗憾随之次线性增长。进一步加入统一残差误差界，便得到到移动一阶驻点集合的平均距离控制。参考点适应、模拟精度和采样投入由此与在线优化性质形成定量联系。

单期统计分析进一步确定了达到给定梯度精度所需的轨迹预算。在固定维度和共同模型常数下，精确轨迹预言机每次提供一条完整的新轨迹，估计程序的最坏情形期望调用数受到预算限制。可实现的组合子模型使两个相近市场的 CPT 梯度保持可识别差异，停止时刻相对熵与两点检验据此给出预算倒数阶的均方误差下界；未截断独立估计器的平均达到同阶上界。这一匹配结果为固定

时期、固定参数下的采样精度提供了统计基准。

第二节 适用范围与研究局限

有界分析域限定了结论的使用范围。对于一次有限回放，财富和价值的上界可以根据模型条件计算，但这些常数可能随回放长度增加。无限时期结论需要一组对总时期数一致的界，或另外声明并分析修改后的财富、回报或停止模型。本文保留财富的连续积累，未加入时期重置或重新归一化。类似地，固定正则化定义了固定目标；令正则化参数趋于零，需要额外控制逼近误差及相关常数。

一阶评价的含义也取决于所用残差与几何条件。平均残差界控制多个时期的总体表现，窗口中的方向抵消可能掩盖较大的单期残差；到驻点集合的距离还依赖给定目标是否满足统一误差界。集合本身可能包含鞍点及非全局最优的驻点，因此全局 CPT 最优性、逐期单调改进和冲击后的确定恢复时间，需要各自的额外条件。有限采样、固定截断和持续模拟误差则可能在现有上界中留下不消失项。

投资评价需要区分学习策略和执行方式。学习层优化随机 Dirichlet 策略的 CPT，执行层采用其均值配置；二者共享参数，但通常具有不同的结果分布。已有受控计算支持给定环境中的机制与统计分析，五种方法的财富风险、出售行为和实际接受度仍有待市场与行为实验检验。动态与静态参考点还定义不同目标，跨方法比较须同时保留各自的一阶指标与统一的投资评价。

统计最优性的比较范围由精确轨迹观测和期望预算确定。拟合模拟器具有额外误差，无法仅凭重复模拟获得对真实市场同样的无偏保证。增加维度、改变信息接口或要求每次运行具有确定成本上限，也会改变当前上下界的适用条件。实际计算时采用的有限层级上限控制单次成本，其统计结果应保留相应截断偏差。

第三节 进一步研究方向

一个值得深入的问题是带有模拟误差的自适应计算分配。当前理论将重复样本数、截断层级和模拟偏差分别列入误差界，但实际应用中计算资源需要在增

加轨迹与改善市场模型之间分配。利用可观测的估计方差、层级差异和模型检验来决定每期计算投入，有望在固定总成本下形成更有效的在线学习程序。相应理论需要处理这些选择依赖历史信息的方式，并保留可预测性与误差控制。

第二个方向是参考点进入策略状态后的联合敏感性。本文的显式参考点分解采用隔离耦合条件，使同一参数下的财富路径与得分可以共享。若策略特征直接含有参考点或相对财富，改变参考点还会改变动作分布及后续财富。建立这种联合变化下的目标与梯度稳定性，需要同时分析参考递推和策略分布的扰动，也能够扩展模型对即时参考依赖决策的表达。

第三个方向是长期财富尺度与行为校准。当前有限时域模型在统一有界分析域上给出结论，长期连续积累可能使该条件变得保守。可以进一步研究适合长期投资的矩条件及相应估计器，同时检验价值平滑与概率正则化对行为解释的影响。结合个体交易记录校准参考适应，并在留出决策上检验策略响应，将有助于连接数学上的参考依赖与实际观察到的投资行为。

总体而言，本文将历史适应机制、分布型梯度估计和时变非凸优化组织为同一分析过程。参考点决定如何评价轨迹，统计估计决定能够获得怎样的更新方向，在线定理则说明这些方向在变化环境中的累计表现。该框架使后续投资比较能够围绕清楚的目标与误差来源展开，也为其他具有动态比较基准的序贯决策问题提供了可延伸的研究起点。

参考文献

- [1] KAHNEMAN D, TVERSKY A. Prospect theory: An analysis of decision under risk [J/OL]. *Econometrica*, 1979, 47(2): 263-291. DOI: [10.2307/1914185](https://doi.org/10.2307/1914185).
- [2] TVERSKY A, KAHNEMAN D. Advances in prospect theory: Cumulative representation of uncertainty[J/OL]. *Journal of Risk and Uncertainty*, 1992, 5(4): 297-323. DOI: [10.1007/BF00122574](https://doi.org/10.1007/BF00122574).
- [3] A. P L, JIE C, FU M, et al. Cumulative prospect theory meets reinforcement learning: Prediction and control[A/OL]. 2016. arXiv: [1506.02632](https://arxiv.org/abs/1506.02632). <https://arxiv.org/abs/1506.02632>.
- [4] LEPEL O, BARAKAT A. Policy gradients for cumulative prospect theory in reinforcement learning[J/OL]. *Transactions on Machine Learning Research*, 2026. <https://arxiv.org/abs/2410.02605v5>.
- [5] RAMASUBRAMANIAN B, NIU L, CLARK A, et al. Reinforcement learning beyond expectation[A/OL]. 2021. arXiv: [2104.00540](https://arxiv.org/abs/2104.00540). <https://arxiv.org/abs/2104.00540>.
- [6] LALMOHAMMED S, GUPTA K, SHAH A, et al. Modeling human behavior without humans: Prospect theoretic multi-agent reinforcement learning[C]//Proceedings of the 42nd International Conference on Machine Learning (ICML). PMLR, 2025.
- [7] ARKES H R, HIRSHLEIFER D, JIANG D, et al. Reference point adaptation: Tests in the domain of security trading[J/OL]. *Organizational Behavior and Human Decision Processes*, 2008, 105(1): 67-81. DOI: [10.1016/j.obhdp.2007.04.005](https://doi.org/10.1016/j.obhdp.2007.04.005).
- [8] ARKES H R, HIRSHLEIFER D, JIANG D, et al. A cross-cultural study of reference point adaptation: Evidence from china, korea, and the US[J/OL]. *Organizational Behavior and Human Decision Processes*, 2010, 112(2): 99-111. DOI: [10.1016/j.obhdp.2010.02.002](https://doi.org/10.1016/j.obhdp.2010.02.002).
- [9] HE X D, YANG L. Realization utility with adaptive reference points[J/OL]. *Mathematical Finance*, 2019, 29(2): 409-447. DOI: [10.1111/mafi.12182](https://doi.org/10.1111/mafi.12182).
- [10] KONG L, QIN C, YUE X. Realization utility with path-dependent reference points [J/OL]. *SIAM Journal on Financial Mathematics*, 2022, 13(3): 1063-1111. DOI: [10.1137/21M1411457](https://doi.org/10.1137/21M1411457).

-
- [11] JIE C, PRASHANTH L A, FU M C, et al. Stochastic optimization in a cumulative prospect theory framework[J/OL]. IEEE Transactions on Automatic Control, 2018, 63(9): 2867-2882. DOI: [10.1109/TAC.2017.2777469](https://doi.org/10.1109/TAC.2017.2777469).
- [12] HAZAN E, SINGH K, ZHANG C. Efficient regret minimization in non-convex games [C]//International Conference on Machine Learning (ICML). PMLR, 2017: 1433-1441.
- [13] AYDORE S, ZHU T, FOSTER D. Dynamic local regret for non-convex online forecasting[C]//Advances in Neural Information Processing Systems (NeurIPS): Vol. 32. 2019.
- [14] HALLAK N, MERTIKOPOULOS P, CEVHER V. Regret minimization in stochastic non-convex learning via a proximal-gradient approach[C]//International Conference on Machine Learning (ICML). PMLR, 2021: 4008-4018.
- [15] RHEE C H, GLYNN P W. Unbiased estimation with square root convergence for SDE models[J/OL]. Operations Research, 2015, 63(5): 1026-1043. DOI: [10.1287/opre.2015.1404](https://doi.org/10.1287/opre.2015.1404).
- [16] GODA T, KITADE W. Constructing unbiased gradient estimators with finite variance for conditional stochastic optimization[J/OL]. Mathematics and Computers in Simulation, 2023, 204: 743-763. <https://arxiv.org/abs/2206.01991>. DOI: [10.1016/j.matcom.2022.09.012](https://doi.org/10.1016/j.matcom.2022.09.012).
- [17] VAN DER VAART A W. Asymptotic statistics[M]. Cambridge University Press, 1998.
- [18] TSYBAKOV A B. Introduction to nonparametric estimation[M]. Springer, 2009.
- [19] MARKOWITZ H. Portfolio selection[J/OL]. The Journal of Finance, 1952, 7(1): 77-91. DOI: [10.1111/j.1540-6261.1952.tb01525.x](https://doi.org/10.1111/j.1540-6261.1952.tb01525.x).
- [20] FAMA E F, FRENCH K R. Common risk factors in the returns on stocks and bonds[J/OL]. Journal of Financial Economics, 1993, 33(1): 3-56. DOI: [10.1016/0304-405X\(93\)90023-5](https://doi.org/10.1016/0304-405X(93)90023-5).
- [21] ANDRÉ E, COQUERET G. Dirichlet policies for reinforced factor portfolios[A]. 2021. arXiv: [2011.05381](https://arxiv.org/abs/2011.05381).
- [22] ODEAN T. Are investors reluctant to realize their losses?[J]. The Journal of finance, 1998, 53(5): 1775-1798.

附录

第一节 主要符号与记号约定

表 6-1 列出本文的主要符号。时期编号为 k ，总时期数为 K ，日历年份为 u ，每期包含 h 个决策步； $X_{k,h}$ 与 $r_{k,h}$ 表示第 k 期的终端财富与终端参考点。条件统计结论固定期初信息 $\mathcal{F}_k$ ，求梯度时固定期初财富、市场信息、持仓与参考点。辅助常数和采样变量在正文首次使用处定义。

表 6-1 主要符号及含义

符号	含义
X_u	以固定初始财富为单位的账户财富
r_u	与归一化财富采用相同单位的参考点
η_+, η_-	盈利方向与亏损方向的参考点适应率
$Y_k = X_{k,h} - r_{k,h}$	第 k 期的终端相对结果
$J_k(\theta, r_k)$	第 k 期正则化 CPT 条件目标
π_θ	参数为 θ 的 Dirichlet 投资组合策略
$G_{k,\theta}(\tau)$	完整轨迹的似然得分函数
g_k	θ_k 处的真实 CPT 策略梯度
$\hat{g}_{k,n,m}^{\text{pl}}$	内外层样本分拆的 CPT 梯度代入估计量
$\hat{g}_k^{\text{db}}$	多层去偏构造的 CPT 梯度估计量
δ_k^J, V_K	相邻时期的目标变化及其累计预算
β_k^{sim}	模拟目标与真实目标之间的梯度偏差界
$Q_k, \mathcal{E}_K$	归一化投影残差及其期望平方的时期平均
S_k	目标 J_k 的受约束一阶驻点集合
$\mathcal{R}_{\rho,w}^Q(K)$	投影残差形式的窗口动态局部遗憾
B	极小极大估计中的期望完整轨迹调用预算

第二节 参考点机制的证明

附录 2.1 命题 4.1 的证明

证明：对路径 A ，中间参考点为 $(1 - \eta_+)r_0 + \eta_+H$ 。由假设指定的第二步分支可得

$$r_A = (1 - \eta_-)((1 - \eta_+)r_0 + \eta_+H) + \eta_-C.$$

对路径 B ，中间参考点为 $(1 - \eta_-)r_0 + \eta_-L_w$ ，因此

$$r_B = (1 - \eta_+)((1 - \eta_-)r_0 + \eta_-L_w) + \eta_+C.$$

两式相减后，含 r_0 的项相互抵消，从而得到式 (4-2)。对确定性结果 y ，端点归一化使其 CPT 值等于 $v_+(y) - v_-(y)$ ：相应的生存函数在效用值以下等于 1，在效用值以上等于 0。对于本文规定的价值函数，这一带符号变换严格递增。因此，不同的确定性相对结果对应不同的 CPT 值。

固定财富值 x 。映射 $r \mapsto \Phi(r, x)$ 在 $r = x$ 处连续，并且在 $r \leq x$ 时斜率为 $1 - \eta_+$ ，在 $r > x$ 时斜率为 $1 - \eta_-$ 。若 r, r' 位于 x 的同一侧，Lipschitz 界可由对应斜率直接得到。若二者分处 x 两侧，则在 x 处分割区间并将两段上界相加。因此

$$|\Phi(r, x) - \Phi(r', x)| \leq (1 - \eta_{\min})|r - r'|.$$

沿共同财富路径逐步归纳，即得式 (4-3)。当终端财富相同时，进一步有 $|Y - Y'| \leq \chi_h|r - r'|$ 。

对 $x > 0$,

$$u'_{\alpha, \varepsilon_v}(x) = \alpha x(x^2 + \varepsilon_v^2)^{\alpha/2-1}.$$

利用 $x \leq \sqrt{x^2 + \varepsilon_v^2}$ 和 $\alpha - 1 \leq 0$ ，可将该导数上界为 $\alpha \varepsilon_v^{\alpha-1}$ 。导数在零点的极限为零，所以与正部、负部映射复合后，函数在零点两侧仍连续可微，并具有所声明的全局 Lipschitz 上界。分别应用收益侧与损失侧的 Lipschitz 不等式并相加，便得到 $\Omega(s) = (L_v^+ + L_v^-)s$ 。

在假设 2.4 下，对两个不同的初始参考点使用相同的动作抽样与市场抽样。

记 $V_{\pm} = v_{\pm}(Y)$ 、 $V'_{\pm} = v_{\pm}(Y')$ ，并令 $S_{\pm}, S'_{\pm}$ 分别为对应的生存函数。对任意由 B_v 控制的非负随机变量 V, V' ，Fubini 定理与该耦合给出

$$\int_0^{B_v} |\mathbb{P}(V > z) - \mathbb{P}(V' > z)| dz \leq \mathbb{E} \int_0^{B_v} |\mathbf{1}\{V > z\} - \mathbf{1}\{V' > z\}| dz = \mathbb{E}|V - V'|. \quad (6-1)$$

逐点连续模将收益侧与损失侧价值差之和控制在 $D_h(|r - r'|)$ 。对两个 CPT 积分应用中值上界 $|w^{\varepsilon}(p) - w^{\varepsilon}(q)| \leq C_1|p - q|$ ，即可得到式 (4-4)。

对于梯度结论，使用已经独立证明的定理 4.1。在该恒等式中对指示变量作中心化，只会减去一个确定性标量与零均值得分的乘积。因此可以使用

$$\varphi(\tau) = \int_0^{B_v} (w_+^{\varepsilon})'(S_+(z)) \mathbf{1}\{V_+ > z\} dz - \int_0^{B_v} (w_-^{\varepsilon})'(S_-(z)) \mathbf{1}\{V_- > z\} dz$$

以及 $\nabla J = \mathbb{E}[G\varphi]$ 。耦合后的财富路径和动作路径具有相同特征，也具有相同的 G 。对收益侧或损失侧中的任一侧，有

$$\begin{aligned} & |(w^{\varepsilon})'(S) \mathbf{1}\{V > z\} - (w^{\varepsilon})'(S') \mathbf{1}\{V' > z\}| \\ & \leq C_1 |\mathbf{1}\{V > z\} - \mathbf{1}\{V' > z\}| + C_2 |S - S'|. \end{aligned}$$

将上式乘以 $\|G\|_2$ ，对 z 积分后取期望，再把收益侧与损失侧相加。第一项逐路径由 $C_1 \mathbb{E}\|G\|_2 D_h(|r - r'|)$ 控制。固定条件环境后，第二项中的生存函数差是确定量；式 (6-1) 将两侧生存函数差的积分之和控制在 $D_h(|r - r'|)$ 。最后使用 $\mathbb{E}\|G\|_2 \leq \sqrt{C_{G,2}}$ ，即可得到式 (4-5)。整个论证只使用得分的矩界，没有使用逐点有界得分，也没有要求结果变量具有密度。 $\square$

第三节 CPT 梯度与估计量的证明

附录 3.1 定理 4.1 的证明

引理 6.1 (Dirichlet 似然矩与支配条件): 在假设 2.1 的紧参数域与参数无关转移核等基础条件下，对每个有界且不显含参数的轨迹泛函，轨迹似然都可以在积分号下求两次导数。对任意固定实数 $p \geq 1$ ，存在有限的一致常数 $C_{G,p}$ ，使得

$$\mathbb{E}_{\theta} \|G\|_2^p \leq C_{G,p}, \quad \mathbb{E}_{\theta} \|H_{\text{lik}}\|_{\text{op}} \leq C_H < \infty, \quad H_{\text{lik}} = \nabla_{\theta}^2 \log p_{\theta}(\tau).$$

这些常数可以依赖 p, d, N, h, Q_f 以及参数的紧邻域。上述界约束得分的固定阶矩，得分自身仍可因极小权重而任意增大。

证明：选取 Θ 的一个有界开邻域 O ，使其闭包包含在允许的参数域内，并令 $B_\theta = \sup_{\theta \in \bar{O}} \|\theta\|_2$ 。对所有状态和 $\theta \in O$ ，一致地有

$$\underline{a} = e^{-B_\theta Q_f} \leq a_i \leq e^{B_\theta Q_f} = \bar{a}, \quad (N+1)\underline{a} \leq a_\Sigma \leq (N+1)\bar{a}.$$

这些不等式由 $\theta^\top q_i$ 上的柯西施瓦茨不等式得到。令 $t = \underline{a}/2$ 。给定采取动作前的状态，Dirichlet 边缘分布的负矩为

$$\mathbb{E}[\omega_i^{-t} | s] = \frac{\Gamma(a_\Sigma)\Gamma(a_i - t)}{\Gamma(a_i)\Gamma(a_\Sigma - t)}. \quad (6-2)$$

所有 Gamma 函数自变量都落在 $(0, \infty)$ 的紧子集上，因此该比值具有有限的一致上界。该公式可以直接对 Dirichlet 密度积分得到：把指数 $a_i - 1$ 替换为 $a_i - t - 1$ ，再取两个归一化常数之比。对 $x \in (0, 1]$ ，令 $z = -\log x \geq 0$ 。由于 $z^p e^{-tz}$ 在 $[0, \infty)$ 上有界，故 $|\log x|^p \leq C_{p,t} x^{-t}$ 。因此，式 (6-2) 控制了每个固定阶数的条件对数矩。

单次动作对应的得分贡献为

$$G_u = \sum_i a_i q_i \Lambda_i, \quad \Lambda_i = \log \omega_i - \psi_0(a_i) + \psi_0(a_\Sigma).$$

在浓度参数域内，除对数项外的所有系数与双伽马函数项均一致有界。结合不等式 $\|\sum_{j=1}^m x_j\|_2^p \leq m^{p-1} \sum_{j=1}^m \|x_j\|_2^p$ 、条件期望以及对资产和日期的有限求和，可得到一致常数 $C_{G,p}$ 。后续状态依赖先前动作，并不要求各期得分贡献相互独立；逐期条件矩界已经足够。

以 ψ_1 表示三伽马函数，并令 $q_\Sigma = \sum_i a_i q_i$ 。在固定轨迹上求导时，每个 q_i 均视为固定量，从而得到

$$H_{\text{lik},u} = \sum_i a_i q_i q_i^\top \Lambda_i + \psi_1(a_\Sigma) q_\Sigma q_\Sigma^\top - \sum_i \psi_1(a_i) a_i^2 q_i q_i^\top. \quad (6-3)$$

系数有界及条件一阶对数矩有界共同推出 $\mathbb{E}\|H_{\text{lik},u}\|_{\text{op}}$ 的一致上界。对 h 个日期求和便得到 C_H 。

为了证明可以在轨迹积分号下求导，定义参考概率律 ν 。该概率律采用相同

的市场转移核与初始状态，并对每项资产使用与状态无关的 Dirichlet 动作浓度 $b_* := \underline{a}/2$ 。给定一条完整轨迹，其似然比是有限时域内下列因子的乘积：

$$\frac{\Gamma(a_\Sigma)}{\prod_i \Gamma(a_i)} \frac{\Gamma(b_*)^{N+1}}{\Gamma((N+1)b_*)} \prod_i \omega_i^{a_i - b_*}.$$

归一化因子及其关于参数的一阶、二阶导数均一致有界。每个指数 $a_i - b_*$ 至少为 $\underline{a}/2 > 0$ 。乘积的一阶与二阶导数只会引入有界系数，以及至多两个对数项的乘积。对每个这样的幂次， $x^{\underline{a}/2} |\log x|^j$ 在 $(0, 1]$ 上有界。因此，似然比及其前两阶导数相对于概率测度 ν 都存在有限的常数包络。该论证也覆盖不同日期之间的交叉项。

由此，支配微分适用于每个有界轨迹泛函。特别地，

$$\nabla_\theta^2 \mathbb{E}_\theta F = \mathbb{E}_\theta [F(H_{\text{lik}} + GG^\top)]. \quad (6-4)$$

条件市场转移核不直接依赖参数，所以它们在似然比中相消。该论证不要求收益规律相对于 Lebesgue 测度具有密度。对每个冻结模拟器，同样的证明成立，并且共同参数域给出一致常数。 $\square$

下面证明定理 4.1 中的梯度恒等式与光滑性结论。

证明：固定真实模型或模拟模型的条件轨迹分布以及一个参数值。由似然条件，对任意有界可测且不显含参数的轨迹泛函 F ，有

$$\nabla_\theta \mathbb{E}_\theta F = \mathbb{E}_\theta [FG]. \quad (6-5)$$

特别地， $\mathbb{E}G = \nabla 1 = 0$ ；对每个阈值 z ，

$$\nabla S_\pm(z) = \mathbb{E}[\mathbf{1}\{v_\pm(Y) > z\}G] = \mathbb{E}[(\mathbf{1}\{v_\pm(Y) > z\} - S_\pm(z))G].$$

由于 $\|\nabla S_\pm(z)\|_2 \leq \sqrt{C_{G,2}}$ 且 $|(w_\pm^\varepsilon)'| \leq C_1$ ，导数的被积函数在有限区间 $[0, B_v]$ 上存在可积上界。应用链式法则并在积分号下求导，即得式 (4-7)。又因为 $|\psi| \leq 2B_v C_1$ 且 $\mathbb{E}\|G\|_2 < \infty$ ，Fubini 定理适用，并同时给出式 (4-8)。这里将路径递推整体视为固定的可测轨迹泛函，不对历史期初状态求导。

为完整证明梯度的 Lipschitz 连续性，使用引理 6.1 中的二阶支配似然微分，

得到

$$\nabla^2 S_{\pm}(z) = \mathbb{E}[\mathbf{1}\{v_{\pm}(Y) > z\}(H_{\text{lik}} + GG^{\top})].$$

因此, $\|\nabla^2 S_{\pm}(z)\|_{\text{op}} \leq C_H + C_{G,2}$, 且上述一阶导数满足 $\|\nabla S_{\pm}(z)\|_2 \leq \sqrt{C_{G,2}}$. 对任一概率权重函数应用 Hessian 链式法则, 得到

$$\nabla^2 w_{\pm}^{\varepsilon}(S_{\pm}) = (w_{\pm}^{\varepsilon})''(S_{\pm})\nabla S_{\pm}\nabla S_{\pm}^{\top} + (w_{\pm}^{\varepsilon})'(S_{\pm})\nabla^2 S_{\pm}.$$

在每个阈值处, 该 Hessian 的算子范数至多为 $C_2 C_{G,2} + C_1(C_{G,2} + C_H)$. 对两个长度均为 B_v 的区间积分, 得到式 (4-9) 的上界。对 $\theta, \theta' \in \Theta$, 二者之间的线段包含于 Θ ; 沿该线段对 Hessian 积分, 得到 $\|\nabla J(\theta') - \nabla J(\theta)\|_2 \leq L\|\theta' - \theta\|_2$. 参考点递推以及 Y 中可能存在的原子都不会妨碍该论证, 因为每个阈值指示变量都是有界且不显含参数的轨迹泛函。□

附录 3.2 命题 4.2 的证明

证明: 固定时期初始条件、参数与模拟规律, 以 S 表示相应的精确模拟生存函数。在式 (3-7) 中将每个经验生存函数替换为对应的精确模拟生存函数, 定义 $T_k^{(\infty)}$. 先对外层轨迹作条件化。对 $I \in \{0, 1\}$,

$$f'(p, I) = (w^{\varepsilon})''(p)(I - p) - (w^{\varepsilon})'(p), \quad f''(p, I) = (w^{\varepsilon})'''(p)(I - p) - 2(w^{\varepsilon})''(p).$$

因此 $|f''| \leq H_f$. 对每个固定阈值, $\hat{S}_n$ 是均值为 S 的独立 Bernoulli 变量的样本均值, 并且独立于外层轨迹。于是

$$\mathbb{E}(\hat{S}_n - S) = 0, \quad \mathbb{E}(\hat{S}_n - S)^2 = S(1 - S)/n \leq 1/(4n).$$

带积分余项的 Taylor 定理给出

$$|\mathbb{E}[f(\hat{S}_n, I) | \tau^{(0)}] - f(S, I)| \leq H_f/(8n).$$

在两个长度为 B_v 的区间上积分, 乘以外层得分, 再使用 $\mathbb{E}\|G_0\|_2 \leq \sqrt{C_{G,2}}$, 可得 $\|\mathbb{E}T_k^{(n)} - \mathbb{E}T_k^{(\infty)}\|_2 \leq A_b/n$. 定理 4.1 表明 $\mathbb{E}T_k^{(\infty)} = \tilde{g}_k$. 另外, $\|T_{k,0}\|_2 \leq 2B_v C_1 \|G_0\|_2$, 从而得到基础层的上界 C_0 .

下面证明全样本与半样本耦合差分的界。令 $n = n_{\ell} = 2m$. 在一个固定阈值处, 以 x 和 y 表示两个半样本的生存概率均值, 则完整样本均值恰为 $(x + y)/2$.

围绕该中点展开 Taylor 公式, 得到

$$\left| f\left(\frac{x+y}{2}, I\right) - \frac{f(x, I) + f(y, I)}{2} \right| \leq \frac{H_f}{8}(x-y)^2. \quad (6-6)$$

为了控制四阶矩, 将两个半样本中的 Bernoulli 变量配对, 并令 $\zeta_j = I_j^{(1)} - I_j^{(2)}$ 。这些变量相互独立、均值为零, 而且满足 $\mathbb{E}\zeta_j^2 = \mathbb{E}\zeta_j^4 = 2S(1-S) \leq 1/2$ 。展开四次方并消去奇数次交叉项, 可得

$$\begin{aligned} \mathbb{E}|x-y|^4 &= \frac{m\mathbb{E}\zeta_1^4 + 3m(m-1)(\mathbb{E}\zeta_1^2)^2}{m^4} \\ &\leq \frac{3}{4m^2} = \frac{3}{n^2}. \end{aligned} \quad (6-7)$$

以 $R_+(z), R_-(z)$ 表示标量中点余项。在两个互不相交区间的并集上应用柯西施瓦茨不等式, 得到

$$\left| \int R_+ - \int R_- \right|^2 \leq 2B_v \left(\int |R_+|^2 + \int |R_-|^2 \right).$$

内层样本上界对外层指示变量一致成立。先给定外层轨迹, 应用式 (6-6) 至式 (6-7), 再对外层轨迹取期望, 可得

$$\mathbb{E}\|\Delta_{k,\ell}\|_2^2 \leq C_{G,2}(2B_v)(2B_v) \frac{H_f^2}{64} \frac{3}{n_\ell^2} = D2^{-2\ell}.$$

该上界允许不同阈值之间存在依赖, 也允许收益侧指示变量与损失侧指示变量之间存在依赖。

尽管两个半样本统计量共享同一条外层轨迹, 每个半样本统计量的边缘分布仍与 $T_{k,\ell-1}$ 相同。因此, 对 $\ell \geq 1$, $\mathbb{E}\Delta_{k,\ell} = \mathbb{E}T_{k,\ell} - \mathbb{E}T_{k,\ell-1}$ 。矩界进一步给出

$$\sum_{\ell=0}^{\infty} \mathbb{E}\|\Delta_{k,\ell}\|_2 \leq \sqrt{C_0} + \sqrt{D} \sum_{\ell=1}^{\infty} 2^{-\ell} < \infty.$$

绝对可积性使得独立随机层级下可以交换求和与期望, 故

$$\mathbb{E}Z = \sum_{\ell=0}^{\infty} \mathbb{E}\Delta_{k,\ell} = \lim_{\ell \rightarrow \infty} \mathbb{E}T_{k,\ell} = \tilde{g}_k.$$

同样, 利用非负项求和可得

$$\mathbb{E}\|Z\|_2^2 = \sum_{\ell=0}^{\infty} \frac{\mathbb{E}\|\Delta_{k,\ell}\|_2^2}{p_\ell} \leq \frac{C_0 + D \sum_{\ell=1}^{\infty} 2^{-(2-a)\ell}}{1 - 2^{-a}} = C_{\text{db}}.$$

一次重复恰好使用 $1 + N_0 2^\ell$ 条原始轨迹。对该成本求和, 得到式 (4-12) 中的 C_{cost} 。上述两个收敛的几何级数分别要求 $a < 2$ 和 $a > 1$ 。排序带来的层级因子

为 $O(1 + \ell)$ ，乘上该因子后成本级数仍然收敛。

对于有限层级上限，令 $p_{\leq L_{\max}} = \sum_{j=0}^{L_{\max}} p_j$ 。截断层级在 $0, \dots, L_{\max}$ 上的分布为 $q_\ell = p_\ell / p_{\leq L_{\max}}$ 。于是

$$\mathbb{E} Z^{\text{db}, (L_{\max})} = \sum_{\ell=0}^{L_{\max}} \mathbb{E} \Delta_{k, \ell} = \mathbb{E} T_{k, L_{\max}},$$

$$\mathbb{E} \|Z^{\text{db}, (L_{\max})}\|_2^2 = p_{\leq L_{\max}} \sum_{\ell=0}^{L_{\max}} \frac{\mathbb{E} \|\Delta_{k, \ell}\|_2^2}{p_\ell} \leq C_{\text{db}}.$$

结合 $n_{L_{\max}} = N_0 2^{L_{\max}}$ 下的期望偏差界，即可证明其余结论。这里使用的是指定的归一化有限层级分布。若先按原概率抽取层级，再直接裁剪所抽到的层级且仍沿用原概率，便不是本证明分析的构造。□

附录 3.3 定理 4.2 的证明

证明：固定条件环境。对于相互独立的完整重复样本，各中心化输出之间的交叉协方差为零。因此

$$\text{tr Var} \left(M^{-1} \sum_{b=1}^M Z_b \right) = M^{-1} \text{tr Var}(Z_1) \leq C_{\text{db}}/M.$$

未截断时，均值为 $\tilde{g}_k$ ；层级上限为 $L_{\max}$ 时，均值为 $\mathbb{E} T_{k, L_{\max}}$ 。作如下分解：

$$\mathbb{E} \|\hat{g} - g_k\|_2^2 = \text{tr Var}(\hat{g}) + \|\mathbb{E} \hat{g} - g_k\|_2^2.$$

确定性的条件偏差由模拟偏差与截断偏差相加得到。应用 $\|a + b\|_2^2 \leq 2\|a\|_2^2 + 2\|b\|_2^2$ ，即得式 (4-17)。

对于代入估计量，以 $\mathcal{I}$ 表示完整的内层样本。给定 $\mathcal{I}$ 后， m 个外层项相互独立，且每一项的二阶矩至多为 C_0 。以 $\mu(\mathcal{I})$ 表示单个外层项的条件均值。全方差公式的迹形式给出

$$\text{tr Var}(\hat{g}_{n,m}^{\text{pl}}) \leq C_0/m + \mathbb{E} \|\mu(\mathcal{I}) - \mathbb{E} \mu(\mathcal{I})\|_2^2. \quad (6-8)$$

替换一条内层轨迹时，每个阈值处任一经验生存函数的改变量至多为 $1/n$ 。由于 $|f'(p, I)| \leq C_1 + C_2$ ，由此造成的条件均值改变量的范数至多为 $2B_v(C_1 + C_2)\sqrt{C_{G,2}}/n$ 。

向量形式的 Efron 与 Stein 不等式可以通过对每个坐标应用标量形式后求

和得到。以 $\mathcal{I}^{(i)}$ 表示将第 i 个内层样本独立替换后形成的样本组，则

$$\mathbb{E}\|\mu(\mathcal{I}) - \mathbb{E}\mu(\mathcal{I})\|_2^2 \leq \frac{1}{2} \sum_{i=1}^n \mathbb{E}\|\mu(\mathcal{I}) - \mu(\mathcal{I}^{(i)})\|_2^2 \leq \frac{2B_v^2(C_1 + C_2)^2 C_{G,2}}{n}.$$

由命题 4.2，相对于 $\tilde{g}_k$ 的均值偏差至多为 A_b/n 。加入模拟偏差，使用同一个两项平方不等式，并与式 (6-8) 合并，即得式 (4-18)。该推导完整保留了多个外层项共享同一内层样本所造成的依赖关系。 $\square$

附录 3.4 定理 4.3 的证明

证明：对几乎处处成立的固定条件环境，中心化向量 $Z_b - \tilde{g}_k$ 独立同分布且具有有限协方差。对任意确定的 $t \in \mathbb{R}^d$ ，标量变量 $t^\top(Z_b - \tilde{g}_k)$ 独立同分布，均值为零，方差为 $t^\top \Sigma_k t$ 。标量独立同分布中心极限定理与 Cramér 和 Wold 定理共同推出式 (4-19)，并允许协方差矩阵奇异。这些概率极限定理作用于固定的条件分布，不涉及随样本量变化的模型序列。

每个协方差矩阵元素都具有有限一阶矩，因为 $\mathbb{E}|Z_i Z_j| \leq (\mathbb{E}Z_i^2 \mathbb{E}Z_j^2)^{1/2} < \infty$ 。对各矩阵元素及样本均值应用独立同分布强大数定律，可得经验协方差的一致性。若 Σ_k 正定，则逆平方根映射在 Σ_k 的某个邻域内连续。随着概率趋于 1，经验协方差落入该邻域；在其补集上任意定义标准化统计量，不会改变极限。再由 Slutsky 定理得到学生化结论。整个论证只使用有限二阶矩。若模拟器存在误差，把中心改为 g_k 会额外引入不消失的确定性位移 $\sqrt{M}(\tilde{g}_k - g_k)$ ，因此不能作这一替换。 $\square$

第四节 驻点集合漂移与动态局部遗憾的证明

附录 4.1 引理 4.1 的证明

证明：映射 $d(g)$ 是 g/a_0 在闭单位球上的欧氏投影。欧氏投影的非扩张性给出

$$\|d(g) - d(g')\|_2 \leq a_0^{-1} \|g - g'\|_2. \quad (6-9)$$

再利用 Π_Θ 的非扩张性以及相邻时期采用相同的步长，可得

$$\sup_{\theta \in \Theta} \|Q_{k+1}(\theta) - Q_k(\theta)\|_2 \leq \delta_k^g / a_0.$$

对任意 $\theta \in S_k$, 由驻点集的定义有 $Q_k(\theta) = 0$ 。因此, 新时期的误差界将上述残差扰动转换为集合距离界, 得到 $\text{dist}(\theta, S_{k+1}) \leq \kappa \delta_k^g / a_0$ 。对旧驻点集中的 θ 取上确界, 即得到一个方向上的有向 Hausdorff 距离界。交换两个时期, 并使用同一个统一常数 κ , 即可得到反方向的有向 Hausdorff 距离界。两个驻点集都是 Θ 的非空紧子集, 故其 Hausdorff 距离有定义, 并满足引理所述上界。 $\square$

附录 4.2 投影上升不等式

引理 6.2 (单步归一化投影上升): 设 J 在非空闭凸集 Θ 上是 L 光滑的, $x \in \Theta$, $g = \nabla J(x)$, 且 $\|g\|_2 \leq B_g$ 。对任意有限向量 $\hat{g}$, 定义

$$x^+ = \Pi_{\Theta}(x + \gamma \mathbf{d}(\hat{g})), \quad Q(x) = \gamma^{-1} \{ \Pi_{\Theta}(x + \gamma \mathbf{d}(g)) - x \}.$$

若 $a_0, \gamma > 0$, $\gamma L \leq a_0$, 并令 $C_g = \max(B_g, a_0)$, 则

$$J(x^+) - J(x) \geq \frac{a_0 \gamma}{8} \|Q(x)\|_2^2 - \frac{5C_g \gamma}{4a_0^2} \|\hat{g} - g\|_2^2. \quad (6-10)$$

证明: 记 $s = x^+ - x$, $c_g = \max(\|g\|_2, a_0)$, 并令 $\delta = \mathbf{d}(\hat{g}) - \mathbf{d}(g)$ 。将可行点 x 代入投影变分不等式, 得到

$$\langle \mathbf{d}(\hat{g}), s \rangle \geq \|s\|_2^2 / \gamma.$$

由于 $g = c_g \mathbf{d}(g)$, 结合 L 光滑函数的下界, 可逐行得到

$$\begin{aligned} J(x+s) - J(x) &\geq \langle g, s \rangle - \frac{L}{2} \|s\|_2^2 \\ &\geq (c_g / \gamma - L/2) \|s\|_2^2 - c_g \|\delta\|_2 \|s\|_2 \\ &\geq (3c_g / (4\gamma) - L/2) \|s\|_2^2 - c_g \gamma \|\delta\|_2^2 \\ &\geq \frac{c_g}{4\gamma} \|s\|_2^2 - c_g \gamma \|\delta\|_2^2. \end{aligned} \quad (6-11)$$

第一行来自光滑性下界。第二行将 $g = c_g \mathbf{d}(g)$ 代入, 并把 $\mathbf{d}(g)$ 写成 $\mathbf{d}(\hat{g}) - \delta$, 随后使用投影变分不等式控制主项。第三行使用 $c_g uv \leq c_g u^2 / (4\gamma) + c_g \gamma v^2$, 其中 $u = \|s\|_2$, $v = \|\delta\|_2$; 第四行使用 $\gamma L \leq a_0 \leq c_g$ 。这些步骤分别保留了实际位移的正贡献和方向误差的二次代价。

令 $t = \Pi_{\Theta}(x + \gamma \mathbf{d}(g)) - x = \gamma Q(x)$ 。投影的非扩张性给出 $\|s - t\|_2 \leq \gamma \|\delta\|_2$,

进而有

$$\|s\|_2^2 \geq \frac{1}{2}\|t\|_2^2 - \gamma^2\|\delta\|_2^2.$$

将该不等式代入式 (6-11)，得到

$$J(x^+) - J(x) \geq \frac{c_g\gamma}{8}\|Q(x)\|_2^2 - \frac{5c_g\gamma}{4}\|\delta\|_2^2.$$

最后，由 $a_0 \leq c_g \leq C_g$ 以及式 (6-9)，可得式 (6-10)。即使投影消除了整个可行步长，该不等式仍然成立。 $\square$

附录 4.3 定理 4.4 的证明

证明： 逐期应用引理 6.2，先对 $\mathcal{F}_k$ 条件化，再取全期望。记 $\Delta J_k = J_k(\theta_{k+1}, r_k) - J_k(\theta_k, r_k)$ ，则

$$\frac{a_0\gamma}{8}\mathbb{E}\|Q_k(\theta_k)\|_2^2 \leq \mathbb{E}\Delta J_k + \frac{5C_g\gamma}{4a_0^2}\mathbb{E}e_k^2. \quad (6-12)$$

这里，左侧衡量第 k 期真实投影残差的平方，右侧由同一期目标的改进量和方向估计误差构成。

对任意已经实现的目标函数序列和迭代点序列，都有以下逐路径恒等式与上界：

$$\begin{aligned} \sum_{k=1}^K \Delta J_k &= J_K(\theta_{K+1}, r_K) - J_1(\theta_1, r_1) \\ &+ \sum_{k=1}^{K-1} [J_k(\theta_{k+1}, r_k) - J_{k+1}(\theta_{k+1}, r_{k+1})] \leq 2B_J + V_K. \end{aligned} \quad (6-13)$$

第一项由目标值的统一界控制，求和中的每一项则在同一参数 θ_{k+1} 处比较相邻时期目标，并由变化预算 V_K 控制。该恒等式完全来自代数上的望远镜展开；即使下一期情境由当前过程内生生成，恒等式仍然成立。对式 (6-12) 从 $k = 1$ 到 K 求和，使用式 (6-13)，再除以 $a_0\gamma K/8$ ，即可证明式 (4-21)。其中常数 8 和 10 正是由该除法得到。对本文实现的估计器，定理 4.2 进一步给出式 (4-22) 中的均方误差代换。

下面证明窗口结论。令 $\alpha_{k,j} = \rho^j/A_k$ 。由于这些系数非负且和为一，Jensen

不等式给出

$$\|\bar{Q}_k\|_2^2 \leq \sum_{j=0}^{\min(w-1, k-1)} \alpha_{k,j} \|Q_{k-j}(\theta_{k-j})\|_2^2.$$

每个逐期残差最多出现在 w 个窗口中，并且每个系数至多为一。因此，对 k 求和可得 $\mathcal{R}_{\rho,w}^Q(K) \leq w \sum_k \|Q_k(\theta_k)\|_2^2$ 。当窗口长度随时间增长时，因同一残差可能被多个窗口重复计入，因子 w 必须保留。

最后，在中间目标 $J(P_{k+1}, z_{k+1}, r_k; \theta)$ 处拆分相邻目标之差。由三角不等式和式 (4-4)，得到

$$\delta_k^J \leq \delta_k^{\text{nr}} + C_1 D_h(|r_{k+1} - r_k|).$$

对该逐路径不等式求和，即得到式 (4-24)。 δ_k^{nr} 保留了市场变化、起始财富、上一期持仓以及市场初始状态的影响。证明中没有假定有界 Lipschitz 距离能够控制无界得分核。 $\square$

附录 4.4 推论 4.1 的证明

证明：当 $J_k \equiv J$ 时， $V_K = 0$ 。对固定的正数 a_0 和 γ ，式 (4-21) 的第一项趋于零；由平均均方误差条件，第二项也趋于零。对于时变目标，附加条件 $\mathbb{E}V_K = o(K)$ 可得到同样结论。

在精确且未截断的模拟中，可以取 $e_k^2 = C_{\text{db}}/M_k$ 。若 $M_k \rightarrow \infty$ 几乎处处成立，则 $1/M_k \rightarrow 0$ 也几乎处处成立，且 $0 \leq 1/M_k \leq 1$ 。由控制收敛定理， $\mathbb{E}[1/M_k] \rightarrow 0$ ，其 Cesàro 平均也趋于零。上述结论针对期望残差平方的平均值，不推出迭代点逐点收敛或几乎处处收敛。 $\square$

附录 4.5 推论 4.2 的证明

证明：对每一个纳入分析的迭代点，可选误差界给出 $\text{dist}^2(\theta_k, S_k) \leq \kappa^2 \|Q_k(\theta_k)\|_2^2$ 。两边取期望后再对时期求平均，将式 (4-21) 代入即可证明有限时间结论；极限结论由推论 4.1 推出。该证明没有使用 Jensen 不等式的逆命题，也没有使用驻点集漂移引理。 $\square$

第五节 极小极大下界的证明

附录 5.1 定理 4.5 的证明

证明：首先明确统计检验不等式所作用的投资组合轨迹实验，使后续信息界、两点检验和预算上界都对应同一个可实现的观测模型。

附录 5.1.0.1 步骤一：构造可实现子模型。考虑一只股票和现金，取 $h = 1$ 、 $c_{tc} = 0$ 、 $X_{\text{start}} = r_{\text{start}} = 1$ ，并固定 $\eta_+ \in (0, 1)$ ；同时固定任意 $\eta_- \in [0, 1]$ 。令 $q_{\text{risky}} = e_1$ 、 $q_{\text{cash}} = 0$ ，其中 e_1 是 $\mathbb{R}^d$ 中的第一个坐标向量。这里， $\theta^{[1]}$ 表示 θ 的第一个坐标，而全文其他位置的 θ_1 表示在线过程的第一个迭代点。于是，风险资产权重满足 $U \sim \text{Beta}(a_{\text{risky}}, 1)$ ，其中 $a_{\text{risky}} = e^{\theta^{[1]}}$ ，其余参数不影响该分布。令股票收益率为 $R = r_* \xi$ ，其中 $\xi \sim \text{Bernoulli}(p)$ 与 U 独立， $r_* > 0$ 固定且足够小，从而满足已声明的界。一次完整的预言机轨迹同时记录动作和收益率，因此可以观测到 ξ 。

参考点更新始终处于收益或相等分支：

$$X_{\text{end}} = 1 + r_* U \xi, \quad r_{\text{end}} = 1 + \eta_+ r_* U \xi, \quad Y = c U \xi, \quad c = (1 - \eta_+) r_* > 0.$$

这与正文中的财富和参考点递推完全一致。状态与价值均有界，特征映射有界，紧参数域则给出引理 6.1 中的统一似然界。将 p 限制在固定紧区间 $I \subset (0, 1)$ 内，不会改变这些界。按照假设 2.6 的要求，可选择共同的模型类常数，使其控制该子模型对应的常数。损失效用在此子模型中为零。整个构造直接来自投资组合轨迹，因此无需另行假设抽象梯度向量的分布。

附录 5.1.0.2 步骤二：分离真实的 CPT 梯度。令 $v = v_+$ 为固定的光滑收益价值函数，并对 $t \in [0, 1]$ 定义 $m(t) = c v'(ct)$ 。对 $t > 0$ 有 $m(t) > 0$ ，且 m 有界。在 CPT 生存积分中作变量代换 $z = v(ct)$ ，得到

$$J_p(\theta) = \int_0^1 m(t) w_+^\varepsilon \{p(1 - t^{e^{\theta^{[1]}}})\} dt. \quad (6-14)$$

具体地, 对 $0 < t < 1$, 有 $\mathbb{P}\{v(Y) > v(ct)\} = p\mathbb{P}(U > t) = p(1 - t^{e^{[1]}})$ 。当阈值高于 $v(c)$ 时, 生存概率为零, 且 $w_+^\varepsilon(0) = 0$ 。在 $\theta_0 = 0$ 处对上述有界可积表达式求导, 得到

$$\nabla J_p(0) = \mathbf{g}(p)e_1, \quad \mathbf{g}(p) = p \int_0^1 m(t)(w_+^\varepsilon)'(p(1-t))(-t \log t) dt. \quad (6-15)$$

在 a_{risky} 的任一紧正区间上, 函数 $t^{a_{\text{risky}}}|\log t|$ 都具有统一的可积上界, 因此交换微分与积分是合法的。令

$$A_v = \int_0^1 m(t)(-t \log t) dt > 0, \quad w_0 = (w_+^\varepsilon)'(0) > 0.$$

利用 $|(w_+^\varepsilon)''| \leq C_2$, 再对 p 求一次导数:

$$\begin{aligned} \mathbf{g}'(p) &= \int_0^1 m(t)(-t \log t)[(w_+^\varepsilon)'(p(1-t)) + p(1-t)(w_+^\varepsilon)''(p(1-t))] dt \\ &\geq (w_0 - 2C_2p)A_v. \end{aligned}$$

选取 $p_{\max} \in (0, 1/4]$, 使 $2C_2p_{\max} \leq w_0/2$; 当 $C_2 = 0$ 时同样可以完成这一选择。定义 $p_* = p_{\max}/2$ 、 $I = [p_*/2, 3p_*/2]$ 以及 $m_* = w_0A_v/2 > 0$ 。于是, 在整个区间 I 上均有 $\mathbf{g}'(p) \geq m_*$ 。该导数严格为正, 直接证明了梯度泛函的局部可识别性, 所需结论来自梯度对 p 的分离程度。

附录 5.1.0.3 步骤三: 停止自适应实验中的信息量。对 $B \geq 1$, 取 $p_\pm = p_* \pm \delta$, 其中 $\delta = c_*/\sqrt{B}$, 固定常数 $c_* > 0$ 将在后文取得足够小。令 $c_* \leq p_*/2$, 即可保证 $p_\pm \in I$ 。单次调用所对应的 Bernoulli 相对熵满足

$$\text{kl}(p_+ \| p_-) \leq \frac{(p_+ - p_-)^2}{p_-(1 - p_-)} \leq C_I \delta^2, \quad C_I = \frac{4}{(p_*/2)(1 - 3p_*/2)}.$$

第一个不等式是在两个 Bernoulli 似然项上分别使用 $\log x \leq x - 1$ 得到的。在任意策略查询点, p_+ 和 p_- 下的条件动作分布相同, 只有 Bernoulli 收益核不同。因此, 即使当前查询依赖此前观测, 每条新轨迹贡献的相对熵仍恰好等于上述 Bernoulli 相对熵。

为完整处理算法内部随机性, 将所有相互独立的算法随机量都纳入观测记录, 并以 N_{call} 表示停止时的调用次数。在两个模型下, 条件查询规则和停止规

则都是观测历史的同一函数。对一条长度为 n 的已观测停止历史，其似然比为

$$\prod_{j=1}^n \left(\frac{p_+}{p_-} \right)^{\xi_j} \left(\frac{1-p_+}{1-p_-} \right)^{1-\xi_j}.$$

先在每个事件 $\{N_{\text{call}} = n\}$ 上逐项相乘条件核即可得到该式，因为共同的动作、算法随机量和停止因子会相互约去。两个模型下的 N_{call} 均有有限期望，所以 $N_{\text{call}} < \infty$ 几乎处处成立，事件 $\{N_{\text{call}} = n\}$ 穷尽整个停止实验。又因为 $p_{\pm}$ 位于固定内部区间 I ，似然增量有界，其停止绝对和的期望至多为某个有限常数乘以 $\mathbb{E}_+ N_{\text{call}}$ ，从而可以交换级数与期望。事件 $\{N_{\text{call}} \geq j\}$ 在第 j 个新收益率出现之前可测，因此

$$\begin{aligned} \text{KL}(\mathbb{P}_+^{\text{tr}} \parallel \mathbb{P}_-^{\text{tr}}) &= \sum_{j \geq 1} \mathbb{E}_+ \left[\mathbf{1}\{N_{\text{call}} \geq j\} \log \frac{p_+^{\xi_j} (1-p_+)^{1-\xi_j}}{p_-^{\xi_j} (1-p_-)^{1-\xi_j}} \right] \\ &= \mathbb{E}_+ N_{\text{call}} \text{kl}(p_+ \parallel p_-) \leq BC_I \delta^2 = C_I c_*^2. \end{aligned} \quad (6-16)$$

该推导证明了期望预算和自适应停止条件下的信息界，也涵盖确定样本量这一特殊情形。进一步减小 c_* ，使 $C_I c_*^2 \leq 1/8$ 。由 Pinsker 不等式，总变差距离至多为 $1/4$ 。

附录 5.1.0.4 步骤四：从估计归约到检验。由中值定理，两个欧氏目标之间的距离满足

$$D_B = \|\mathbf{g}(p_+)e_1 - \mathbf{g}(p_-)e_1\|_2 \geq 2m_*\delta.$$

给定任意估计器，可构造一个检验，选择与估计值距离更近的目标。发生检验错误时，由三角不等式，估计值到真实目标的距离至少为 $D_B/2$ 。两个检验错误概率之和至少等于一减总变差距离。具体而言，对任意判决事件 A ，该概率和为 $\mathbb{P}_+(A^c) + \mathbb{P}_-(A) = 1 - [\mathbb{P}_+(A) - \mathbb{P}_-(A)]$ 。因此

$$\begin{aligned} \max_{s \in \{+, -\}} \mathbb{E}_s \|\hat{g} - \mathbf{g}(p_s)e_1\|_2^2 &\geq \frac{D_B^2}{8} [1 - \text{TV}(\mathbb{P}_+^{\text{tr}}, \mathbb{P}_-^{\text{tr}})] \\ &\geq \frac{3m_*^2 c_*^2}{8B}. \end{aligned}$$

任何满足模型类统一期望预算的过程，在这个两点子模型上也满足相同预算。对所有这类过程取下确界，得到模型类下界，其中 $c_{\text{lb}} = 3m_*^2 c_*^2 / 8 > 0$ 。所用检验

不等式是经典结果^[18]；上述模型嵌入和停止信息量计算给出了这些不等式在本文问题中所需的输入。

附录 5.1.0.5 步骤五：匹配的成本校准上界。对每个 $P \in \mathfrak{C}$ ，共同的原始量界给出统一的 C_{db} ，并给出命题 4.2 中的同一个 C_{cost} 。在 θ_0 处运行 $M = \lfloor B/C_{\text{cost}} \rfloor$ 次完整、相互独立且未截断的重复模拟。当层级和完成当前重复模拟所需的剩余抽样次数都作为算法状态的一部分时，总轨迹数构成一个允许的停止时刻。其期望成本满足 $MC_{\text{cost}} \leq B$ 。由精确抽样和定理 4.2，

$$\sup_{P \in \mathfrak{C}} \mathbb{E}_P \|\hat{g} - g_P\|_2^2 \leq C_{\text{db}}/M \leq 2C_{\text{db}}C_{\text{cost}}/B$$

对所有 $B \geq 2C_{\text{cost}}$ 成立。至此，在同一模型类上、针对同一目标与损失、使用同一预言机和期望原始轨迹预算，定理的上下界均已得到证明。□

第六节 实验复现细节

配套脚本 `verification_experiments.py` 执行正文中的统计量计算和递推过程。运行环境需要 Python 和 NumPy；受控实验不依赖外部市场数据或行为数据。随机种子、全部参数、原始轨迹数量、估计器汇总结果和逐期记录均保存为 JSON 与 CSV 文件。表格条目由这些已保存的输出生成，并采用与文中汇总结果相同的数值精度。估计器与学习过程的随机种子为 20260911，实际执行收益流的随机种子为 88177。逐层诊断在每个层级使用 1600 次独立重复，批量诊断使用 8192 次带截断的重复模拟。各批量结果只在所报告的不同分组规模之间复用同一个已保存样本池，回放中的学习样本则重新生成。带有限层级上限的数值模拟只表示相应的截断构造，不表示未截断模拟。

附录 6.1 多项式权重诊断中的解析偏差

记 $b = 1 - 2\varepsilon$ 、 $D_w = (1 - \varepsilon)^3 - \varepsilon^3$ ，则

$$b_{w,0} = 3\varepsilon^2 b/D_w, \quad b_{w,1} = 6\varepsilon b^2/D_w, \quad b_{w,2} = 3b^3/D_w.$$

在纯收益诊断中取 $\theta = 0$ ，有 $S(v_+(ct)) = 1 - t$ 。直接对 $1 + \log u$ 从 t 积分到 1，得到 $\mathbb{E}[(1 + \log U)\mathbf{1}\{U > t\}] = -t \log t$ 。外层样本与内层样本相互独立，并

且 $\mathbb{E}G = 0$ ，所以 $\mathbb{E}T_k^{(n)}$ 中只含 $(w^\varepsilon)'(\hat{S})\hat{S}$ 的项被消去。Bernoulli 经验均值满足 $\mathbb{E}\hat{S} = S$ 和 $\mathbb{E}\hat{S}^2 = S^2 + S(1 - S)/n$ ，因此

$$\mathbb{E}(w^\varepsilon)'(\hat{S}) = (w^\varepsilon)'(S) + b_{w,2}S(1 - S)/n.$$

将上式乘以 $\mathbb{E}[G\mathbf{1}\{U > t\}]$ ，作变量代换 $z = v_+(ct)$ ，再积分，即可证明式 (5-2)。所有积分均有限，因为固定的光滑价值函数使端点处的对数因子可积。若层级上限为 $L_{\max}$ ，则在样本量记号下，截断构造以 $T_k^{(N_0 2^{L_{\max}})}$ 为目标，由此得到文中报告的剩余偏差。这些公式为实际抽样统计量提供独立的总体比较基准，不会以解析量替代样本数据。

附录 6.2 有限样本统计量的精确积分

对收益侧或损失侧中的一侧，先将零点、全部内层效用观测值和外层效用观测值合并，排序后去除重复值。在任意两个相邻断点之间，经验生存概率和外层示性函数都保持常数。因此，可用区间长度乘以 $(w^\varepsilon)'(\hat{S})(I_0 - \hat{S})$ ，再对全部区间求和。超过最大断点后，两者都为零；由于 $f(0,0) = 0$ ，该区间上的被积函数也为零。对另一侧重复相同步骤，再取收益侧与损失侧之差，并乘以共享得分。两个半样本统计量使用相同的外层效用值和得分，但各自使用对应内层半样本产生的断点。

附录 6.3 独立数值梯度检验

单期回放包含一只风险资产，其收益率为 $+r_*$ 或 $-r_*$ ，并且 $U \sim \text{Beta}(e^\theta, 1)$ 。固定情境 (X, r) 后，正相对结果阈值 y 等价于终端财富超过 $r + y/(1 - \eta_+)$ ；损失阈值等价于终端财富低于 $r - y/(1 - \eta_-)$ 。对 $R \neq 0$ ，相应的动作阈值为 $(\text{wealth threshold}/X - 1)/R$ ，并截断到 $[0, 1]$ 。该阈值处的分布函数为 t^{e^θ} ，在区间内部对参数的导数为 $e^\theta t^{e^\theta} \log t$ 。合并两个收益率分支后，可直接得到 $S_\pm$ 和 $\nabla S_\pm$ 。数值计算分别对 $w^\varepsilon(S_\pm)$ 和 $(w^\varepsilon)'(S_\pm)\nabla S_\pm$ 关于效用阈值积分，并在端点断点处分割积分区间。另行对独立积分得到的目标使用中心差分，以交叉检验梯度。将积分阶数加倍得到正文报告的数值稳定性诊断；该比较不构成严格的积分误差证明。

附录 6.4 回放步长的适用区域

对已执行的受控回放, $h = 1$ 、 $c_{tc} = 0$ 、 $|R| \leq 0.04$ 、 $K = 36$, 且 $\Theta = [-2, 2]$ 。均值动作和抽样动作都位于 $[0, 1]$, 所以回放中所有期初财富以及单步假想财富均由 $X_{\max} = 1.04^{K+1}$ 控制。参考点是此前财富与初始参考点的凸组合, 因而同样满足这一上界。由非负性可得 $|Y| \leq X_{\max}$ 。由于该验证中的两个指数和两个平滑尺度分别相同, 取 $B_v = \lambda v_+(X_{\max})$ 。标量 Beta 得分为 $G = 1 + e^\theta \log U$; 随机变量 $-e^\theta \log U$ 服从单位指数分布, 因此 $\mathbb{E}G^2 = 1$ 且 $\mathbb{E}|\partial_\theta G| = 1$ 。于是, 由似然 Hessian 的计算可知, $L = 2B_v(C_2 + 2C_1)$ 是一个有效的保守上界; 实现中取 $a_0 = 1$ 、 $\gamma = 1/(2L)$, 满足 $\gamma L \leq a_0$ 。

附录 6.5 数值精度

统计实验采用有限层级上限和浮点运算。报告的标准误用于量化 Monte Carlo 变动, 积分阶数比较用于评估数值稳定性。解析结果对应满足既定假设的数学抽样构造。发布的源文件记录了随机种子、精度设置、重复模拟输出和逐期记录, 从而可以直接比较数值量与解析量。

致谢

谢谢。本模板仅供内部使用，谢谢配合。

个人简历

基本情况

某某某, 男/女, 某某省某某市/县人, 199? /200? 年 ? 月出生.

教育状况

20XX 年 9 月至 20XX 年 7 月, 某某学校某某学院, 本科, 专业: XXXX。

20XX 年 9 月至 201XX 年 7 月, 上海财经大学统计与管理学院, 硕士研究生, 专业: XXX。

研究兴趣

XXXXXX。

联系方式

E-mail: XXXXXX@mail.shufe.edu.cn.